

# Avances Pr2\_Ad2

Andre Jo

2025-03-07

```
library(GGally)
library(nortest)
library(dplyr)
library(tidyverse)
library(rpart)
library(rpart.plot)
library(caret)
library(discretization)
```

## 1. Conjuntos de Entrenamiento y Prueba


```
datos <- read.csv("test.csv")
mergeprice <- read.csv("sample_submission.csv")
train <- read.csv("train.csv")

datos <- merge(datos, mergeprice)

mergeprice <- datos$SalePrice
datos$SalePrice <- NULL
```

Leemos el conjunto de datos de las casas a observar.

2. Elabore un árbol de regresión para predecir el precio de las casas usando todas las variables



### 3. Úselo para predecir y analice el resultado. ¿Qué tal lo hizo?

```
predModelo1 <- predict(modelo1, newdata = datos)
rmseModelo1test<-RMSE(predModelo1,mergeprice)
mseModelo1test<-mean((predModelo1 - mergeprice)^2)
predModelo1Train <- predict(modelo1, newdata = train)
rmseModelo1train<-RMSE(predModelo1Train,train$SalePrice)
mseModelo1train<-mean((predModelo1Train - train$SalePrice)^2)

rmseModelo1test
```

```
## [1] 77161.11
```


```
rmseModelo1train
```

```
## [1] 38464.11
```

Se observa que el rmse del modelo de prueba es de 38464.11 y el rmse del modelo de entrenamiento es de 77161.11 lo cual sus valores son muy altos lo cual puede indicar un overfitting de los datos.

```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```

## Predicciones vs valores originales



observa en la gráfica y efectivamente se puede respaldar el overfitting en los datos, como se observa con los puntos rojos, se observa líneas de puntos mientras que en los puntos azules se van esparciendo no como la línea de puntos rojos.


```
controlcv <- trainControl(method = "cv", number = 10)
profundidades <- data.frame(c(1,4,6,8,10,12,14))
names(profundidades) <- "maxdepth"
system.time(
  modelo3 <- train(SalePrice ~ .,
    data = train,
    method = "rpart2",
    tuneGrid = profundidades,
    trControl = controlcv,
    metric = "RMSE",
    na.action = na.pass
  )
)
```

```
## user system elapsed
## 2.18 0.14 2.40
```

```
modelo3
```



```
## CART
##
## 1460 samples
## 80 predictor
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 1316, 1313, 1315, 1312, 1315, 1315, ...
## Resampling results across tuning parameters:
##
##  maxdepth  RMSE      Rsquared  MAE
##  1         58159.32  0.4629694 43292.08
##  4         46989.97  0.6516015 32824.88
##  6         47232.59  0.6535426 32367.83
##  8         45463.02  0.6787156 30641.36
##  10        43918.42  0.7042205 29707.93
##  12        43918.42  0.7042205 29707.93
##  14        43918.42  0.7042205 29707.93
##
## RMSE was used to select the optimal model using the smallest value.
## The final value used for the model was maxdepth = 10.
```


```
plot(modelo3)
```



tuneamos la profundidad podemos ver una profundidad máxima de 10. En este caso solo probaremos profundidades menores al árbol anterior.

4. Haga, al menos, 3 modelos más, cambiando el parámetro de la profundidad del árbol. ¿Cuál es el mejor modelo para predecir el precio de las casas?





5.

Compare los resultados con el modelo de regresión lineal de la hoja anterior, ¿cuál lo hizo mejor?

La gráfica que tiene una profundidad de 3 puede predecir mejor el precio de las casas debido a que en la última profundidad de la primera gráfica es solo utilizada para clasificar identificadores lo cual no nos provee una información valiosa lo cual podemos quitar.