

Avances Pr2_Ad2

Andre Jo

2025-03-07


```
library(GGally)
library(nortest)
library(dplyr)
library(tidyverse)
library(rpart)
library(rpart.plot)
library(caret)
library(discretization)
```

```
datos <- read.csv("test.csv")
mergeprice <- read.csv("sample_submission.csv")
train <- read.csv("train.csv")

datos <- merge(datos, mergeprice)

mergeprice <- datos$SalePrice
datos$SalePrice <- NULL
```

Leemos el conjunto de datos de las casas a observar.



```

predModelo1 <- predict(modelo1, newdata = datos)
rmseModelo1test<-RMSE(predModelo1,mergeprice)
mseModelo1test<-mean((predModelo1 - mergeprice)^2)
predModelo1Train <- predict(modelo1, newdata = train)
rmseModelo1train<-RMSE(predModelo1Train,train$SalePrice)
mseModelo1train<-mean((predModelo1Train - train$SalePrice)^2)

rmseModelo1test

```

```
## [1] 77161.11
```

```
rmseModelo1train
```

```
## [1] 38464.11
```


Se observa que el rmse del modelo de prueba es de 38464.11 y el rmse del modelo de entrenamiento es de 77161.11 lo cual sus valores son muy altos lo cual puede indicar un overfitting de los datos.

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

Predicciones vs valores originales



observa en la gráfica y efectivamente se puede respaldar el overfitting en los datos, como se observa con los puntos rojos, se observa líneas de puntos mientras que en los puntos azules se van esparciendo no como la línea de puntos rojos.


```
controlcv <- trainControl(method = "cv", number = 10)
profundidades <- data.frame(c(1,4,6,8,10,12,14))
names(profundidades) <- "maxdepth"
system.time(
  modelo3 <- train(SalePrice ~ .,
    data = train,
    method = "rpart2",
    tuneGrid = profundidades,
    trControl = controlcv,
    metric = "RMSE",
    na.action = na.pass
  )
)
```

```
## user system elapsed
## 1.89 0.07 2.03
```



```
modelo3
```


```
## CART
##
## 1460 samples
## 80 predictor
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 1314, 1314, 1315, 1313, 1312, 1314, ...
## Resampling results across tuning parameters:
##
##  maxdepth  RMSE      Rsquared  MAE
##  1         58562.78  0.4556037  43283.27
##  4         45707.33  0.6762082  32219.43
##  6         46514.14  0.6649888  31865.08
##  8         44084.84  0.7010669  29755.22
##  10        44722.00  0.6964961  29938.22
##  12        44722.00  0.6964961  29938.22
##  14        44722.00  0.6964961  29938.22
##
## RMSE was used to select the optimal model using the smallest value.
## The final value used for the model was maxdepth = 8.
```

```
plot(modelo3)
```



tuneamos la profundidad podemos ver una profundidad máxima de 10. En este caso solo probaremos profundidades menores al árbol anterior.





La

gráfica que tiene una profundidad de 3 puede predecir mejor el precio de las casas debido a que en la última profundidad de la primera gráfica es solo utilizada para clasificar identificadores lo cual no nos provee una información valiosa lo cual podemos quitar.