

Máquinas Vectoriales de Soporte (SVM)

Andre Jo 22199, Nelson Escalante 22046

2025-04-25

Introducción

En el presente trabajo, se tiene como objetivo construir y evaluar modelos predictivos utilizando el algoritmo de Máquinas de Vectores de Soporte (SVM) para clasificar propiedades inmobiliarias según su precio en tres categorías: barata, media y cara. Para ello, se emplearán los mismos conjuntos de datos de entrenamiento y prueba utilizados en trabajos previos, asegurando la consistencia en las evaluaciones.

En primer lugar, se realizará un análisis exploratorio de los datos para identificar las transformaciones necesarias y garantizar que las características sean adecuadas para el entrenamiento del modelo SVM. Se utilizará como variable de respuesta una categorización del precio de las casas, lo que permitirá desarrollar un modelo de clasificación.

A continuación, se llevará a cabo una exploración general de los datos, utilizando herramientas como las cajas de bigote para visualizar la distribución de las variables y detectar posibles valores atípicos.

##	Id	SalePrice	economico	medio	caro
## 1	1461	169277.1	1	0	0
## 2	1462	187758.4	0	1	0
## 3	1463	183583.7	1	0	0
## 4	1464	179317.5	1	0	0
## 5	1465	150730.1	1	0	0
## 6	1466	177151.0	1	0	0

##	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour
## 1	1	60	RL	65	8450	Pave	<NA>	Reg	Lv1
## 2	2	20	RL	80	9600	Pave	<NA>	Reg	Lv1
## 3	3	60	RL	68	11250	Pave	<NA>	IR1	Lv1
## 4	4	70	RL	60	9550	Pave	<NA>	IR1	Lv1
## 5	5	60	RL	84	14260	Pave	<NA>	IR1	Lv1
## 6	6	50	RL	85	14115	Pave	<NA>	IR1	Lv1
##	Utilities	LotConfig	LandSlope	Neighborhood	Condition1	Condition2	BldgType		
## 1	AllPub	Inside	Gtl	CollgCr	Norm	Norm	1Fam		
## 2	AllPub	FR2	Gtl	Veenker	Feedr	Norm	1Fam		
## 3	AllPub	Inside	Gtl	CollgCr	Norm	Norm	1Fam		
## 4	AllPub	Corner	Gtl	Crawfor	Norm	Norm	1Fam		
## 5	AllPub	FR2	Gtl	NoRidge	Norm	Norm	1Fam		
## 6	AllPub	Inside	Gtl	Mitchel	Norm	Norm	1Fam		
##	HouseStyle	OverallQual	OverallCond	YearBuilt	YearRemodAdd	RoofStyle	RoofMatl		
## 1	2Story	7	5	2003	2003	Gable	CompShg		
## 2	1Story	6	8	1976	1976	Gable	CompShg		
## 3	2Story	7	5	2001	2002	Gable	CompShg		
## 4	2Story	7	5	1915	1970	Gable	CompShg		
## 5	2Story	8	5	2000	2000	Gable	CompShg		
## 6	1.5Fin	5	5	1993	1995	Gable	CompShg		
##	Exterior1st	Exterior2nd	MasVnrType	MasVnrArea	ExterQual	ExterCond	Foundation		
## 1	VinylSd	VinylSd	BrkFace	196	Gd	TA	PConc		
## 2	MetalSd	MetalSd	None	0	TA	TA	CBlock		
## 3	VinylSd	VinylSd	BrkFace	162	Gd	TA	PConc		
## 4	Wd Sdng	Wd Shng	None	0	TA	TA	BrkTil		
## 5	VinylSd	VinylSd	BrkFace	350	Gd	TA	PConc		
## 6	VinylSd	VinylSd	None	0	TA	TA	Wood		
##	BsmtQual	BsmtCond	BsmtExposure	BsmtFinType1	BsmtFinSF1	BsmtFinType2			
## 1	Gd	TA	No	GLQ	706	Unf			
## 2	Gd	TA	Gd	ALQ	978	Unf			
## 3	Gd	TA	Mn	GLQ	486	Unf			
## 4	TA	Gd	No	ALQ	216	Unf			
## 5	Gd	TA	Av	GLQ	655	Unf			
## 6	Gd	TA	No	GLQ	732	Unf			
##	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	Heating	HeatingQC	CentralAir	Electrical		
## 1	0	150	856	GasA	Ex	Y	SBrkr		
## 2	0	284	1262	GasA	Ex	Y	SBrkr		
## 3	0	434	920	GasA	Ex	Y	SBrkr		
## 4	0	540	756	GasA	Gd	Y	SBrkr		
## 5	0	490	1145	GasA	Ex	Y	SBrkr		
## 6	0	64	796	GasA	Ex	Y	SBrkr		
##	X1stFlrSF	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	BsmtHalfBath	FullBath		
## 1	856	854	0	1710	1	0	2		
## 2	1262	0	0	1262	0	1	2		
## 3	920	866	0	1786	1	0	2		
## 4	961	756	0	1717	1	0	1		
## 5	1145	1053	0	2198	1	0	2		
## 6	796	566	0	1362	1	0	1		
##	HalfBath	BedroomAbvGr	KitchenAbvGr	KitchenQual	TotRmsAbvGrd	Functional			
## 1	1	3	1	Gd	8	Typ			
## 2	0	3	1	TA	6	Typ			

## 3	1	3	1	Gd	6	Typ			
## 4	0	3	1	Gd	7	Typ			
## 5	1	4	1	Gd	9	Typ			
## 6	1	1	1	TA	5	Typ			
##	Fireplaces	FireplaceQu	GarageType	GarageYrBlt	GarageFinish	GarageCars			
## 1	0	<NA>	Attchd	2003	RFn	2			
## 2	1	TA	Attchd	1976	RFn	2			
## 3	1	TA	Attchd	2001	RFn	2			
## 4	1	Gd	Detchd	1998	Unf	3			
## 5	1	TA	Attchd	2000	RFn	3			
## 6	0	<NA>	Attchd	1993	Unf	2			
##	GarageArea	GarageQual	GarageCond	PavedDrive	WoodDeckSF	OpenPorchSF			
## 1	548	TA	TA	Y	0	61			
## 2	460	TA	TA	Y	298	0			
## 3	608	TA	TA	Y	0	42			
## 4	642	TA	TA	Y	0	35			
## 5	836	TA	TA	Y	192	84			
## 6	480	TA	TA	Y	40	30			
##	EnclosedPorch	X3SsnPorch	ScreenPorch	PoolArea	PoolQC	Fence	MiscFeature		
## 1	0	0	0	0	<NA>	<NA>	<NA>		
## 2	0	0	0	0	<NA>	<NA>	<NA>		
## 3	0	0	0	0	<NA>	<NA>	<NA>		
## 4	272	0	0	0	<NA>	<NA>	<NA>		
## 5	0	0	0	0	<NA>	<NA>	<NA>		
## 6	0	320	0	0	<NA>	MnPrv	Shed		
##	MiscVal	MoSold	YrSold	SaleType	SaleCondition	SalePrice	economico	medio	caro
## 1	0	2	2008	WD	Normal	208500	1	0	0
## 2	0	5	2007	WD	Normal	181500	1	0	0
## 3	0	9	2008	WD	Normal	223500	1	0	0
## 4	0	2	2006	WD	Abnorml	140000	1	0	0
## 5	0	12	2008	WD	Normal	250000	1	0	0
## 6	700	10	2009	WD	Normal	143000	1	0	0

```

##      Id      MSSubClass      MSZoning      LotFrontage
## Min.   :1461  Min.    : 20.00  Length:1459  Min.    : 21.00
## 1st Qu.:1826  1st Qu.: 20.00  Class :character  1st Qu.: 58.00
## Median :2190  Median : 50.00  Mode  :character  Median : 67.00
## Mean   :2190  Mean    : 57.38                      Mean   : 68.58
## 3rd Qu.:2554  3rd Qu.: 70.00                      3rd Qu.: 80.00
## Max.   :2919  Max.    :190.00                      Max.    :200.00
##                                     NA's    :227
##
##      LotArea      Street      Alley      LotShape
## Min.    : 1470  Length:1459  Length:1459  Length:1459
## 1st Qu.: 7391  Class :character  Class :character  Class :character
## Median : 9399  Mode  :character  Mode  :character  Mode  :character
## Mean    : 9819
## 3rd Qu.:11518
## Max.    :56600
##
##      LandContour      Utilities      LotConfig      LandSlope
## Length:1459      Length:1459      Length:1459      Length:1459
## Class :character  Class :character  Class :character  Class :character
## Mode  :character  Mode  :character  Mode  :character  Mode  :character
##
##
##
##      Neighborhood      Condition1      Condition2      BldgType
## Length:1459      Length:1459      Length:1459      Length:1459
## Class :character  Class :character  Class :character  Class :character
## Mode  :character  Mode  :character  Mode  :character  Mode  :character
##
##
##
##      HouseStyle      OverallQual      OverallCond      YearBuilt
## Length:1459      Min.    : 1.000  Min.    :1.000  Min.    :1879
## Class :character  1st Qu.: 5.000  1st Qu.:5.000  1st Qu.:1953
## Mode  :character  Median : 6.000  Median :5.000  Median :1973
##                                     Mean   : 6.079  Mean   :5.554  Mean   :1971
##                                     3rd Qu.: 7.000  3rd Qu.:6.000  3rd Qu.:2001
##                                     Max.    :10.000  Max.    :9.000  Max.    :2010
##
##      YearRemodAdd      RoofStyle      RoofMatl      Exterior1st
## Min.    :1950  Length:1459  Length:1459  Length:1459
## 1st Qu.:1963  Class :character  Class :character  Class :character
## Median :1992  Mode  :character  Mode  :character  Mode  :character
## Mean    :1984
## 3rd Qu.:2004
## Max.    :2010
##
##      Exterior2nd      MasVnrType      MasVnrArea      ExterQual
## Length:1459      Length:1459      Min.    : 0.0  Length:1459
## Class :character  Class :character  1st Qu.: 0.0  Class :character
## Mode  :character  Mode :character  Median : 0.0  Mode  :character

```

```

##                               Mean   : 100.7
##                               3rd Qu.: 164.0
##                               Max.   :1290.0
##                               NA's   :15
##      ExterCond      Foundation      BsmtQual      BsmtCond
## Length:1459      Length:1459      Length:1459      Length:1459
## Class :character  Class :character  Class :character  Class :character
## Mode  :character  Mode  :character  Mode  :character  Mode  :character
##
##
##
##
## BsmtExposure      BsmtFinType1      BsmtFinSF1      BsmtFinType2
## Length:1459      Length:1459      Min.   : 0.0      Length:1459
## Class :character  Class :character  1st Qu.: 0.0      Class :character
## Mode  :character  Mode  :character  Median : 350.5    Mode  :character
##                               Mean   : 439.2
##                               3rd Qu.: 753.5
##                               Max.   :4010.0
##                               NA's   :1
##      BsmtFinSF2      BsmtUnfSF      TotalBsmtSF      Heating
## Min.   : 0.00      Min.   : 0.0      Min.   : 0      Length:1459
## 1st Qu.: 0.00      1st Qu.: 219.2    1st Qu.: 784      Class :character
## Median : 0.00      Median : 460.0    Median : 988      Mode  :character
## Mean   : 52.62      Mean   : 554.3      Mean  :1046
## 3rd Qu.: 0.00      3rd Qu.: 797.8      3rd Qu.:1305
## Max.   :1526.00      Max.   :2140.0      Max.   :5095
## NA's   :1          NA's   :1          NA's   :1
##      HeatingQC      CentralAir      Electrical      X1stFlrSF
## Length:1459      Length:1459      Length:1459      Min.   : 407.0
## Class :character  Class :character  Class :character  1st Qu.: 873.5
## Mode  :character  Mode  :character  Mode  :character  Median :1079.0
##                               Mean   :1156.5
##                               3rd Qu.:1382.5
##                               Max.   :5095.0
##
##      X2ndFlrSF      LowQualFinSF      GrLivArea      BsmtFullBath
## Min.   : 0      Min.   : 0.000      Min.   : 407      Min.   :0.0000
## 1st Qu.: 0      1st Qu.: 0.000      1st Qu.:1118      1st Qu.:0.0000
## Median : 0      Median : 0.000      Median :1432      Median :0.0000
## Mean   : 326      Mean   : 3.543      Mean   :1486      Mean   :0.4345
## 3rd Qu.: 676      3rd Qu.: 0.000      3rd Qu.:1721      3rd Qu.:1.0000
## Max.   :1862      Max.   :1064.000      Max.   :5095      Max.   :3.0000
##                               NA's   :2
##      BsmtHalfBath      FullBath      HalfBath      BedroomAbvGr
## Min.   :0.0000      Min.   :0.000      Min.   :0.0000      Min.   :0.000
## 1st Qu.:0.0000      1st Qu.:1.000      1st Qu.:0.0000      1st Qu.:2.000
## Median :0.0000      Median :2.000      Median :0.0000      Median :3.000
## Mean   :0.0652      Mean   :1.571      Mean   :0.3777      Mean   :2.854
## 3rd Qu.:0.0000      3rd Qu.:2.000      3rd Qu.:1.0000      3rd Qu.:3.000
## Max.   :2.0000      Max.   :4.000      Max.   :2.0000      Max.   :6.000
## NA's   :2

```

```


## KitchenAbvGr KitchenQual TotRmsAbvGrd Functional
## Min. :0.000 Length:1459 Min. : 3.000 Length:1459
## 1st Qu.:1.000 Class :character 1st Qu.: 5.000 Class :character
## Median :1.000 Mode :character Median : 6.000 Mode :character
## Mean :1.042 Mean : 6.385
## 3rd Qu.:1.000 3rd Qu.: 7.000
## Max. :2.000 Max. :15.000
##
## Fireplaces FireplaceQu GarageType GarageYrBlt
## Min. :0.0000 Length:1459 Length:1459 Min. :1895
## 1st Qu.:0.0000 Class :character Class :character 1st Qu.:1959
## Median :0.0000 Mode :character Mode :character Median :1979
## Mean :0.5812 Mean :1978
## 3rd Qu.:1.0000 3rd Qu.:2002
## Max. :4.0000 Max. :2207
## NA's :78
## GarageFinish GarageCars GarageArea GarageQual
## Length:1459 Min. :0.000 Min. : 0.0 Length:1459
## Class :character 1st Qu.:1.000 1st Qu.: 318.0 Class :character
## Mode :character Median :2.000 Median : 480.0 Mode :character
## Mean :1.766 Mean : 472.8
## 3rd Qu.:2.000 3rd Qu.: 576.0
## Max. :5.000 Max. :1488.0
## NA's :1 NA's :1
## GarageCond PavedDrive WoodDeckSF OpenPorchSF
## Length:1459 Length:1459 Min. : 0.00 Min. : 0.00
## Class :character Class :character 1st Qu.: 0.00 1st Qu.: 0.00
## Mode :character Mode :character Median : 0.00 Median : 28.00
## Mean : 93.17 Mean : 48.31
## 3rd Qu.: 168.00 3rd Qu.: 72.00
## Max. :1424.00 Max. :742.00
##
## EnclosedPorch X3SsnPorch ScreenPorch PoolArea
## Min. : 0.00 Min. : 0.000 Min. : 0.00 Min. : 0.000
## 1st Qu.: 0.00 1st Qu.: 0.000 1st Qu.: 0.00 1st Qu.: 0.000
## Median : 0.00 Median : 0.000 Median : 0.00 Median : 0.000
## Mean : 24.24 Mean : 1.794 Mean : 17.06 Mean : 1.744
## 3rd Qu.: 0.00 3rd Qu.: 0.000 3rd Qu.: 0.00 3rd Qu.: 0.000
## Max. :1012.00 Max. :360.000 Max. :576.00 Max. :800.000
##
## PoolQC Fence MiscFeature MiscVal
## Length:1459 Length:1459 Length:1459 Min. : 0.00
## Class :character Class :character Class :character 1st Qu.: 0.00
## Mode :character Mode :character Mode :character Median : 0.00
## Mean : 58.17
## 3rd Qu.: 0.00
## Max. :17000.00
##
## MoSold YrSold SaleType SaleCondition
## Min. : 1.000 Min. :2006 Length:1459 Length:1459
## 1st Qu.: 4.000 1st Qu.:2007 Class :character Class :character
## Median : 6.000 Median :2008 Mode :character Mode :character

```

```
## Mean : 6.104 Mean :2008
## 3rd Qu.: 8.000 3rd Qu.:2009
## Max. :12.000 Max. :2010
##
```


```
##      Id      SalePrice      economico      medio
## Min. :1461 Min. :135751 Min. :0.0000 Min. :0.0000
## 1st Qu.:1826 1st Qu.:168703 1st Qu.:0.0000 1st Qu.:0.0000
## Median :2190 Median :179209 Median :1.0000 Median :0.0000
## Mean :2190 Mean :179184 Mean :0.6923 Mean :0.3009
## 3rd Qu.:2554 3rd Qu.:186789 3rd Qu.:1.0000 3rd Qu.:1.0000
## Max. :2919 Max. :281644 Max. :1.0000 Max. :1.0000
##      caro      category
## Min. :0.000000 Length:1459
## 1st Qu.:0.000000 Class :character
## Median :0.000000 Mode :character
## Mean :0.006854
## 3rd Qu.:0.000000
## Max. :1.000000
```

Se observa que utilizamos para la variable objetivo tres categorías, economico, caro y medio donde primero calculamos el valor de la casa máxima y el mínimo valor de la casa donde luego lo restamos el valor máximo con el mínimo y luego dividirlo entre tres para así diferenciar que casa debería de pertenecer en esas tres variables.




observa que las casas que tienen una condición de venta "Normal" son las más caras. En comparación, otras casas con diferentes condiciones tienden a ser económicas o de bajo costo. Aunque también se observa que la

condición “Family” tiende a presentar un precio medio.



observa que las casas con escritura “WD” presentan un mayor rango de precios, concentrándose en viviendas caras y con áreas superiores a los 30,000 m². Sin embargo, también se identifican varios puntos atípicos en este grupo. Por otro lado, las propiedades con escritura tipo “COD” (escritura emitida por un funcionario judicial) tienden a ubicarse en un rango de entre 0 y 20,000 m², con precios mayormente medios y algunos económicos. Finalmente, las viviendas con tipo de venta “ConLI” (contrato con interés bajo) se asocian exclusivamente a casas económicas, sin presencia en los rangos de precio medio o alto.



observa en este diagrama de caja y bigotes que la mayoría de las casas clasificadas como “caras” forman parte del tipo de venta “WD”, que corresponde a la transferencia mediante escritura. Por otro lado, las categorías “caro” y “medio” se encuentran en un rango similar, aunque “caro” presenta un rango más amplio. También se puede notar que dentro del criterio “WD” existen casos tanto económicos como de precio medio. Por otro lado, las casas vendidas bajo condiciones de menor interés (como “ConLI”) presentan un mayor volumen de viviendas económicas, lo cual resulta coherente con el tipo de financiación ofrecido.

En base a los datos explorados podemos observar o utilizar ciertas variables para generar el modelo SVM. A continuación se realizaran varios modelos tuneados de SVM para realizar comparaciones ante la eficiencia y exactitud de otros modelos.

```
## Loading required package: lattice
```

```
##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##   filter, lag
```

```
## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

```
##
##
## ===== MODELO 1: SVM LINEAL =====
```

```
##
## ===== Resultados para SVM Lineal (C=1) =====
## Precisión en train: 96.38 %
## Precisión en test: 95.65 %
## Diferencia (train-test): 0.73 % puntos
##
## Matriz de confusión (datos de prueba):
##           Reference
## Prediction caro economico medio
## caro        2          1      1
## economico   0        381     9
## medio       0          8    35
##
## Diagnóstico: El modelo parece estar bien ajustado
```

```
##
##
## ===== MODELO 2: SVM POLINOMIAL =====
```

```
##
## ===== Resultados para SVM Polinomial (grado=2, C=1) =====
## Precisión en train: 95.21 %
## Precisión en test: 94.51 %
## Diferencia (train-test): 0.7 % puntos
##
## Matriz de confusión (datos de prueba):
##           Reference
## Prediction caro economico medio
## caro        0          1      1
## economico   1        383    14
## medio       1          6    30
##
## Diagnóstico: El modelo parece estar bien ajustado
```

```
##
##
## ===== MODELO 3: SVM RADIAL =====
```


```
##
## ===== Resultados para SVM Radial (gamma=0.1, C=1) =====
## Precisión en train: 97.07 %
## Precisión en test: 94.97 %
## Diferencia (train-test): 2.1 % puntos
##
## Matriz de confusión (datos de prueba):
##           Reference
## Prediction  caro economico medio
##   caro           0           0       0
##   economico      0          382      12
##   medio          2           8       33
##
## Diagnóstico: El modelo parece estar bien ajustado
```

```
##
##
## ===== MODELO 4: SVM RADIAL CON MAYOR REGULARIZACIÓN =====
```

```
##
## ===== Resultados para SVM Radial Regularizado (gamma=0.01, C=0.5) =====
## Precisión en train: 94.92 %
## Precisión en test: 95.42 %
## Diferencia (train-test): -0.51 % puntos
##
## Matriz de confusión (datos de prueba):
##           Reference
## Prediction  caro economico medio
##   caro           0           0       0
##   economico      0          383      11
##   medio          2           7       34
##
## Diagnóstico: El modelo parece estar bien ajustado
```


##	Modelo	Precisión_Train	Precisión_Test	Diferencia
## 1	SVM Lineal	0.9638319	0.9565217	0.007310128
## 2	SVM Polinomial	0.9521017	0.9450801	0.007021570
## 3	SVM Radial	0.9706745	0.9496568	0.021017736
## 4	SVM Radial Regularizado	0.9491691	0.9542334	-0.005064299

Comparación de Precisión entre Modelos SVM



Diferencia entre Precisión de Train y Test

Valores más altos indican mayor riesgo de sobreajuste



```
## El mejor modelo según precisión en validación es: SVM Lineal
```

Todos los modelos parecen tener una precisión demasiado alta, lo que podría ser indicador de sobreajuste, pero el modelo con la mayor diferencia de precisión (y la precisión más alta) parece ser el SVM Radial. Para manejar posibles sobreajustes se podría:


- Reducir la complejidad del modelo (con menor gamma o grado polinomial)
- Aumentar la regularización
- Reducir el número de variables predictoras
- Usar validación cruzada

Al observar la eficiencia de diferentes modelos podemos notar que hay algunos más eficientes que el modelo SVM pero, el modelo SVM se puede realizar un tuneo con la finalidad de observar si es más eficiente o mejor que otros modelos. A continuación se realizará el tuneo de SVM lineal y realizar la comparación ante modelos como KNN, naive Bayes con el criterio del menor RMSE.

```
## [1] 70803.9
```


Al normalizar los datos y reemplazar valores NA's observamos que el RMSE del modelo SVM lineal está en los rangos adecuados de otros modelos pero se observa en un momento que este no es un modelo con el menor RMSE.

Comparación: Valores Reales vs. Predicciones



Como se muestra en la gráfica, observamos que los valores predicho se acercan más a los valores reales y confirme se observa este es el mejor para realizar comparación ante valores reales y predichos que otros modelos.

Comparación: Valores Reales vs. Predicciones




observa en la gráfica del modelo KNN que hay algunos puntos que si pudo predecir y además no hay evidencia de sobreajuste. Pero, se observa que el modelo SVM lineal es el mejor al realizar predicciones.

```
RMSE(predModelo3, datos$SalePrice)
```

```
## [1] 62053.9
```

Observamos que KNN tiene el menor RMSE de los modelos a analizar. Este modelo puede ser el menor RMSE de los modelos pero no haya mejor gráfica que SVM lineal.

El modelo a utilizar es Naive Bayes donde a continuación se presentara la gráfica y su RMSE.




observa en la gráfica que no es un modelo tan óptimo ya que presenta algunos datos con sobreajuste pero existen otros datos que no están sobreajustados.

```
RMSE(predBayes, datos$SalePrice)
```

```
## [1] 70237.08
```

Por otro lado vemos que el RMSE es menor que SVM lineal. Aunque no es uno de los mejores modelos, en el siguiente modelo a comparar observamos el mayor RMSE y sobreajuste de datos.




EI

modelo presentado es un árbol de decisión en la cual tenemos 4 niveles de comparación. Además en se observa que RMSE es el mayor de todos los modelos presentados.

```
## [1] 77161.11
```

se observa que el rmse del modelo de prueba es de 77161.11 lo cual sus valores son muy altos lo cual puede indicar un overfitting de los datos como se muestra en la siguiente gráfica.

Predicciones vs valores originales




observa en la gráfica y efectivamente se puede respaldar el overfitting en los datos, como se observa con los puntos rojos, se observa líneas de puntos mientras que en los puntos azules se van espaciando no como la línea de puntos rojos.

```
fitLMPW<-lm(SalePrice~LotArea, data = train)
```

```
ggplot(data = train, mapping = aes(x = SalePrice, y = LotArea)) +
  geom_point(color = "firebrick", size = 2) +
  geom_smooth(method = "lm", se = TRUE, color = "black") +
  labs(title = "Precio Casas ~ Area del lote", x = "Precio", y = "Area") +
  theme_bw() + theme(plot.title = element_text(hjust = 0.5))
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

Precio Casas ~ Area del lote



Usando esta ecuación podemos predecir la Venta de casa para el conjunto de prueba.

```
predL<-predict(fitLMPW, newdata = datos)
```

Al sacar la predicción observamos que este modelo tiene un RMSE muy alto lo cual podemos argumentar y analizar con las siguientes gráficas.

```
RMSE(predL, price$SalePrice)
```

```
## [1] 11620.85
```

```
head(predL)
```

```
##      1      2      3      4      5      6
## 183242.0 188796.5 187878.8 179789.7 169346.5 179835.9
```

```
length(predL)
```

```
## [1] 1459
```



Para saber que tan bueno es el modelo para predecir dados los datos de entrenamiento se deben analizar los residuos. Estos no pueden seguir ningún patrón, es decir que deben ser aleatorios alrededor de 0. Deben estar distribuidos normalmente.

```
head(fitLMPW$residuals)
```

```
##           1           2           3           4           5           6
## 31919.085  2504.117  41039.164 -38890.884  61218.248 -45477.256
```

En los siguientes gráficos se pueden analizar los residuales.

```
plot(fitLMPW)
```








gráfico **Residuals vs Fitted** se puede ver que no parece haber un patrón y que los puntos están aleatoriamente


distribuidos alrededor de 0.

```
hist(fitLMPW$residuals)
```

Histogram of fitLMPW\$residuals




```
boxplot(fitLMPW$residuals)
```



```
qqnorm(fitLMPW$residuals)
qqline(fitLMPW$residuals, col="red")
```

Normal Q-Q Plot



observa con el histograma que los datos están distribuidos de manera aproximadamente normal, aunque no de forma perfecta. Además, se nota que las colas del QQ plot no están alineadas con la línea de tendencia, lo cual podría indicar un sobreajuste en los modelos, lo que se puede observar en ciertos modelos, como el árbol de regresión. Por otro lado, en el diagrama de cajas de bigote se pueden identificar dos datos atípicos, los cuales podrían representar ventas de casas en ocasiones raras. Por lo tanto en breve se presentarán las conclusiones a realizar en todos los modelos realizado, comparaciones, eficiencia, entre otros aspectos.

En conclusión, tras evaluar los diferentes modelos de regresión, se observa que el modelo de KNN presenta un bajo valor de RMSE, lo que indica una buena precisión en sus predicciones. Sin embargo, al analizar la dispersión de los puntos predichos frente a los valores reales, se puede notar que el modelo de SVM lineal tiene los puntos más cercanos a los valores reales en comparación con el KNN, lo que sugiere una mejor capacidad de generalización. En contraste, otros modelos presentaron signos de sobreajuste o un RMSE elevado, lo que indica que no lograron generalizar bien los datos.