

Proyecto 2 - Entrega 1

Modelo de regresion lineal.

Nelson Escalante - 22046

PARTE 1: Analisis exploratorio de los datos.

Setup

```
In [3]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Analisis

```
In [4]: #Direccion del archivo
path = "data/train.csv"

houses = pd.read_csv(path)
houses.head()
```

```
Out[4]:
```

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape
0	1	60	RL	65.0	8450	Pave	NaN	Reg
1	2	20	RL	80.0	9600	Pave	NaN	Reg
2	3	60	RL	68.0	11250	Pave	NaN	IR1
3	4	70	RL	60.0	9550	Pave	NaN	IR1
4	5	60	RL	84.0	14260	Pave	NaN	IR1

5 rows × 81 columns

```
In [5]: houses.shape
```

```
Out[5]: (1460, 81)
```

```
In [6]: houses.info()
```

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1460 entries, 0 to 1459

Data columns (total 81 columns):

#	Column	Non-Null Count	Dtype
0	Id	1460 non-null	int64
1	MSSubClass	1460 non-null	int64
2	MSZoning	1460 non-null	object
3	LotFrontage	1201 non-null	float64
4	LotArea	1460 non-null	int64
5	Street	1460 non-null	object
6	Alley	91 non-null	object
7	LotShape	1460 non-null	object
8	LandContour	1460 non-null	object
9	Utilities	1460 non-null	object
10	LotConfig	1460 non-null	object
11	LandSlope	1460 non-null	object
12	Neighborhood	1460 non-null	object
13	Condition1	1460 non-null	object
14	Condition2	1460 non-null	object
15	BldgType	1460 non-null	object
16	HouseStyle	1460 non-null	object
17	OverallQual	1460 non-null	int64
18	OverallCond	1460 non-null	int64
19	YearBuilt	1460 non-null	int64
20	YearRemodAdd	1460 non-null	int64
21	RoofStyle	1460 non-null	object
22	RoofMatl	1460 non-null	object
23	Exterior1st	1460 non-null	object
24	Exterior2nd	1460 non-null	object
25	MasVnrType	588 non-null	object
26	MasVnrArea	1452 non-null	float64
27	ExterQual	1460 non-null	object
28	ExterCond	1460 non-null	object
29	Foundation	1460 non-null	object
30	BsmtQual	1423 non-null	object
31	BsmtCond	1423 non-null	object
32	BsmtExposure	1422 non-null	object
33	BsmtFinType1	1423 non-null	object
34	BsmtFinSF1	1460 non-null	int64
35	BsmtFinType2	1422 non-null	object
36	BsmtFinSF2	1460 non-null	int64
37	BsmtUnfSF	1460 non-null	int64
38	TotalBsmtSF	1460 non-null	int64
39	Heating	1460 non-null	object
40	HeatingQC	1460 non-null	object
41	CentralAir	1460 non-null	object
42	Electrical	1459 non-null	object
43	1stFlrSF	1460 non-null	int64
44	2ndFlrSF	1460 non-null	int64
45	LowQualFinSF	1460 non-null	int64
46	GrLivArea	1460 non-null	int64
47	BsmtFullBath	1460 non-null	int64
48	BsmtHalfBath	1460 non-null	int64
49	FullBath	1460 non-null	int64
50	HalfBath	1460 non-null	int64

51	BedroomAbvGr	1460	non-null	int64
52	KitchenAbvGr	1460	non-null	int64
53	KitchenQual	1460	non-null	object
54	TotRmsAbvGrd	1460	non-null	int64
55	Functional	1460	non-null	object
56	Fireplaces	1460	non-null	int64
57	FireplaceQu	770	non-null	object
58	GarageType	1379	non-null	object
59	GarageYrBlt	1379	non-null	float64
60	GarageFinish	1379	non-null	object
61	GarageCars	1460	non-null	int64
62	GarageArea	1460	non-null	int64
63	GarageQual	1379	non-null	object
64	GarageCond	1379	non-null	object
65	PavedDrive	1460	non-null	object
66	WoodDeckSF	1460	non-null	int64
67	OpenPorchSF	1460	non-null	int64
68	EnclosedPorch	1460	non-null	int64
69	3SsnPorch	1460	non-null	int64
70	ScreenPorch	1460	non-null	int64
71	PoolArea	1460	non-null	int64
72	PoolQC	7	non-null	object
73	Fence	281	non-null	object
74	MiscFeature	54	non-null	object
75	MiscVal	1460	non-null	int64
76	MoSold	1460	non-null	int64
77	YrSold	1460	non-null	int64
78	SaleType	1460	non-null	object
79	SaleCondition	1460	non-null	object
80	SalePrice	1460	non-null	int64

dtypes: float64(3), int64(35), object(43)
memory usage: 924.0+ KB

Se puede observar que contamos con mas variables categoricas que numericas.
Ademas, las siguientes columnas contienen datos nulos:

- LotFrontage
- Alley
- MasVnrType
- MasVnrArea
- BsmtQual
- BsmtCond
- BsmtExposure
- BsmtFinType1
- BsmtFinType2
- Electrical
- FireplaceQu
- GarageType
- GarageYrBlt
- GarageFinish
- GarageQual

- GarageCond
- PoolQC
- Fence
- MiscFeature

```
In [8]: #Variables numericas
numeric = [
    'Id',
    # 'MSSubClass', <- Es una variable que utiliza numeros para representar l
    'LotFrontage',
    'LotArea',
    'OverallQual',
    'OverallCond',
    'YearBuilt',
    'YearRemodAdd',
    'MasVnrArea',
    'BsmtFinSF1',
    'BsmtFinSF2',
    'BsmtUnfSF',
    'TotalBsmtSF',
    '1stFlrSF',
    '2ndFlrSF',
    'LowQualFinSF',
    'GrLivArea',
    'BsmtFullBath',
    'BsmtHalfBath',
    'FullBath',
    'HalfBath',
    'BedroomAbvGr',
    'KitchenAbvGr',
    'TotRmsAbvGr',
    'Fireplaces',
    'GarageYrBlt',
    'GarageCars',
    'GarageArea',
    'WoodDeckSF',
    'OpenPorchSF',
    'EnclosedPorch',
    '3SsnPorch',
    'ScreenPorch',
    'PoolArea',
    'MiscVal',
    'MoSold',
    'YrSold',
    'SalePrice'
]
```

Al tener una lista de variables numericas podemos utilizarlas para realizar analisis detallados de los datos.

```
In [9]: #Categorias unicas en variables categoricas
houses.select_dtypes(include=['object']).nunique()
```

```

Out[9]: MSZoning      5
        Street        2
        Alley         2
        LotShape      4
        LandContour   4
        Utilities     2
        LotConfig     5
        LandSlope     3
        Neighborhood  25
        Condition1    9
        Condition2    8
        BldgType      5
        HouseStyle    8
        RoofStyle     6
        RoofMatl      8
        Exterior1st   15
        Exterior2nd   16
        MasVnrType    3
        ExterQual     4
        ExterCond     5
        Foundation    6
        BsmtQual      4
        BsmtCond      4
        BsmtExposure  4
        BsmtFinType1  6
        BsmtFinType2  6
        Heating       6
        HeatingQC     5
        CentralAir    2
        Electrical    5
        KitchenQual   4
        Functional    7
        FireplaceQu   5
        GarageType    6
        GarageFinish  3
        GarageQual    5
        GarageCond    5
        PavedDrive    3
        PoolQC        3
        Fence         4
        MiscFeature   4
        SaleType      9
        SaleCondition 6
        dtype: int64

```

En base a los datos recopilados en el analisis, y gracias tambien al archivo 'data_description.txt' que venia junto a los datos, podemos identificar las variables clave en nuestro dataset.

```

In [10]: #Variables clave
key_var = [
    'MSSubClass',
    'MSZoning',
    'LotArea',
    'Street',

```

```
'Alley',  
'LandContour',  
'Utilities',  
'LotConfig',  
'Neighborhood',  
'Condition1',  
'Condition2',  
'HouseStyle',  
'OverallQual',  
'OverallCond',  
'Exterior1st',  
'Exterior2nd',  
'ExterQual',  
'ExterCond',  
'BsmtQual',  
'BstmCond',  
'TotalBsmtSF',  
'Heating',  
'CentralAir',  
'GrLivArea',  
'FullBath',  
'Bedroom',  
'Kitchen',  
'TotRmsAbvGrd',  
'Functional',  
'Fireplaces',  
'GarageType',  
'GarageArea',  
'GarageQual',  
'PoolArea',  
'MiscFeature'  
]
```


```
In [11]: key_var.__len__()
```

```
Out[11]: 35
```

Estas seran las variables sobre las cuales realizaremos un analisis mas a fondo y buscaremos relaciones para realizar predicciones de los precios de las casas. Estas variables fueron seleccionadas debido a la relevancia que tienen sobre estos precios, por lo que se espera que sean utiles en los pasos siguientes.

Ademas de el analisis de las variables, es importante analizar el comportamiento de la variable objetivo de nuestra investigacion: SalePrice

```
In [12]: plt.figure(figsize=(8, 5))  
sns.histplot(houses['SalePrice'], bins=30, kde=True)  
plt.title("Distribución del Precio de las Casas")  
plt.xlabel("Precio de Venta (USD)")  
plt.ylabel("Frecuencia")  
plt.show()
```



Gracias a la grafica podemos observar que la distribucion de del precio es una distribucion normal con sesgo positivo, es decir, hacia la derecha. En base a esto podemos asumir que hay muchas casas con precios relativamente bajos, pero tambien hay casas con precios muy altos que elevan la media de los precios.

Hay que tomar en cuenta este comportamiento, ya que puede afectar en algunos modelos de regresion.