

Proyecto 2 - Entrega 1

Modelo de regresion lineal.

Nelson Escalante - 22046

PARTE 1: Analisis exploratorio de los datos.

Setup

```
In [3]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

Analisis

```
In [4]: #Direccion del archivo
path = "data/train.csv"

houses = pd.read_csv(path)
houses.head()
```

```
Out[4]:
```

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape
0	1	60	RL	65.0	8450	Pave	NaN	Reg
1	2	20	RL	80.0	9600	Pave	NaN	Reg
2	3	60	RL	68.0	11250	Pave	NaN	IR1
3	4	70	RL	60.0	9550	Pave	NaN	IR1
4	5	60	RL	84.0	14260	Pave	NaN	IR1

5 rows × 81 columns

```
In [5]: houses.shape
```

```
Out[5]: (1460, 81)
```

```
In [6]: houses.info()
```

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1460 entries, 0 to 1459

Data columns (total 81 columns):

#	Column	Non-Null Count	Dtype
0	Id	1460 non-null	int64
1	MSSubClass	1460 non-null	int64
2	MSZoning	1460 non-null	object
3	LotFrontage	1201 non-null	float64
4	LotArea	1460 non-null	int64
5	Street	1460 non-null	object
6	Alley	91 non-null	object
7	LotShape	1460 non-null	object
8	LandContour	1460 non-null	object
9	Utilities	1460 non-null	object
10	LotConfig	1460 non-null	object
11	LandSlope	1460 non-null	object
12	Neighborhood	1460 non-null	object
13	Condition1	1460 non-null	object
14	Condition2	1460 non-null	object
15	BldgType	1460 non-null	object
16	HouseStyle	1460 non-null	object
17	OverallQual	1460 non-null	int64
18	OverallCond	1460 non-null	int64
19	YearBuilt	1460 non-null	int64
20	YearRemodAdd	1460 non-null	int64
21	RoofStyle	1460 non-null	object
22	RoofMatl	1460 non-null	object
23	Exterior1st	1460 non-null	object
24	Exterior2nd	1460 non-null	object
25	MasVnrType	588 non-null	object
26	MasVnrArea	1452 non-null	float64
27	ExterQual	1460 non-null	object
28	ExterCond	1460 non-null	object
29	Foundation	1460 non-null	object
30	BsmtQual	1423 non-null	object
31	BsmtCond	1423 non-null	object
32	BsmtExposure	1422 non-null	object
33	BsmtFinType1	1423 non-null	object
34	BsmtFinSF1	1460 non-null	int64
35	BsmtFinType2	1422 non-null	object
36	BsmtFinSF2	1460 non-null	int64
37	BsmtUnfSF	1460 non-null	int64
38	TotalBsmtSF	1460 non-null	int64
39	Heating	1460 non-null	object
40	HeatingQC	1460 non-null	object
41	CentralAir	1460 non-null	object
42	Electrical	1459 non-null	object
43	1stFlrSF	1460 non-null	int64
44	2ndFlrSF	1460 non-null	int64
45	LowQualFinSF	1460 non-null	int64
46	GrLivArea	1460 non-null	int64
47	BsmtFullBath	1460 non-null	int64
48	BsmtHalfBath	1460 non-null	int64
49	FullBath	1460 non-null	int64
50	HalfBath	1460 non-null	int64

51	BedroomAbvGr	1460	non-null	int64
52	KitchenAbvGr	1460	non-null	int64
53	KitchenQual	1460	non-null	object
54	TotRmsAbvGrd	1460	non-null	int64
55	Functional	1460	non-null	object
56	Fireplaces	1460	non-null	int64
57	FireplaceQu	770	non-null	object
58	GarageType	1379	non-null	object
59	GarageYrBlt	1379	non-null	float64
60	GarageFinish	1379	non-null	object
61	GarageCars	1460	non-null	int64
62	GarageArea	1460	non-null	int64
63	GarageQual	1379	non-null	object
64	GarageCond	1379	non-null	object
65	PavedDrive	1460	non-null	object
66	WoodDeckSF	1460	non-null	int64
67	OpenPorchSF	1460	non-null	int64
68	EnclosedPorch	1460	non-null	int64
69	3SsnPorch	1460	non-null	int64
70	ScreenPorch	1460	non-null	int64
71	PoolArea	1460	non-null	int64
72	PoolQC	7	non-null	object
73	Fence	281	non-null	object
74	MiscFeature	54	non-null	object
75	MiscVal	1460	non-null	int64
76	MoSold	1460	non-null	int64
77	YrSold	1460	non-null	int64
78	SaleType	1460	non-null	object
79	SaleCondition	1460	non-null	object
80	SalePrice	1460	non-null	int64

dtypes: float64(3), int64(35), object(43)
memory usage: 924.0+ KB

Se puede observar que contamos con mas variables categoricas que numericas.
Ademas, las siguientes columnas contienen datos nulos:

- LotFrontage
- Alley
- MasVnrType
- MasVnrArea
- BsmtQual
- BsmtCond
- BsmtExposure
- BsmtFinType1
- BsmtFinType2
- Electrical
- FireplaceQu
- GarageType
- GarageYrBlt
- GarageFinish
- GarageQual

- GarageCond
- PoolQC
- Fence
- MiscFeature

```
In [8]: #Variables numericas
numeric = [
    'Id',
    # 'MSSubClass', <- Es una variable que utiliza numeros para representar l
    'LotFrontage',
    'LotArea',
    'OverallQual',
    'OverallCond',
    'YearBuilt',
    'YearRemodAdd',
    'MasVnrArea',
    'BsmtFinSF1',
    'BsmtFinSF2',
    'BsmtUnfSF',
    'TotalBsmtSF',
    '1stFlrSF',
    '2ndFlrSF',
    'LowQualFinSF',
    'GrLivArea',
    'BsmtFullBath',
    'BsmtHalfBath',
    'FullBath',
    'HalfBath',
    'BedroomAbvGr',
    'KitchenAbvGr',
    'TotRmsAbvGr',
    'Fireplaces',
    'GarageYrBlt',
    'GarageCars',
    'GarageArea',
    'WoodDeckSF',
    'OpenPorchSF',
    'EnclosedPorch',
    '3SsnPorch',
    'ScreenPorch',
    'PoolArea',
    'MiscVal',
    'MoSold',
    'YrSold',
    'SalePrice'
]
```

Al tener una lista de variables numericas podemos utilizarlas para realizar analisis detallados de los datos.

```
In [9]: #Categorias unicas en variables categoricas
houses.select_dtypes(include=['object']).nunique()
```

```

Out[9]: MSZoning      5
        Street        2
        Alley         2
        LotShape      4
        LandContour   4
        Utilities     2
        LotConfig     5
        LandSlope     3
        Neighborhood  25
        Condition1    9
        Condition2    8
        BldgType      5
        HouseStyle    8
        RoofStyle     6
        RoofMatl      8
        Exterior1st   15
        Exterior2nd   16
        MasVnrType    3
        ExterQual     4
        ExterCond     5
        Foundation    6
        BsmtQual      4
        BsmtCond      4
        BsmtExposure  4
        BsmtFinType1  6
        BsmtFinType2  6
        Heating       6
        HeatingQC     5
        CentralAir    2
        Electrical    5
        KitchenQual   4
        Functional    7
        FireplaceQu   5
        GarageType    6
        GarageFinish  3
        GarageQual    5
        GarageCond    5
        PavedDrive    3
        PoolQC        3
        Fence         4
        MiscFeature   4
        SaleType      9
        SaleCondition 6
dtype: int64

```

En base a los datos recopilados en el analisis, y gracias tambien al archivo 'data_description.txt' que venia junto a los datos, podemos identificar las variables clave en nuestro dataset.

```

In [10]: #Variables clave
key_var = [
    'MSSubClass',
    'MSZoning',
    'LotArea',
    'Street',

```

```
'Alley',  
'LandContour',  
'Utilities',  
'LotConfig',  
'Neighborhood',  
'Condition1',  
'Condition2',  
'HouseStyle',  
'OverallQual',  
'OverallCond',  
'Exterior1st',  
'Exterior2nd',  
'ExterQual',  
'ExterCond',  
'BsmtQual',  
'BstmCond',  
'TotalBsmtSF',  
'Heating',  
'CentralAir',  
'GrLivArea',  
'FullBath',  
'Bedroom',  
'Kitchen',  
'TotRmsAbvGrd',  
'Functional',  
'Fireplaces',  
'GarageType',  
'GarageArea',  
'GarageQual',  
'PoolArea',  
'MiscFeature'  
]
```


```
In [11]: key_var.__len__()
```

```
Out[11]: 35
```

Estas seran las variables sobre las cuales realizaremos un analisis mas a fondo y buscaremos relaciones para realizar predicciones de los precios de las casas. Estas variables fueron seleccionadas debido a la relevancia que tienen sobre estos precios, por lo que se espera que sean utiles en los pasos siguientes.

Ademas de el analisis de las variables, es importante analizar el comportamiento de la variable objetivo de nuestra investigacion: SalePrice

```
In [12]: plt.figure(figsize=(8, 5))  
sns.histplot(houses['SalePrice'], bins=30, kde=True)  
plt.title("Distribución del Precio de las Casas")  
plt.xlabel("Precio de Venta (USD)")  
plt.ylabel("Frecuencia")  
plt.show()
```



Gracias a la grafica podemos observar que la distribucion de del precio es una distribucion normal con sesgo positivo, es decir, hacia la derecha. En base a esto podemos asumir que hay muchas casas con precios relativamente bajos, pero tambien hay casas con precios muy altos que elevan la media de los precios.

Hay que tomar en cuenta este comportamiento, ya que puede afectar en algunos modelos de regresion.

Proyecto 2 - Entrega 2

Modelos de regresion lineal

Nelson Escalante - 22046

SETUP

```
In [55]: import pandas as pd
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
import seaborn as sns

#Variables clave
key_var = [
    'MSSubClass',
    'MSZoning',
    'LotArea',
    'Street',
    'Alley',
    'LandContour',
    'Utilities',
    'LotConfig',
    'Neighborhood',
    'Condition1',
    'Condition2',
    'HouseStyle',
    'OverallQual',
    'OverallCond',
    'Exterior1st',
    'Exterior2nd',
    'ExterQual',
    'ExterCond',
    'BsmtQual',
    'BsmtCond',
    'TotalBsmtSF',
    'Heating',
    'CentralAir',
    'GrLivArea',
    'FullBath',
    'BedroomAbvGr',
    'KitchenAbvGr',
    'TotRmsAbvGrd',
    'Functional',
    'Fireplaces',
    'GarageType',
    'GarageArea',
    'GarageQual',
    'PoolArea',
    'MiscFeature'
```

```

]

train_path = "data/train.csv"
train = pd.read_csv(train_path)

numeric = train.select_dtypes(include=["number"]).columns
categ = train.select_dtypes(include=["object"]).columns

train[numeric] = train[numeric].fillna(train[numeric].median())

for col in categ:
    train[col] = train[col].fillna(train[col].mode()[0])

```

In [56]: `train.isnull().sum().sum()`

Out[56]: `np.int64(0)`

In [57]: *#Separar variables de prediccion y la variable objetivo*
`x = train[key_var]`
`y = train["SalePrice"]`

#Realizar el entrenamiento
`x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, ran`


In [58]: *#Filas en el conjunto de entrenamiento*
`x_train.shape[0]`

Out[58]: `1168`

In [59]: *#Filas en el conjunto de prueba*
`x_test.shape[0]`

Out[59]: `292`

In [60]: *#Verificar distribucion*
`plt.figure(figsize=(10, 5))`
`sns.histplot(y_train, bins=30, kde=True, color="blue", label="Entrenamiento"`
`sns.histplot(y_test, bins=30, kde=True, color="red", label="Prueba", alpha=0.5)`
`plt.legend()`
`plt.title("Distribución de Precios en los Conjuntos de Entrenamiento y Prueba")`
`plt.show()`




```
In [64]: train = pd.get_dummies(train, drop_first=True) # Convierte texto en números

corr_matrix = train.corr()

# Seleccionar solo las 15 variables más correlacionadas con SalePrice
top_corr_features = corr_matrix.nlargest(15, "SalePrice")["SalePrice"].index
corr_top = train[top_corr_features].corr()

# Graficar la correlación de estas variables
plt.figure(figsize=(10, 6))
sns.heatmap(corr_top, annot=True, cmap="coolwarm", fmt=".2f", linewidths=0.5)
plt.title("Matriz de Correlación: Variables Más Relacionadas con SalePrice")
plt.show()
```



In []:

Las variables que se correlacionan mejor con 'SalePrice' son las siguientes:

- OverallQual
- GrLivArea
- GarageCars
- GarageArea
- TotalBsmtSF
- 1stFlrSF
- FullBath

Estas variables son nuestros mejores indicadores sobre los precios de las casas, y nos pueden servir para realizar el modelo de regresion lineal y predecir dichos precios.

Si lo analizamos, estas variables tienen sentido. Las personas que tengan mas carros pueden pagar mas por sus casas, por lo que el Garage nos sirve como buen indicador de precio. El tamaño en general de la casa, indicado por 'TotalBsmtSF' y '1stFlrSF', también nos sirve para saber los precios estimados de las casas.

Avances Proyecto 2

Andre Jo

2025-02-27

Leer datos del csv y juntar con sales para incluir las variables.


```
data <- read.csv("test.csv")  
datasample <- read.csv("sample_submission.csv")  
data_analysis <- merge(data, datasample, by="Id")
```

```
suppressWarnings(hopkins(data_hop))
```

```
## [1] 1
```

El valor del estadístico de hopkins está alejado de 0.5 por lo que los datos no son aleatorios hay altas posibilidades de que sea factible el agrupamiento. Además vemos que alcanza a 1 lo cual significa que si hay tendencia fuerte de agrupamientos


```
datos_dist<- dist(data_hop)  
fviz_dist(datos_dist, show_labels = F)
```



Como se puede observar en la VAT, sí existen ciertos patrones que el estadístico de hopkins da.

```
wss=0
for (i in 1:10)
  wss[i] <- sum(kmeans(na.omit(data_analysis), centers=i)$withinss)


plot(1:10, wss, type="b", xlab="Number of Clusters", ylab="Within groups sum of squares")
```



En

este caso podemos observar que el numero de clusters a elegir es 3 como se observa en la gráfica ya que esta empezando a reducir su descenso a llegar a uno estable.


```
fviz_nbclust(na.omit(data_analysis), kmeans, method = "wss") +
  labs(subtitle = "Elbow method")
```



Nuevamente para confirmar que si es el numero de clusters, si se observa que actua como la grafica anterior donde el cluster k 3 no tiene un mayor desenso.

```
km<-kmeans(na.omit(data_analysis),3,iter.max =100)
data_analysis<- na.omit(data_analysis)
data_analysis$grupo<-km$cluster
```

```
fviz_cluster(km, data = na.omit(data_hop) ,geom = "point", ellipse.type = "norm")
```



observa que el segundo cluster se traslapa del cluster tercer y primer donde se ve que hay un segmento que si se juntan. Lo cual puede significar que las variables no son tan distintas. Cabe recalcar que el cluster 2 y 3 pueden ser distintas pero son pocas las diferencias.

```
km$size
```

```
## [1] 644 347 155
```

Se observa que el primer cluster tiene 653 puntos, segundo cluster tiene 144 puntos y el tercero cluster tiene 349 puntos. Esto puede significar que el primer cluster al tener mayor cantidad de datos puede que esten distribuidos de manera uniforme entre los clusters.


```
km$withinss
```

```
## [1] 23622998411 20744978676 34634214706
```

Se observa que hay mayor cantidad en el cluster 2 pero como vemos en la grafica con anterioridad el numero de clusters se debe reducir a 2.

```
km<-kmeans(na.omit(data_analysis),2,iter.max =100)
data_analysis<- na.omit(data_analysis)
data_analysis$grupo<-km$cluster
```

```
fviz_cluster(km, data = na.omit(data_hop) ,geom = "point", ellipse.type = "norm")
```



observa que el segundo cluster se traslapa del primer cluster donde se ve que hay un segmento que si se juntan. Lo cual puede significar que las variables no son tan distintas como habia mencionado anteriormente.

```
km$size
```

```
## [1] 629 517
```

Se observa que el primer cluster tiene 526 puntos, segundo cluster tiene 620 puntos lo cual no se alejan de uno al otro a diferencia de los 3 clusters elegidos.

```
km$withinss
```

```
## [1] 99774526450 43634356963
```


Aunque podemos observar que withinss tiene mas diferencia puede ser comparado el segundo cluster como el doble del cluster 1. Se puede inferir que los puntos del cluster dos estan más ceparados a comparación del cluster 1.

```
m<-data.frame(withinss=km$withinss, size=km$size)
ggplot(m, aes(size,withinss))+
  geom_point()+
  geom_smooth(method="lm")+
  labs(x="cardinalidad (size)",y="magnitud (whithinss)")+
  geom_text_repel(label=rownames(m))
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

```
## Warning in qt((1 - level)/2, df): Se han producido NaNs
```


```
## Warning in max(ids, na.rm = TRUE): ningun argumento finito para max; retornando
## -Inf
```



puede inferir de los 2 grupos, no se alejan demasiado de la línea recta por lo que podríamos decir que no existen grupos anómalos.


```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo<-as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(1:5, 38)],
  aes(col = factor(grupo)),
  progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```




```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo<-as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(7:12, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```




```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo<-as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(13:18, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```




```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo <- as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(19:24, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```



```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo <- as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(25:30, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```




```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo <- as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(31:34, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```




```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo <- as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(35:37, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

```
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
## `stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```



```
data_analysis <- as.data.frame(data_analysis)
data_analysis <- na.omit(data_analysis)
data_analysis$grupo<-as.factor(data_analysis$grupo)
ggpairs(data_analysis[, c(1:37, 38)],
aes(col = factor(grupo)),
progress = FALSE)
```

En la gráfica en general de las 38 variables no se puede observar alguna significancia, aunque podemos observar que las variable de 31 a 34 sus correlancias son muy bajas a comparación de las otras gráficas.

```
library(flexclust)
```

```
## Cargando paquete requerido: grid
```

```
## Cargando paquete requerido: lattice
```

```
## Cargando paquete requerido: modeltools
```

```
## Cargando paquete requerido: stats4
```

```
##
## Adjuntando el paquete: 'flexclust'
```

```
## The following object is masked from 'package:e1071':
##
##      bclust
```

```
set.seed(123)
res<-kcca(na.omit(data_hop),2)
```


```
## Found more than one class "kcca" in cache; using the first, from namespace 'kernlab'
```

```
## Also defined by 'flexclust'
```

```
## Found more than one class "kcca" in cache; using the first, from namespace 'kernlab'
```

```
## Also defined by 'flexclust'
```


```
importance <- FeatureImpCluster(res, as.data.table(na.omit(data_hop)))
plot(importance)
```




variables con tasas de error más bajas (0.00) son más importantes para el modelo, ya que contribuyen menos a las predicciones incorrectas. En este caso, variables como “YearBuilt”, “GarageYrBlt”, “OverallQual”, “TotalBsmtSF” y “GrLivArea” parecen tener un buen desempeño. Las variables con tasas de error más altas ($x \geq 0.00$) son menos importantes, ya que contribuyen más a las predicciones incorrectas. Variables como “PoolArea”, “MiscVal”, “X3SsnPorch” y “KitchenAbvGr” parecen tener un desempeño pobre.

```
barplot(res, bycluster=T, cex.names = 0.2)
```

Cluster 1: 522 points (46%)




Cluster 2: 624 points (54%)



Como se puede observar en los dos clusters. Al comparar podemos observar que cada uno de ellos es lo contrario. Ahora inferimos que para "SalePrice" es significativamente más alta en el Cluster 2 que en el Cluster 1, esto sugiere que las viviendas en el Cluster 2 tienden a tener precios de venta más altos que las viviendas en el Cluster 1. Si la barra para "LotArea" es más alta en el Cluster 1 que en el Cluster 2, esto sugiere que las viviendas en el Cluster 1 tienden a tener lotes más grandes que las viviendas en el Cluster 2.

```
fviz_cluster(km,
data_analysis,
labelsize = 6,
choose.vars = c("SalePrice","LotArea"),
main="k=2 grupos")
```



tanto se realiza una comparacion ante las dos variables de salePrice y Lot Area donde se tiende a agrupar propiedades con precios de venta bajos y áreas de lote más pequeñas. Mientras que el otro cluster tiende a agrupar propiedades con precios de venta más altos y áreas de lote más grandes.


```
silkkm<-silhouette(km$cluster,dist(data_analysis))
mean(silkkm[,2]) #0.45, no es la mejor partici3n pero no est3 mal
```

```
## [1] 1.548866
```

```
matriz_dist<- dist(data_analysis)
```

```
hc<-hclust(datos_dist, method = "ward.D2") #Genera el clustering jer3rquico de los datos
plot(hc, cex=0.5, axes=FALSE) #Genera el dendrograma
rect.hclust(hc,k=2)
```

Cluster Dendrogram



```
datos_dist  
hclust (*, "ward.D2")
```

```
fviz_dend(hc,k=2, cex = .2, horiz = T)
```

```
```\r  
fviz_dend(hc, k=2, color_labels_by_k = T, cex = .4 ,type = "phylogenetic", repel = T)
```

400

200

0

-200

-200

0

200

A

partir de los dos clusters elegidos, se puede examinar las características de los puntos de datos dentro de cada uno para entender sus similitudes y diferencias.

# Avances Pr2\_Ad2

Andre Jo 22199, Nelson Escalante 22046

2025-03-07

```
library(GGally)
library(nortest)
library(dplyr)
library(tidyverse)
library(rpart)
library(rpart.plot)
library(caret)
library(discretization)
library(randomForest)
```

```
datos <- read.csv("test.csv")
mergeprice <- read.csv("sample_submission.csv")
train <- read.csv("train.csv")

datos <- merge(datos, mergeprice)

mergeprice <- datos$SalePrice
datos$SalePrice <- NULL
```

## 1. Conjuntos de Entrenamiento y Prueba


```
#Variables Numericos
#datos[, c("MSSubClass", "LotArea", "OverallQual", "OverallCond",
"YearBuilt", "YearRemodAdd", "BsmFinSF1", "BsmFinSF2",
"BsmUnfSF", "X1stFlrSF", "X2ndFlrSF", "LowQualFinSF",
"BsmFullBath", "BsmHalfBath", "FullBath", "HalfBath",
"BedroomAbvGr", "KitchenAbvGr", "TotRmsAbvGrd", "Fireplaces",
"GarageCars", "GarageArea", "WoodDeckSF", "OpenPorchSF", "EnclosedPorch",
"X3SsnPorch", "ScreenPorch", "PoolArea", "MiscVal", "MoSold", "YrSold",
"SalePrice")]

datos[] <- lapply(datos, function(x) {
 if (is.numeric(x)) {
 # For numeric columns, replace NAs with the median
 x[is.na(x)] <- median(x, na.rm = TRUE)
 } else if (is.factor(x) | is.character(x)) {
 # For factor or character columns, replace NAs with the mode (most frequent value)
 mode_value <- names(sort(table(x), decreasing = TRUE))[1]
 x[is.na(x)] <- mode_value
 }
 return(x)
})

train[] <- lapply(train, function(x) {
 if (is.numeric(x)) {
 # For numeric columns, replace NAs with the median
 x[is.na(x)] <- median(x, na.rm = TRUE)
 } else if (is.factor(x) | is.character(x)) {
 # For factor or character columns, replace NAs with the mode (most frequent value)
 mode_value <- names(sort(table(x), decreasing = TRUE))[1]
 x[is.na(x)] <- mode_value
 }
 return(x)
})
```

Leemos el conjunto de datos de las casas a observar. También se puede observar que las variables categóricas tienen valores nulos (NA) por lo cual las reemplazamos por valores que son más frecuentes usando la moda. Por otro lado los numéricos que tienen nulos se les aplica la media. Todo esto es aplicado por el conjunto de datos de entrenamiento y de prueba.

2. Elabore un árbol de regresión para predecir el precio de las casas usando todas las variables.



3. Úselo para predecir y analice el resultado. ¿Qué tal lo hizo?

```
predModelo1 <- predict(modelo1, newdata = datos)
rmseModelo1test<-RMSE(predModelo1,mergeprice)
mseModelo1test<-mean((predModelo1 - mergeprice)^2)
predModelo1Train <- predict(modelo1, newdata = train)
rmseModelo1train<-RMSE(predModelo1Train,train$SalePrice)
mseModelo1train<-mean((predModelo1Train - train$SalePrice)^2)

mseModelo1test
```


```
[1] 5953836826
```

```
mseModelo1train
```

```
[1] 1479488059
```

En cuanto al error medio cuadrado es 5953836826 en el modelo de prueba y 1479488059 en el modelo de entrenamiento. Además, se observa que el rmse del modelo de prueba es de 38464.11 y el rmse del modelo de entrenamiento es de 77161.11 lo cual sus valores son muy altos lo cual puede indicar un overfitting de los datos.

```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```



efectivamente se puede respaldar el overfitting en los datos, como se observa con los puntos rojos, se observa líneas de puntos mientras que en los puntos azules se van espaciando no como la línea de puntos rojos.


```
controlcv <- trainControl(method = "cv", number = 10)
profundidades <- data.frame(c(1,4,6,8,10,12,14))
names(profundidades)<- "maxdepth"
system.time(
modelo3<-train(SalePrice~,
 data=train,
 method="rpart2",
 tuneGrid = profundidades,
 trControl = controlcv,
 metric = "RMSE",
 na.action = na.pass
)
)
```

```
user system elapsed
3.02 0.10 3.14
```

```
modelo3
```

```
CART
##
1460 samples
80 predictor
##
No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 1314, 1315, 1312, 1315, 1313, 1314, ...
Resampling results across tuning parameters:
##
maxdepth RMSE Rsquared MAE
1 58500.34 0.4608829 43338.79
4 45974.19 0.6661461 32349.58
6 45747.32 0.6684158 31844.94
8 43905.53 0.6966329 30160.87
10 43923.27 0.6954464 29823.57
12 43900.90 0.6962509 29804.11
14 43900.90 0.6962509 29804.11
##
RMSE was used to select the optimal model using the smallest value.
The final value used for the model was maxdepth = 12.
```

```
plot(modelo3)
```




Si tuneamos la profundidad podemos

ver una profundidad máxima de 10. En este caso solo probaremos profundidades menores al árbol anterior.

4. Haga, al menos, 3 modelos más, cambiando el parámetro de la profundidad del árbol. ¿Cuál es el mejor modelo para predecir el precio de las casas?

## Modelo con una profundidad a 2



```

predModelo2 <- predict(modelo2, newdata = datos)
rmseModelo2test<-RMSE(predModelo2,mergeprice)
mseModelo2test<-mean((predModelo2 - mergeprice)^2)
predModelo2Train <- predict(modelo2, newdata = train)
rmseModelo2train<-RMSE(predModelo2Train,train$SalePrice)
mseModelo2train<-mean((predModelo2Train - train$SalePrice)^2)

```


```
mseModelo2test
```

```
[1] 4638949211
```

```
mseModelo2train
```

```
[1] 2284545955
```


```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo2, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```



Se observa que hay overfitting en el

conjunto de datos pero esta vez, la segunda linea si puede predecir ciertos conjuntos de datos mientras que la primera y segunda linea son muy pocos que puede predecir.

## Modelo con una profundidad 1



```
predModelo3 <- predict(modelo3, newdata = datos)
rmseModelo3test<-RMSE(predModelo3,mergeprice)
mseModelo3test<-mean((predModelo3 - mergeprice)^2)
predModelo3Train <- predict(modelo3, newdata = train)
rmseModelo3train<-RMSE(predModelo3Train,train$SalePrice)
mseModelo3train<-mean((predModelo3Train - train$SalePrice)^2)


mseModelo3test
```

```
[1] 3278688769
```

```
mseModelo3train
```

```
[1] 3441133619
```


```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo3, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```



Al igual que la gráfica anterior hay

overfitting de datos.

## Modelo con una profundidad 3



```
predModelo4 <- predict(modelo4, newdata = datos)
rmseModelo4test<-RMSE(predModelo4,mergeprice)
mseModelo4test<-mean((predModelo4 - mergeprice)^2)
predModelo4Train <- predict(modelo4, newdata = train)
rmseModelo4train<-RMSE(predModelo4Train,train$SalePrice)
mseModelo4train<-mean((predModelo4Train - train$SalePrice)^2)


mseModelo4test
```

```
[1] 4838046177
```

```
mseModelo4train
```

```
[1] 1702662865
```

```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo4, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```



5. Compare los resultados con el modelo de regresión lineal de la hoja anterior, ¿cuál lo hizo mejor?

```
CompModelos<-c(rmseModelo2test,rmseModelo3test,rmseModelo4test, rmseModelo1test)
names(CompModelos)<-c("Modelo1","Modelo2","Modelo3", "Modelo Anterior (1)")
CompModelos
```

##	Modelo1	Modelo2	Modelo3	Modelo Anterior (1)
##	68109.83	57259.84	69556.06	77161.11

La gráfica que tiene una profundidad de 3 puede predecir mejor el precio de las casas debido a que en la última profundidad de la primera gráfica es solo utilizada para clasificar identificadores lo cual no nos provee una información valiosa lo cual podemos quitar. Aunque vemos que todos los modelos tienen overfitting si se puede predecir que modelo puede predecir el precio de las cosas comparando con el rmse. A comparación con la profundidad 4 observamos que hay los dos tienen overfitting de datos pero se observa que el modelo anterior tiene un rmse mejor a comparación con el modelo 3 para poder predecir el precio de las casas.

A continuación se presenta los problemas, 6,7,8 y 9 en el siguiente link

[https://github.com/EscasanN/Data\\_mining\\_P2/blob/master/Avances2.2/arbo](https://github.com/EscasanN/Data_mining_P2/blob/master/Avances2.2/arbo)  
[https://github.com/EscasanN/Data\\_mining\\_P2/blob/master/Avances2.2/arbo](https://github.com/EscasanN/Data_mining_P2/blob/master/Avances2.2/arbo)

10. Entrene un modelo usando validación cruzada, prediga con él. ¿le fue mejor que al modelo anterior?

```
Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.
```

# Arbol de Clasifiacion

Nelson Escalante - 22046

Este archivo incluye los incisos del 6 al 8 de la seccion de actividades.

## SETUP

```
In [6]: import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd


train_path = "../data/train.csv"
train = pd.read_csv(train_path)
```

## INCISO 6:

Creacion de la variable respuesta para clasificacion de casas.

Lo principal es observar nuevamente la distribucion de los precios de las casas para entender los datos de buena manera y crear una division apropiada.

```
In [8]: plt.figure(figsize=(10, 6))
sns.histplot(train["SalePrice"], bins=30, kde=True)
plt.title("Distribución de los Precios de las Casas")
plt.xlabel("Precio de Venta (USD)")
plt.ylabel("Frecuencia")
plt.show()
```



Podemos observar que la distribucion de las casas es una distribucion normal con sesgo positivo, lo que nos indica que hay pocas casas que tienen precios muy altos en relacion a las demas.

Para la creacion de nuestra nueva variable tenemos que tener en cuenta esta cualidad de los datos.

Utilizaremos percentiles para crear una division equitativa de los datos en base a los precios y su relacion entre si.

```
In [9]: p33 = train["SalePrice"].quantile(0.33)
p66 = train["SalePrice"].quantile(0.66)

print(f"Límite Económicas: Menos de ${p33:,.0f}")
print(f"Límite Intermedias: Entre ${p33:,.0f} y ${p66:,.0f}")
print(f"Límite Caras: Más de ${p66:,.0f}")
```

Límite Económicas: Menos de \$139,000  
Límite Intermedias: Entre \$139,000 y \$189,893  
Límite Caras: Más de \$189,893

Con esta nueva division, nuestros datos se distribuyen entre los tres limites de manera equitativa. Vamos a crear la nueva variable con la informacion anterior.

```
In [10]: def categorize_price(price):
 if price <= p33:
 return "Económica"
 elif price <= p66:
 return "Intermedia"
 else:
 return "Cara"

Aplicar la función a la columna SalePrice
train["PriceCategory"] = train["SalePrice"].apply(categorize_price)

Verificar distribución de clases
train["PriceCategory"].value_counts()
```

```
Out[10]: PriceCategory
Cara 497
Económica 483
Intermedia 480
Name: count, dtype: int64
```

Esta nueva variable servira para la creacion del arbol de clasificacion a base de los precios de las casas.

```
In [12]: from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier

Seleccionar las variables predictoras (excluyendo SalePrice)
X = train.drop(columns=["SalePrice", "PriceCategory"])
y = train["PriceCategory"] # Variable objetivo

Convertir variables categóricas en numéricas
X = pd.get_dummies(X, drop_first=True)

Dividir en entrenamiento y prueba (80% - 20%)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Conjunto de entrenamiento: {X_train.shape}")
print(f"Conjunto de prueba: {X_test.shape}")

Crear el modelo de árbol de clasificación
clf = DecisionTreeClassifier(max_depth=5, random_state=42) # Limitamos la profundidad a 5 niveles
clf.fit(X_train, y_train) # Entrenar el modelo


Predicciones en el conjunto de prueba
y_pred = clf.predict(X_test)

Conjunto de entrenamiento: (1168, 245)
Conjunto de prueba: (292, 245)
```

Es importante visualizar nuestro modelo de manera grafica para evaluarlo.

```
In [18]: import matplotlib.pyplot as plt
from sklearn.tree import plot_tree

plt.figure(figsize=(30, 20))
plot_tree(clf, feature_names=X.columns, class_names=clf.classes_, filled=True, rounded=True, fontsize=12)
plt.title("Árbol de Clasificación para Categoría de Precio")
plt.show()
```




Ahora que tenemos nuestro modelo de clasificación, podemos evaluarlo para verificar que tan bien funciona.

```
In [19]: from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

Crear la matriz de confusión
cm = confusion_matrix(y_test, y_pred, labels=clf.classes_)

Graficar la matriz de confusión
plt.figure(figsize=(8, 6))
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=clf.classes_)
disp.plot(cmap="Blues", values_format="d")
plt.title("Matriz de Confusión - Árbol de Clasificación")
plt.show()
```


<Figure size 800x600 with 0 Axes>



El modelo ha clasificado bastante bien los datos, por lo que podemos decir que funciona bastante bien para la predicción de los precios.

```
[1] 1702662865
```

```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo4, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```



5. Compare los resultados con el modelo de regresión lineal de la hoja anterior, ¿cuál lo hizo mejor?

```
CompModelos<-c(rmseModelo2test,rmseModelo3test,rmseModelo4test, rmseModelo1test)
names(CompModelos)<-c("Modelo1","Modelo2","Modelo3", "Modelo Anterior (1)")
CompModelos
```

##	Modelo1	Modelo2	Modelo3	Modelo Anterior (1)
##	68109.83	57259.84	69556.06	77161.11


La gráfica que tiene una profundidad de 3 puede predecir mejor el precio de las casas debido a que en la última profundidad de la primera gráfica es solo utilizada para clasificar identificadores lo cual no nos provee una información valiosa lo cual podemos quitar. Aunque vemos que todos los modelos tienen overfitting si se puede predecir que modelo puede predecir el precio de las cosas comparando con el rmse. A comparación con la profundidad 4 observamos que hay los dos tienen overfitting de datos pero se observa que el modelo anterior tiene un rmse mejor a comparación con el modelo 3 para poder predecir el precio de las casas.

A continuación se presenta los problemas, 6,7,8 y 9 en el siguiente link

[https://github.com/EscasanN/Data\\_mining\\_P2/blob/master/Avances2.2/arbo](https://github.com/EscasanN/Data_mining_P2/blob/master/Avances2.2/arbo)  
[https://github.com/EscasanN/Data\\_mining\\_P2/blob/master/Avances2.2/arbo](https://github.com/EscasanN/Data_mining_P2/blob/master/Avances2.2/arbo)

10. Entrene un modelo usando validación cruzada, prediga con él. ¿le fue mejor que al modelo anterior?

```
Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.
```



```

predModelo5 <- predict(modelo5, newdata = datos)
rmseModelo5test<-RMSE(predModelo5,mergeprice)
mseModelo5test<-mean((predModelo5 - mergeprice)^2)

predModelo5Train <- predict(modelo5, newdata = train)
rmseModelo5train<-RMSE(predModelo5Train,train$SalePrice)
mseModelo5train<-mean((predModelo5Train - train$SalePrice)^2)

```

```
mseModelo5test
```

```
[1] 3998029436
```

```
mseModelo5train
```


```
[1] 2707256389
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo5, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

### Predicciones vs valores originales



No Dio una mejora con la gráfica

anterior. En base a los datos mostrados, se observa que el modelo no cruzado y cruzado tienen overfitting los datos lo cual solo podemos comparar con el rmse en la cual el modelo no cruzado tiene mayor rmse.


```
CompModelos<-c(rmseModelo1test, rmseModelo4test ,rmseModelo5test)
names(CompModelos)<-c("Modelo no Cruzado", "Modelo no Cruzado con profundidad 3","Modelo Cruzado")
CompModelos
```

```
Modelo no Cruzado Modelo no Cruzado con profundidad 3
77161.11 69556.06
Modelo Cruzado
63229.97
```

```
profundidades <- data.frame(c(1,4,6,8,10,12,13))
names(profundidades)<- "maxdepth"
system.time(
modelo6<-train(SalePrice~.,
 data=train,
 method="rpart2",
 #tuneLength = 10,
 tuneGrid = profundidades,
 trControl = controlcv,
 metric = "RMSE",
 na.action = na.pass
)
)
```

```
user system elapsed
1.97 0.14 2.11
```

```
plot(modelo6)
```



La gráfica de profundidades muestra

que desde la profundidad 4 escala hasta llegar a la profundidad 6 lo cual hay un gran cambio y conforme llegamos a fondo, puede tener una profundidad de 10 donde ya que no se mejora.

```
profundidades <- expand.grid(maxdepth = 2:14)


system.time (modelo6.1<-train(SalePrice~.,
 data=train,
 method="rpart2",
 tuneLength = 10,
 tuneGrid = profundidades,
 trControl = controlcv,
 metric = "RMSE",
 na.action = na.pass
)
)
```

```
user system elapsed
2.96 0.09 3.15
```


```
modelo6.1
```

```
CART
##
1460 samples
80 predictor
##
No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 1313, 1315, 1316, 1314, 1313, 1314, ...
Resampling results across tuning parameters:
##
maxdepth RMSE Rsquared MAE
2 51927.89 0.5745846 36283.65
3 48577.77 0.6268160 34692.13
4 45955.55 0.6670994 32363.96
5 46338.05 0.6598245 32441.21
6 45763.18 0.6693950 31726.03
7 44736.69 0.6826315 31248.66
8 44051.98 0.6926130 30069.31
9 44225.54 0.6917890 30070.47
10 44109.39 0.6938788 30046.71
11 44094.21 0.6942243 29933.43
12 44094.21 0.6942243 29933.43
13 44094.21 0.6942243 29933.43
14 44094.21 0.6942243 29933.43
##
RMSE was used to select the optimal model using the smallest value.
The final value used for the model was maxdepth = 8.
```

```
plot(modelo6.1)
```



```
rpart.plot(modelo6.1$finalModel)
```



De acuerdo con el modelo de greedy,

la profundidad es la misma lo cual vamos a utilizar una profundidad de 4 para realizar las los modelos.

```

predModelo6.1 <- predict(modelo6.1, newdata = datos)
rmseModelo6.1test<-RMSE(predModelo6.1,mergeprice)
mseModelo6.1test<-mean((predModelo6.1 - mergeprice)^2)

predModelo6.1Train <- predict(modelo6.1, newdata = train)
rmseModelo6.1train<-RMSE(predModelo6.1Train,train$SalePrice)
mseModelo6.1train<-mean((predModelo6.1Train - train$SalePrice)^2)

```

```
mseModelo6.1test
```

```
[1] 5843740252
```

```
mseModelo6.1train
```


```
[1] 1542464278
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo6.1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

### Predicciones vs valores originales



Se observa que todavia existe

overfitting en la gráfica observada.

```

profundidades <- expand.grid(maxdepth = 2:15)

system.time (modelo7.1<-train(SalePrice~.,
 data=train,
 method="rpart2",
 tuneLength = 10,
 tuneGrid = profundidades,
 trControl = controlcv,
 metric = "RMSE",
 na.action = na.pass
)
)

```

```

user system elapsed
2.84 0.12 2.97

```


```
modelo7.1
```

```


CART
##
1460 samples
80 predictor
##
No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 1313, 1315, 1315, 1314, 1312, 1314, ...
Resampling results across tuning parameters:
##
maxdepth RMSE Rsquared MAE
2 51790.47 0.5799916 36288.11
3 48714.86 0.6305755 34714.28
4 47727.38 0.6503320 32980.37
5 47796.33 0.6519421 32614.72
6 46842.78 0.6652085 31924.90
7 45771.90 0.6829139 31439.35
8 45036.55 0.6944306 30361.97
9 44978.15 0.6972515 30434.04
10 45032.94 0.6963769 30346.85
11 45032.94 0.6963769 30346.85
12 45032.94 0.6963769 30346.85
13 45032.94 0.6963769 30346.85
14 45032.94 0.6963769 30346.85
15 45032.94 0.6963769 30346.85
##
RMSE was used to select the optimal model using the smallest value.
The final value used for the model was maxdepth = 9.

```

```
plot(modelo7.1)
```



```
rpart.plot(modelo7.1$finalModel)
```



```

predModelo7.1 <- predict(modelo7.1, newdata = datos)
rmseModelo7.1test<-RMSE(predModelo7.1,mergeprice)
mseModelo7.1test<-mean((predModelo7.1 - mergeprice)^2)

predModelo7.1Train <- predict(modelo7.1, newdata = train)
rmseModelo7.1train<-RMSE(predModelo7.1Train,train$SalePrice)
mseModelo7.1train<-mean((predModelo7.1Train - train$SalePrice)^2)

```

```
mseModelo7.1test
```

```
[1] 5843740252
```

```
mseModelo7.1train
```


```
[1] 1542464278
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo7.1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

### Predicciones vs valores originales



```

profundidades <- expand.grid(maxdepth = 2:20)

system.time (modelo8<-train(SalePrice~.,
 data=train,
 method="rpart2",
 tuneLength = 10,
 tuneGrid = profundidades,
 trControl = controlcv,
 metric = "RMSE",
 na.action = na.pass
)
)

```

```

user system elapsed
5.00 0.17 5.30

```


```
modelo8
```

```


CART
##
1460 samples
80 predictor
##
No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 1312, 1315, 1313, 1315, 1314, 1315, ...
Resampling results across tuning parameters:
##
maxdepth RMSE Rsquared MAE
2 51680.00 0.5800860 36273.05
3 48114.30 0.6374921 34517.84
4 45672.44 0.6749482 32320.24
5 46999.00 0.6595927 32437.95
6 46267.24 0.6703882 32203.79
7 44912.76 0.6920051 31285.49
8 44371.10 0.7013002 30326.36
9 44120.03 0.7042711 29808.43
10 43921.16 0.7085804 29611.42
11 43921.16 0.7085804 29611.42
12 43921.16 0.7085804 29611.42
13 43921.16 0.7085804 29611.42
14 43921.16 0.7085804 29611.42
15 43921.16 0.7085804 29611.42
16 43921.16 0.7085804 29611.42
17 43921.16 0.7085804 29611.42
18 43921.16 0.7085804 29611.42
19 43921.16 0.7085804 29611.42
20 43921.16 0.7085804 29611.42
##
RMSE was used to select the optimal model using the smallest value.
The final value used for the model was maxdepth = 10.

```

```
plot(modelo8)
```



```
rpart.plot(modelo8$finalModel)
```



```

predModelo8 <- predict(modelo8, newdata = datos)
rmseModelo8test<-RMSE(predModelo8,mergeprice)
mseModelo8test<-mean((predModelo8 - mergeprice)^2)

predModelo8Train <- predict(modelo8, newdata = train)
rmseModelo8train<-RMSE(predModelo8Train,train$SalePrice)
mseModelo8train<-mean((predModelo8Train - train$SalePrice)^2)

```

```
mseModelo8test
```

```
[1] 5843740252
```

```
mseModelo8train
```


```
[1] 1542464278
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo8, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

### Predicciones vs valores originales



```
profundidades <- expand.grid(maxdepth = 2:3)


system.time (modelo9<-train(SalePrice~.,
 data=train,
 method="rpart2",
 tuneLength = 10,
 tuneGrid = profundidades,
 trControl = controlcv,
 metric = "RMSE",
 na.action = na.pass
))
```

```
user system elapsed
1.23 0.01 1.31
```


```
modelo9
```

```
CART
##
1460 samples
80 predictor
##
No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 1313, 1315, 1315, 1314, 1315, 1314, ...
Resampling results across tuning parameters:
##
maxdepth RMSE Rsquared MAE
2 51600.32 0.5795800 36247.96
3 44546.45 0.6944071 30922.63
##
RMSE was used to select the optimal model using the smallest value.
The final value used for the model was maxdepth = 3.
```

```
plot(modelo9)
```



```
rpart.plot(modelo9$finalModel)
```



```

predModelo9 <- predict(modelo9, newdata = datos)
rmseModelo9test<-RMSE(predModelo9,mergeprice)
mseModelo9test<-mean((predModelo9 - mergeprice)^2)

predModelo9Train <- predict(modelo9, newdata = train)
rmseModelo9train<-RMSE(predModelo9Train,train$SalePrice)
mseModelo9train<-mean((predModelo9Train - train$SalePrice)^2)

```

```
mseModelo9test
```

```
[1] 4741037550
```

```
mseModelo9train
```


```
[1] 1706990759
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo9, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

### Predicciones vs valores originales



```
modeloRF1<-randomForest(SalePrice~.,data=train)
prediccionRF1<-predict(modeloRF1,newdata = datos)
rmseModelo10test<-RMSE(prediccionRF1,mergeprice)
mseModelo10test<-mean((prediccionRF1 - mergeprice)^2)

prediccionRF1Train<-predict(modeloRF1,newdata = datos)
rmseModelo10train<-RMSE(prediccionRF1Train,train$SalePrice)
```

```
Warning in pred - obs: longer object length is not a multiple of shorter object
length
```

```
mseModelo10train<-mean((prediccionRF1Train - train$SalePrice)^2)
```

```
Warning in prediccionRF1Train - train$SalePrice: longer object length is not a
multiple of shorter object length
```

```
mseModelo10test
```


```
[1] 4731196302
```

```
mseModelo10train
```

```
[1] 11338402180
```

```
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(prediccionRF1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)
```

### Predicciones vs valores originales



```
CompModelos<-c(rmseModelo6.1test,rmseModelo7.1test,rmseModelo8test,rmseModelo9test,rmseModelo10test)
names(CompModelos)<-c("Tuneado Modelo1","Tuneado Modelo2","Tuneado Modelo3", "Tuneado Modelo4","Modelo Random Forest")
CompModelos
```


##	Tuneado Modelo1	Tuneado Modelo2	Tuneado Modelo3
##	76444.36	76444.36	76444.36
##	Tuneado Modelo4	Modelo Random Forest	
##	68855.19	68783.69	

Con la comparación de los 4 modelos utilizados con tuneo y el modelo de Random Forest podemos observar gráficamente con el modelo de Random Forest que tiene pocas asimilaciones con el modelo pero observamos que los modelo tuneado tienen mayor rmse a comparación del modelo de Random Forest. POr lo tanto inferimos aunque tenga menor rmse que el modelo 1 y 2, observamos que es mejor tener el modelo de Random Forest ya que no tiene overfitting de datos y esta cerca del rango de los modelos de tuneado.

## Avances 2.3

Andre Jo 22199

2025-03-14



Observamos que en la parte inferior se observa un patrón de overfitting pero en la parte de arriba no tanto. Además de eso, el modelo acertó pocas veces con la concentración de datos que existe en el rango de SalesPrice de 150,000 a 200,000.

```
EMA <- (mean(data_analysis$SalePrice-predBayes, na.rm = T)^2)
EMA
```

```
[1] 141211223
```

```
RMSE <- sqrt(mean((data_analysis$SalePrice - predBayes)^2, na.rm = TRUE))
RMSE
```

```
[1] 70237.08
```

A comparación del RMSE del modelo Naive Bayes, observamos que pertenece al rango de los modelos presentados anteriormente. (entrega pasada)

```

modeloRF1<-randomForest(SalePrice~.,data=train)
prediccionRF1<-predict(modeloRF1,newdata = datos)
rmseModelo10test<-RMSE(prediccionRF1,mergeprice)
mseModelo10test<-mean((prediccionRF1 - mergeprice)^2)

prediccionRF1Train<-predict(modeloRF1,newdata = datos)
rmseModelo10train<-RMSE(prediccionRF1Train,train$SalePrice)

Warning in pred - obs: longitud de objeto mayor no es múltiplo de la longitud
de uno menor
mseModelo10train<-mean((prediccionRF1Train - train$SalePrice)^2)


Warning in prediccionRF1Train - train$SalePrice: longitud de objeto mayor no es
múltiplo de la longitud de uno menor
mseModelo10test

[1] 4711955718
rmseModelo10test

[1] 68643.69
plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(prediccionRF1, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

## Predicciones vs valores originales



De las entregas anteriores, se puede observar que la gráfica que más relación tiene es el modelo de Random

Forest ya que no es un modelo que este presente el overfitting de los datos.

#### RMSE DE LOS SIGUIENTES MODELOS

```
CompModelos<-c(76444.36,76444.36,76444.36,68855.19,69164.43)
names(CompModelos)<-c("Tuneado Modelo1","Tuneado Modelo2","Tuneado Modelo3", "Tuneado Modelo4","Modelo Random Forest")
```

CompModelos

##	Tuneado Modelo1	Tuneado Modelo2	Tuneado Modelo3
##	76444.36	76444.36	76444.36
##	Tuneado Modelo4	Modelo Random Forest	
##	68855.19	69164.43	


De acuerdo con la siguiente tabla a comparar y el rmse del modelo de prueba con Naive Bayes, obtenemos un RMSE de 70237.08 lo cual esta cerca ante los modelos de Random Forest y el Modelo 4. Además no observamos que la gráfica no tenga overfitting lo cual se relaciona con el modelo de Random Forest, pero observamos que Naive Bayes no acierta con los puntos que estan concentrados en el rango de 150,000 a 200,000 de la variable salePrice. Esto significa que Random Forest sigue siendo el modelo con más certeza a comparación de los otros modelos.

8.Haga un modelo usando validación cruzada, compare los resultados de este con los del modelo anterior. ¿Cuál funcionó mejor?

```
controlcv <- trainControl(method = "cv",number = 10)
modelo5<- train(SalePrice~.,data=train,
 method="rpart",
 trControl=controlcv,
 na.action=na.pass
)
```

```
Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.
```

```
rpart.plot(modelo5$finalModel)
```



```

predModelo5 <- predict(modelo5, newdata = datos)
rmseModelo5test<-RMSE(predModelo5,mergeprice)
mseModelo5test<-mean((predModelo5 - mergeprice)^2)

predModelo5Train <- predict(modelo5, newdata = train)
rmseModelo5train<-RMSE(predModelo5Train,train$SalePrice)
mseModelo5train<-mean((predModelo5Train - train$SalePrice)^2)

```

```
mseModelo5test
```

```
[1] 3998029436
```

```
[1] 3998029436
```

```
rmseModelo5test
```


```
[1] 63229.97
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo5, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

## Predicciones vs valores originales




La gráfica mostrada con validación cruzada tiene datos sobreajustados a comparación de la gráfica utilizando Naive Bayes no observamos ese patrón. Por otro lado observamos que el RMSE del modelo de validación cruzada es menor a comparación del Naive Bayes. Por lo tanto, se debe tomar en cuenta que el modelo que funciona más en estos casos es el modelo Naive Bayes debido a que no tiene overfitting de datos lo cual no se ajusta demasiado con el modelo.

9. Tanto para los modelos de regresión como de clasificación, pruebe con varios valores de los hiperparámetros, use el mejor modelo del tuneo, ¿Mejoraron los modelos? Explique

```
controlcv <- trainControl(method = "repeatedcv", number = 8, repeats = 3)
modelo5 <- train(SalePrice ~ ., data = train,
 method = "rpart",
 trControl = controlcv,
 na.action = na.pass
)
```

```
Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.
```

```
rpart.plot(modelo5$finalModel)
```



```

predModelo5 <- predict(modelo5, newdata = datos)
rmseModelo5test<-RMSE(predModelo5,mergeprice)
mseModelo5test<-mean((predModelo5 - mergeprice)^2)

predModelo5Train <- predict(modelo5, newdata = train)
rmseModelo5train<-RMSE(predModelo5Train,train$SalePrice)
mseModelo5train<-mean((predModelo5Train - train$SalePrice)^2)

```

```
mseModelo5test
```

```
[1] 3998029436
```

```
[1] 3998029436
```

```
rmseModelo5test
```


```
[1] 63229.97
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo5, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```


## Predicciones vs valores originales



```
controlcv <- trainControl(method = "boot", number = 20)
modelo5 <- train(SalePrice ~ ., data = train,
 method = "rpart",
 trControl = controlcv,
 na.action = na.pass
)
```

```
Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.
```

```
rpart.plot(modelo5$finalModel)
```



```

predModelo5 <- predict(modelo5, newdata = datos)
rmseModelo5test<-RMSE(predModelo5,mergeprice)
mseModelo5test<-mean((predModelo5 - mergeprice)^2)

predModelo5Train <- predict(modelo5, newdata = train)
rmseModelo5train<-RMSE(predModelo5Train,train$SalePrice)
mseModelo5train<-mean((predModelo5Train - train$SalePrice)^2)

```

```
mseModelo5test
```

```
[1] 3998029436
```

```
[1] 3998029436
```

```
rmseModelo5test
```

```
[1] 63229.97
```


```
[1] 63229.97
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo5, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```


## Predicciones vs valores originales



```
Warning in adaptiveWorkflow(x = x, y = y, wts = weights, info = trainInfo, :
There were missing values in resampled performance measures.

Warning in data.frame(..., check.names = FALSE): los nombres de fila se
encontraron a partir de una variable corta y se descartaron
Warning in data.frame(..., check.names = FALSE): los nombres de fila se
encontraron a partir de una variable corta y se descartaron
Warning in data.frame(..., check.names = FALSE): los nombres de fila se
encontraron a partir de una variable corta y se descartaron
Warning in data.frame(..., check.names = FALSE): los nombres de fila se
encontraron a partir de una variable corta y se descartaron

Warning in adaptiveWorkflow(x = x, y = y, wts = weights, info = trainInfo, :
There were missing values in resampled performance measures.
```



```

predModelo5 <- predict(modelo5, newdata = datos)
rmseModelo5test<-RMSE(predModelo5,mergeprice)
mseModelo5test<-mean((predModelo5 - mergeprice)^2)

predModelo5Train <- predict(modelo5, newdata = train)
rmseModelo5train<-RMSE(predModelo5Train,train$SalePrice)
mseModelo5train<-mean((predModelo5Train - train$SalePrice)^2)

```

```
mseModelo5test
```

```
[1] 3998029436
```

```
[1] 3998029436
```

```
rmseModelo5test
```

```
[1] 63229.97
```


```
[1] 63229.97
```

```

plot(mergeprice,col="blue", main="Predicciones vs valores originales")
points(predModelo5, col="red")
legend(30,45,legend=c("original", "prediccion"),col=c("blue", "red"),pch=1, cex=0.8)

```

## Predicciones vs valores originales



Se realizaron diferentes metodos para realizar validación con la finalidad de ver si existen algunas mejoras. Se infiere que no hubo unos cambios encontrados con el RMSE , MSE y además en todas las gráficas se observan el overfitting de los datos.

10. Compare la eficiencia del algoritmo con el resultado obtenido con el árbol de decisión (el de clasificación) y el modelo de random forest que hizo en la hoja pasada. ¿Cuál es mejor para predecir? ¿Cuál se demoró más en procesar?

```
system.time({
 modelo5 <- train(SalePrice ~ .,
 data = train,
 method = "rpart",
 trControl = controlcv,
 na.action = na.pass
)
})

user system elapsed
1.25 0.01 1.30

Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.
user system elapsed
1.80 0.06 1.91

system.time({
 modeloRF1 <- randomForest(SalePrice ~ ., data = train)
})
```

```
user system elapsed
4.78 0.04 5.02
user system elapsed
4.64 0.05 4.86
```

```
system.time({
 modeloNB <- naiveBayes(SalePrice ~ ., data = train)
})
```

```
user system elapsed
0.34 0.01 0.38
user system elapsed
0.34 0.05 0.43
```

En terminos de eficiencia, se puede medir con el tiempo y en base a los tres modelos comparados (random forest, Naive Bayes y Random Forest). Observamos que Naive bayes es el más eficiente debido a que el tiempo más corto entre estos modelos. El más costos es el random forest como se puede observar ante los resultados.

## Avances 2.4

Andre Jo 22199

2025-03-21

```
library(GGally)
library(dplyr)
library(tidyverse)
library(class)
library(ggplot2)
library(caret)
```

Debido a que los datos que observamos, tienen datos faltantes, se realiza un la media y el promedio de los datos para rellenar valores faltantes.

```
head(summary(datos))
```

```
Id MSSubClass MSZoning LotFrontage
Min. :1461 Min. : 20.00 Length:1459 Min. : 21.00
1st Qu.:1826 1st Qu.: 20.00 Class :character 1st Qu.: 60.00
Median :2190 Median : 50.00 Mode :character Median : 67.00
Mean :2190 Mean : 57.38 Mean : 68.33
3rd Qu.:2554 3rd Qu.: 70.00 3rd Qu.: 78.00
Max. :2919 Max. :190.00 Max. :200.00
LotArea Street Alley LotShape
Min. : 1470 Length:1459 Length:1459 Length:1459
1st Qu.: 7391 Class :character Class :character Class :character
Median : 9399 Mode :character Mode :character Mode :character
Mean : 9819
3rd Qu.:11518
Max. :56600
LandContour Utilities LotConfig LandSlope
Length:1459 Length:1459 Length:1459 Length:1459
Class :character Class :character Class :character Class :character
Mode :character Mode :character Mode :character Mode :character
##
##
Neighborhood Condition1 Condition2 BldgType
Length:1459 Length:1459 Length:1459 Length:1459
Class :character Class :character Class :character Class :character
Mode :character Mode :character Mode :character Mode :character
##
##
HouseStyle OverallQual OverallCond YearBuilt
Length:1459 Min. : 1.000 Min. :1.000 Min. :1879
Class :character 1st Qu.: 5.000 1st Qu.:5.000 1st Qu.:1953
```

```

Mode :character Median : 6.000 Median :5.000 Median :1973
Mean : 6.079 Mean :5.554 Mean :1971
3rd Qu.: 7.000 3rd Qu.:6.000 3rd Qu.:2001
Max. :10.000 Max. :9.000 Max. :2010
YearRemodAdd RoofStyle RoofMatl Exterior1st
Min. :1950 Length:1459 Length:1459 Length:1459
1st Qu.:1963 Class :character Class :character Class :character
Median :1992 Mode :character Mode :character Mode :character
Mean :1984
3rd Qu.:2004
Max. :2010
Exterior2nd MasVnrType MasVnrArea ExterQual
Length:1459 Length:1459 Min. : 0.00 Length:1459
Class :character Class :character 1st Qu.: 0.00 Class :character
Mode :character Mode :character Median : 0.00 Mode :character
Mean : 99.67
3rd Qu.: 162.00
Max. :1290.00
ExterCond Foundation BsmtQual BsmtCond
Length:1459 Length:1459 Length:1459 Length:1459
Class :character Class :character Class :character Class :character
Mode :character Mode :character Mode :character Mode :character
##
##
BsmtExposure BsmtFinType1 BsmtFinSF1 BsmtFinType2
Length:1459 Length:1459 Min. : 0.0 Length:1459
Class :character Class :character 1st Qu.: 0.0 Class :character
Mode :character Mode :character Median : 350.5 Mode :character
Mean : 439.1
3rd Qu.: 752.0
Max. :4010.0
BsmtFinSF2 BsmtUnfSF TotalBsmtSF Heating
Min. : 0.00 Min. : 0.0 Min. : 0 Length:1459
1st Qu.: 0.00 1st Qu.: 219.5 1st Qu.: 784 Class :character
Median : 0.00 Median : 460.0 Median : 988 Mode :character
Mean : 52.58 Mean : 554.2 Mean :1046
3rd Qu.: 0.00 3rd Qu.: 797.5 3rd Qu.:1304
Max. :1526.00 Max. :2140.0 Max. :5095
HeatingQC CentralAir Electrical X1stFlrSF
Length:1459 Length:1459 Length:1459 Min. : 407.0
Class :character Class :character Class :character 1st Qu.: 873.5
Mode :character Mode :character Mode :character Median :1079.0
Mean :1156.5
3rd Qu.:1382.5
Max. :5095.0
X2ndFlrSF LowQualFinSF GrLivArea BsmtFullBath
Min. : 0 Min. : 0.000 Min. : 407 Min. :0.0000
1st Qu.: 0 1st Qu.: 0.000 1st Qu.:1118 1st Qu.:0.0000
Median : 0 Median : 0.000 Median :1432 Median :0.0000
Mean : 326 Mean : 3.544 Mean :1486 Mean :0.4339
3rd Qu.: 676 3rd Qu.: 0.000 3rd Qu.:1721 3rd Qu.:1.0000
Max. :1862 Max. :1064.000 Max. :5095 Max. :3.0000
BsmtHalfBath FullBath HalfBath BedroomAbvGr

```

## Min. :0.00000	Min. :0.000	Min. :0.0000	Min. :0.000
## 1st Qu.:0.00000	1st Qu.:1.000	1st Qu.:0.0000	1st Qu.:2.000
## Median :0.00000	Median :2.000	Median :0.0000	Median :3.000
## Mean :0.06511	Mean :1.571	Mean :0.3777	Mean :2.854
## 3rd Qu.:0.00000	3rd Qu.:2.000	3rd Qu.:1.0000	3rd Qu.:3.000
## Max. :2.00000	Max. :4.000	Max. :2.0000	Max. :6.000
## KitchenAbvGr	KitchenQual	TotRmsAbvGrd	Functional
## Min. :0.000	Length:1459	Min. : 3.000	Length:1459
## 1st Qu.:1.000	Class :character	1st Qu.: 5.000	Class :character
## Median :1.000	Mode :character	Median : 6.000	Mode :character
## Mean :1.042		Mean : 6.385	
## 3rd Qu.:1.000		3rd Qu.: 7.000	
## Max. :2.000		Max. :15.000	
## Fireplaces	FireplaceQu	GarageType	GarageYrBlt
## Min. :0.0000	Length:1459	Length:1459	Min. :1895
## 1st Qu.:0.0000	Class :character	Class :character	1st Qu.:1960
## Median :0.0000	Mode :character	Mode :character	Median :1979
## Mean :0.5812			Mean :1978
## 3rd Qu.:1.0000			3rd Qu.:2001
## Max. :4.0000			Max. :2207
## GarageFinish	GarageCars	GarageArea	GarageQual
## Length:1459	Min. :0.000	Min. : 0.0	Length:1459
## Class :character	1st Qu.:1.000	1st Qu.: 318.0	Class :character
## Mode :character	Median :2.000	Median : 480.0	Mode :character
##	Mean :1.766	Mean : 472.8	
##	3rd Qu.:2.000	3rd Qu.: 576.0	
##	Max. :5.000	Max. :1488.0	
## GarageCond	PavedDrive	WoodDeckSF	OpenPorchSF
## Length:1459	Length:1459	Min. : 0.00	Min. : 0.00
## Class :character	Class :character	1st Qu.: 0.00	1st Qu.: 0.00
## Mode :character	Mode :character	Median : 0.00	Median : 28.00
##		Mean : 93.17	Mean : 48.31
##		3rd Qu.: 168.00	3rd Qu.: 72.00
##		Max. :1424.00	Max. :742.00
## EnclosedPorch	X3SsnPorch	ScreenPorch	PoolArea
## Min. : 0.00	Min. : 0.000	Min. : 0.00	Min. : 0.000
## 1st Qu.: 0.00	1st Qu.: 0.000	1st Qu.: 0.00	1st Qu.: 0.000
## Median : 0.00	Median : 0.000	Median : 0.00	Median : 0.000
## Mean : 24.24	Mean : 1.794	Mean : 17.06	Mean : 1.744
## 3rd Qu.: 0.00	3rd Qu.: 0.000	3rd Qu.: 0.00	3rd Qu.: 0.000
## Max. :1012.00	Max. :360.000	Max. :576.00	Max. :800.000
## PoolQC	Fence	MiscFeature	MiscVal
## Length:1459	Length:1459	Length:1459	Min. : 0.00
## Class :character	Class :character	Class :character	1st Qu.: 0.00
## Mode :character	Mode :character	Mode :character	Median : 0.00
##			Mean : 58.17
##			3rd Qu.: 0.00
##			Max. :17000.00
## MoSold	YrSold	SaleType	SaleCondition
## Min. : 1.000	Min. :2006	Length:1459	Length:1459
## 1st Qu.: 4.000	1st Qu.:2007	Class :character	Class :character
## Median : 6.000	Median :2008	Mode :character	Mode :character
## Mean : 6.104	Mean :2008		
## 3rd Qu.: 8.000	3rd Qu.:2009		

```
Max. :12.000 Max. :2010
SalePrice
Min. :135751
1st Qu.:168703
Median :179209
Mean :179184
3rd Qu.:186789
Max. :281644
```

Separamos las variables a numericas.

1. Elabore un modelo de regresión usando K nearest Neighbors (KNN), el conjunto de entrenamiento y la variable respuesta SalesPrice. Prediga con el modelo y explique los resultados a los que llega. Asegúrese que los conjuntos de entrenamiento y prueba sean los mismos de las entregas anteriores para que los modelos sean comparables

```
train<-train[complete.cases(train),]
k_vecinos <- round(sqrt(nrow(datos)),0)
```

```
k_vecinos
```

```
[1] 38
```

En total se observa que k es igual a 38.

```
parametros <- expand.grid(k = k_vecinos)
modelo1 <- train(
 SalePrice~.,
 data=train,
 method = "knn",
 preProcess= c("center","scale","knnImpute"),
 tuneGrid = parametros
)
predModelo1 <- predict(modelo1, newdata=datos)
```

```
rmse <- RMSE(predModelo1, datos$SalePrice)
mse <- rmse^2
```

```
MSE
```

```
mse
```

```
[1] 2737344392
```

```
RMSE
```

```
rmse
```


```
[1] 52319.64
```

Se observa que el RMSE de el modelo de KNN es mejor a comparación de otros modelos como el modelo de Naive Bayes que tiene un RMSE de 70237.08 de acuerdo con la entrega pasada. Ahora con el modelo mejor que fue tuneado, se infiere a base de estos dos numeros (RMSE modelo tuneado 68855.19); se observa que el modelo de KNN es mucho mejor.

```
Crear un dataframe con los valores reales y predichos
df_resultados <- data.frame(
 Índice = 1:length(datos$SalePrice), # Índice de cada observación
 Real = datos$SalePrice,
 Predicho = predModelo1
```

```
)

Graficar ambas series
ggplot(df_resultados) +
 geom_point(aes(x = Índice, y = Real, color = "Real"), size = 2) + # Puntos rojos (valores reales)
 geom_point(aes(x = Índice, y = Predicho, color = "Predicho"), size = 2) + # Puntos azules (predicciones)
 scale_color_manual(values = c("Real" = "red", "Predicho" = "blue")) + # Definir colores
 labs(title = "Comparación: Valores Reales vs. Predicciones",
 x = "Índice de Observación",
 y = "Sale Price",
 color = "Serie") +
 theme_minimal()
```



Se observa en la gráfica que hay algunos puntos que el modelo no pudo predecir aunque no observamos que los datos estén sobreajustados como en los otros modelos vistos anteriormente. Por otro lado en los modelos anteriores se ve que se relaciona con el modelo de random forest.

8. Haga un modelo usando validación cruzada, compare los resultados de este con los del modelo anterior. ¿Cuál funcionó mejor?

```
trctrl1 <- trainControl(method = "repeatedcv",
 number = 10,
 repeats = 3)

modelo2 <- train(
 SalePrice~.,
 data=train,
 method = "knn",
```

```

trControl = trctrl,
preProcess= c("center","scale"),
tuneGrid = parametros
)
predModelo2 <- predict(modelo2, newdata=datos)

```

```
RMSE(predModelo2, datos$SalePrice)
```

```
[1] 52319.64
```

El RMSE es de 52319.64, es el mismo que el modelo de knn utilizado donde k es igual a la raíz cuadrada del número de filas (38).

En el siguiente gráfico se muestran los valores predichos y los reales.


```

df_resultados <- data.frame(
 Índice = 1:length(datos$SalePrice), # Índice de cada observación
 Real = datos$SalePrice,
 Predicho = predModelo2
)

Graficar ambas series
ggplot(df_resultados) +
 geom_point(aes(x = Índice, y = Real, color = "Real"), size = 2) + # Puntos rojos (valores reales)
 geom_point(aes(x = Índice, y = Predicho, color = "Predicho"), size = 2) + # Puntos azules (predicciones)
 scale_color_manual(values = c("Real" = "red", "Predicho" = "blue")) + # Definir colores
 labs(title = "Comparación: Valores Reales vs. Predicciones",
 x = "Índice de Observación",
 y = "City MPG",
 color = "Serie") +
 theme_minimal()

```

## Comparación: Valores Reales vs. Predicciones



Observamos que no tiene sobreajustes de datos y además observamos que con validación cruzada, tiene casi los mismos datos predichos que en la gráfica del modelo anterior. Ahora con la eficiencia del algoritmo se podría observar si es mejor el modelo con o sin validación cruzada.

9. Tanto para los modelos de regresión como de clasificación, pruebe con varios valores de los hiperparámetros ¿Qué parámetros pueden tunearse en un KNN?, use el mejor modelo del tuneo, ¿Mejoraron los resultados usando el mejor modelo ahora? Explique

Se puede realizar el cambio de valor K, necesita tener validación cruzada e incluso preprocesar los datos.


Tuneando varios valores de k

```
parametros <- expand.grid(k = seq(1,25))
modelo3 <- train(
 SalePrice~.,
 data=train,
 method = "knn",
 trControl = trctrl,
 preProcess= c("center","scale"),
 tuneGrid = parametros
)
predModelo3 <- predict(modelo3, newdata=datos)
```

El mejor valor de k

```
ggplot(modelo3$results, aes(x = k, y = RMSE)) +
 geom_line(color = "orange") + # Línea azul
 geom_point(size = 3, color = "darkgreen") + # Puntos rojos
 labs(title = "Precisión vs Número de Vecinos (k)",
```

```
x = "Número de Vecinos (k)",
y = "RMSE") +
theme_minimal() # Tema limpio
```




Se observa que el mejor vecino de acuerdo con la gráfica es 9 u 11.

```
df_resultados <- data.frame(
 Índice = 1:length(datos$SalePrice), # Índice de cada observación
 Real = datos$SalePrice,
 Predicho = predModelo3
)

Graficar ambas series
ggplot(df_resultados) +
 geom_point(aes(x = Índice, y = Real, color = "Real"), size = 2) + # Puntos rojos (valores reales)
 geom_point(aes(x = Índice, y = Predicho, color = "Predicho"), size = 2) + # Puntos azules (predicciones)
 scale_color_manual(values = c("Real" = "red", "Predicho" = "blue")) + # Definir colores
 labs(title = "Comparación: Valores Reales vs. Predicciones",
 x = "Índice de Observación",
 y = "Sale Price",
 color = "Serie") +
 theme_minimal()
```

## Comparación: Valores Reales vs. Predicciones



```
rmse <- RMSE(predModelo3, datos$SalePrice)
rmse
```


```
[1] 60204.08
```

Se observa que el rmse al realizar diferentes configuraciones como realizar validación cruzada, preprocesamiento de datos e incluso cambiando el valor de k observamos que no es mejor a comparación del modelo 1 ( $k = 38$ ). El modelo 1 tiene un rmse de 5319.64 que mucho mejor que este modelo (60844.42).

```
residuos <- datos$SalePrice - predModelo3

Crear un dataframe con los valores reales y residuos
df_resultados <- data.frame(
 Real = datos$SalePrice,
 Residuo = residuos
)

Graficar valores reales vs residuos
ggplot(df_resultados, aes(x = Real, y = Residuo)) +
 geom_point(color = "red", size = 2, alpha = 0.7) + # Puntos rojos
 geom_hline(yintercept = 0, linetype = "dashed", color = "blue") + # Línea en y = 0
 labs(title = "Valores Reales vs Residuos",
 x = "Sale Price Reales",
 y = "Residuo (Error)") +
 theme_minimal()
```



Se observa que la dispersión de los puntos rojos no es uniforme a lo largo del eje X. En la zona de precios de venta más bajos ( 160,000 - 200,000), los residuos tienden a ser más dispersos, mientras que en la zona de precios más altos, la dispersión es menor. Por lo cual se puede inferir que el modelo tiene una varianza de error no constante.

10. Compare la eficiencia del algoritmo con el resultado obtenido con el árbol de decisión (el de clasificación), el modelo de random forest y el de naive bayes que hizo en las entregas pasadas. ¿Cuál es mejor para predecir? ¿Cuál se demoró más en procesar?

Eficiencia del modelo donde se utiliza la raíz cuadrada de filas donde es 38

```
parametros <- expand.grid(k = k_vecinos)
system.time({
 modelo1 <- train(
 SalePrice~.,
 data=train,
 method = "knn",
 preProcess= c("center","scale","knnImpute"),
 tuneGrid = parametros
)
})
```

```
user system elapsed
4.78 0.11 4.95
```

Eficiencia del modelo utilizado con validación cruzada

```
trctrl <- trainControl(method = "repeatedcv",
 number = 10,
```

```

repeats = 3)
system.time({
modelo2 <- train(
 SalePrice~.,
 data=train,
 method = "knn",
 trControl = trctrl,
 preProcess= c("center","scale"),
 tuneGrid = parametros
)
})

```

```

user system elapsed
2.27 0.03 2.35

```

Eficiencia del modelo utilizando diferentes hiperparámetros

```

parametros <- expand.grid(k = seq(1,25))
system.time({
modelo3 <- train(
 SalePrice~.,
 data=train,
 method = "knn",
 trControl = trctrl,
 preProcess= c("center","scale"),
 tuneGrid = parametros
)
})

```

```

user system elapsed
55.21 1.25 57.50

```

Se observa que el modelo con más hiperparámetros puede tardar más a comparación de los dos modelos que estan cerca en terminos de tiempo de ejecución. Por otro lado observamos que los otros algoritmo como random forest y Naive Bayes observamos que el algoritmo más eficiente sigue siendo Naive Bayes. Por lo tanto inferimos que el modelo que es mejor para realizar producciones es utilizar el algoritmo de knn donde k es la raiz cuadrada del numero de filas donde tiene el mejor rmse (60844.42). Ahora en terminos de eficiencia seria mejor utilizar el modelo de Naive Bayes. Pero si se necesita un modelo que es adecuado con el tiempo de ejecución y una buena predicción, utilizaria el algoritmo de Random Forest.

# Avacnes2.5

Andre Jo 22199, Nelson Escalante 22046

2025-04-11

```
datos <-read.csv("test.csv")
```

```
Id SalePrice economico medio caro
1 1461 169277.1 1 0 0
2 1462 187758.4 0 1 0
3 1463 183583.7 1 0 0
4 1464 179317.5 1 0 0
5 1465 150730.1 1 0 0
6 1466 177151.0 1 0 0

Id MSSubClass MSZoning LotFrontage LotArea Street Alley LotShape LandContour
1 1 60 RL 65 8450 Pave <NA> Reg Lvl
2 2 20 RL 80 9600 Pave <NA> Reg Lvl
3 3 60 RL 68 11250 Pave <NA> IR1 Lvl
4 4 70 RL 60 9550 Pave <NA> IR1 Lvl
5 5 60 RL 84 14260 Pave <NA> IR1 Lvl
6 6 50 RL 85 14115 Pave <NA> IR1 Lvl

Utilities LotConfig LandSlope Neighborhood Condition1 Condition2 BldgType
1 AllPub Inside Gtl CollgCr Norm Norm 1Fam
2 AllPub FR2 Gtl Veenker Feedr Norm 1Fam
3 AllPub Inside Gtl CollgCr Norm Norm 1Fam
4 AllPub Corner Gtl Crawfor Norm Norm 1Fam
5 AllPub FR2 Gtl NoRidge Norm Norm 1Fam
6 AllPub Inside Gtl Mitchel Norm Norm 1Fam

HouseStyle OverallQual OverallCond YearBuilt YearRemodAdd RoofStyle RoofMatl
1 2Story 7 5 2003 2003 Gable CompShg
2 1Story 6 8 1976 1976 Gable CompShg
3 2Story 7 5 2001 2002 Gable CompShg
4 2Story 7 5 1915 1970 Gable CompShg
5 2Story 8 5 2000 2000 Gable CompShg
6 1.5Fin 5 5 1993 1995 Gable CompShg

Exterior1st Exterior2nd MasVnrType MasVnrArea ExterQual ExterCond Foundation
1 VinylSd VinylSd BrkFace 196 Gd TA PConc
2 MetalSd MetalSd None 0 TA TA CBlock
3 VinylSd VinylSd BrkFace 162 Gd TA PConc
4 Wd Sdng Wd Shng None 0 TA TA BrkTil
5 VinylSd VinylSd BrkFace 350 Gd TA PConc
6 VinylSd VinylSd None 0 TA TA Wood

BsmtQual BsmtCond BsmtExposure BsmtFinType1 BsmtFinSF1 BsmtFinType2
1 Gd TA No GLQ 706 Unf
2 Gd TA Gd ALQ 978 Unf
3 Gd TA Mn GLQ 486 Unf
4 TA Gd No ALQ 216 Unf
```

## 5	Gd	TA	Av	GLQ	655	Unf	
## 6	Gd	TA	No	GLQ	732	Unf	
##	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	Heating	HeatingQC	CentralAir	Electrical
## 1	0	150	856	GasA	Ex	Y	SBrkr
## 2	0	284	1262	GasA	Ex	Y	SBrkr
## 3	0	434	920	GasA	Ex	Y	SBrkr
## 4	0	540	756	GasA	Gd	Y	SBrkr
## 5	0	490	1145	GasA	Ex	Y	SBrkr
## 6	0	64	796	GasA	Ex	Y	SBrkr
##	X1stFlrSF	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	BsmtHalfBath	FullBath
## 1	856	854	0	1710	1	0	2
## 2	1262	0	0	1262	0	1	2
## 3	920	866	0	1786	1	0	2
## 4	961	756	0	1717	1	0	1
## 5	1145	1053	0	2198	1	0	2
## 6	796	566	0	1362	1	0	1
##	HalfBath	BedroomAbvGr	KitchenAbvGr	KitchenQual	TotRmsAbvGrd	Functional	
## 1	1	3	1	Gd	8	Typ	
## 2	0	3	1	TA	6	Typ	
## 3	1	3	1	Gd	6	Typ	
## 4	0	3	1	Gd	7	Typ	
## 5	1	4	1	Gd	9	Typ	
## 6	1	1	1	TA	5	Typ	
##	Fireplaces	FireplaceQu	GarageType	GarageYrBlt	GarageFinish	GarageCars	
## 1	0	<NA>	Attchd	2003	RFn	2	
## 2	1	TA	Attchd	1976	RFn	2	
## 3	1	TA	Attchd	2001	RFn	2	
## 4	1	Gd	Detchd	1998	Unf	3	
## 5	1	TA	Attchd	2000	RFn	3	
## 6	0	<NA>	Attchd	1993	Unf	2	
##	GarageArea	GarageQual	GarageCond	PavedDrive	WoodDeckSF	OpenPorchSF	
## 1	548	TA	TA	Y	0	61	
## 2	460	TA	TA	Y	298	0	
## 3	608	TA	TA	Y	0	42	
## 4	642	TA	TA	Y	0	35	
## 5	836	TA	TA	Y	192	84	
## 6	480	TA	TA	Y	40	30	
##	EnclosedPorch	X3SsnPorch	ScreenPorch	PoolArea	PoolQC	Fence	MiscFeature
## 1	0	0	0	0	<NA>	<NA>	<NA>
## 2	0	0	0	0	<NA>	<NA>	<NA>
## 3	0	0	0	0	<NA>	<NA>	<NA>
## 4	272	0	0	0	<NA>	<NA>	<NA>
## 5	0	0	0	0	<NA>	<NA>	<NA>
## 6	0	320	0	0	<NA>	MnPrv	Shed
##	MiscVal	MoSold	YrSold	SaleType	SaleCondition	SalePrice	economico medio caro
## 1	0	2	2008	WD	Normal	208500	1 0 0
## 2	0	5	2007	WD	Normal	181500	1 0 0
## 3	0	9	2008	WD	Normal	223500	1 0 0
## 4	0	2	2006	WD	Abnorml	140000	1 0 0
## 5	0	12	2008	WD	Normal	250000	1 0 0
## 6	700	10	2009	WD	Normal	143000	1 0 0

Se observa que utilizamos para la variable objetivo tres categorías, economico, caro y medio donde primero calculamos el valor de la casa máxima y el mínimo valor de la casa donde luego lo restamos el valor máximo

con el mínimo y luego dividirlo entre tres para así diferenciar que casa debería de pertenecer en esas tres variables.

Solo se elimina la variable ID, Exterior2ndCBlock, GrLivArea, TotalBsmtSF porque no es importante en estos analisis y evitar el analisis de más variables.

```
summary(modelo_todas_cv)
```

```
##
Call:
NULL
##
Coefficients: (3 not defined because of singularities)
Estimate Std. Error z value Pr(>|z|)
(Intercept) 2.657e+01 1.654e+07 0 1
MSSubClass 6.661e-15 1.301e+03 0 1
MSZoningFV -1.533e-13 1.889e+05 0 1
MSZoningRH 4.699e-13 1.872e+05 0 1
MSZoningRL 3.488e-13 1.608e+05 0 1
MSZoningRM 4.195e-13 1.505e+05 0 1
LotFrontage -1.545e-14 6.903e+02 0 1
LotArea -1.213e-16 1.749e+00 0 1
StreetPave -3.577e-12 1.904e+05 0 1
AlleyPave 1.715e-12 7.469e+04 0 1
LotShapeIR2 -4.465e-13 6.640e+04 0 1
LotShapeIR3 1.419e-12 1.398e+05 0 1
LotShapeReg -6.592e-13 2.516e+04 0 1
LandContourHLS -2.003e-12 8.051e+04 0 1
LandContourLow 1.793e-12 1.001e+05 0 1
LandContourLvl 2.327e-14 5.794e+04 0 1
UtilitiesNoSeWa 8.389e-12 4.145e+05 0 1
LotConfigCulDSac -1.878e-12 5.206e+04 0 1
LotConfigFR2 -2.475e-13 6.332e+04 0 1
LotConfigFR3 -2.153e-12 1.976e+05 0 1
LotConfigInside -2.748e-13 2.814e+04 0 1
LandSlopeMod 5.262e-13 6.254e+04 0 1
LandSlopeSev 7.730e-12 1.803e+05 0 1
NeighborhoodBlueste 8.778e-13 3.032e+05 0 1
NeighborhoodBrDale -2.786e-15 1.725e+05 0 1
NeighborhoodBrkSide 1.314e-12 1.489e+05 0 1
NeighborhoodClearCr 2.268e-12 1.446e+05 0 1
NeighborhoodCollgCr 2.118e-12 1.141e+05 0 1
NeighborhoodCrawfor 2.427e-12 1.346e+05 0 1
NeighborhoodEdwards 3.516e-12 1.261e+05 0 1
NeighborhoodGilbert 1.773e-12 1.207e+05 0 1
NeighborhoodIDOTRR 5.281e-12 1.688e+05 0 1
NeighborhoodMeadowV 1.164e-12 1.763e+05 0 1
NeighborhoodMitchel 1.662e-12 1.286e+05 0 1
NeighborhoodNames 1.807e-12 1.232e+05 0 1
NeighborhoodNoRidge 5.046e-12 1.339e+05 0 1
NeighborhoodNPkVill -5.475e-13 2.213e+05 0 1
NeighborhoodNridgHt 1.322e-12 1.193e+05 0 1
NeighborhoodNWames 2.114e-12 1.262e+05 0 1
NeighborhoodOldTown 5.554e-12 1.510e+05 0 1
NeighborhoodSawyer 2.579e-12 1.278e+05 0 1
```

## NeighborhoodSawyerW	1.988e-12	1.224e+05	0	1
## NeighborhoodSomerst	1.683e-12	1.418e+05	0	1
## NeighborhoodStoneBr	-2.015e-12	1.319e+05	0	1
## NeighborhoodSWISU	4.673e-12	1.525e+05	0	1
## NeighborhoodTimber	1.144e-12	1.275e+05	0	1
## NeighborhoodVeenker	3.504e-13	1.653e+05	0	1
## Condition1Feedr	4.815e-12	7.859e+04	0	1
## Condition1Norm	4.107e-12	6.596e+04	0	1
## Condition1PosA	5.164e-12	1.571e+05	0	1
## Condition1PosN	4.473e-12	1.169e+05	0	1
## Condition1RR Ae	4.870e-12	1.427e+05	0	1
## Condition1RR An	3.474e-12	1.090e+05	0	1
## Condition1RR Ne	5.202e-12	2.748e+05	0	1
## Condition1RR Nn	-5.933e-13	2.028e+05	0	1
## Condition2Feedr	2.546e-12	3.681e+05	0	1
## Condition2Norm	-4.530e-12	3.183e+05	0	1
## Condition2PosA	7.785e-12	5.831e+05	0	1
## Condition2PosN	6.791e-12	4.484e+05	0	1
## Condition2RR Ae	1.410e-11	8.951e+05	0	1
## Condition2RR An	-4.819e-12	4.955e+05	0	1
## Condition2RR Nn	-3.474e-12	4.250e+05	0	1
## BldgType2fmCon	-2.640e-12	1.965e+05	0	1
## BldgTypeDuplex	-1.713e-12	1.157e+05	0	1
## BldgTypeTwnhs	-4.017e-13	1.580e+05	0	1
## BldgTypeTwnhsE	3.541e-13	1.422e+05	0	1
## HouseStyle1.5Unf	-5.766e-13	1.243e+05	0	1
## HouseStyle1Story	-1.336e-12	6.860e+04	0	1
## HouseStyle2.5Fin	1.080e-11	1.942e+05	0	1
## HouseStyle2.5Unf	-2.510e-12	1.453e+05	0	1
## HouseStyle2Story	-1.723e-12	5.502e+04	0	1
## HouseStyleSFoyer	-8.396e-13	9.788e+04	0	1
## HouseStyleSLvl	-9.990e-13	8.699e+04	0	1
## OverallQual	1.036e-13	1.631e+04	0	1
## OverallCond	5.208e-13	1.399e+04	0	1
## YearBuilt	-4.551e-15	1.208e+03	0	1
## YearRemodAdd	-3.681e-14	8.758e+02	0	1
## RoofStyleGable	4.064e-12	2.901e+05	0	1
## RoofStyleGambrel	4.350e-12	3.173e+05	0	1
## RoofStyleHip	3.940e-12	2.913e+05	0	1
## RoofStyleMansard	3.202e-12	3.369e+05	0	1
## RoofStyleShed	-4.901e-12	5.456e+05	0	1
## RoofMatlCompShg	-3.391e-11	6.426e+05	0	1
## RoofMatlMembran	-3.073e-11	8.608e+05	0	1
## RoofMatlMetal	-3.811e-11	8.403e+05	0	1
## RoofMatlRoll	-2.966e-11	7.506e+05	0	1
## `RoofMatlTar&Grv`	-2.907e-11	7.013e+05	0	1
## RoofMatlWdShake	-3.427e-11	6.880e+05	0	1
## RoofMatlWdShngl	-3.471e-11	6.686e+05	0	1
## Exterior1stAsphShn	-5.949e-12	5.153e+05	0	1
## Exterior1stBrkComm	1.691e-12	4.351e+05	0	1
## Exterior1stBrkFace	1.219e-12	1.994e+05	0	1
## Exterior1stCBlock	8.826e-12	4.274e+05	0	1
## Exterior1stCemntBd	-3.590e-11	3.040e+05	0	1
## Exterior1stHdBoard	-5.367e-13	2.023e+05	0	1

## Exterior1stImStucc	-1.644e-11	4.436e+05	0	1
## Exterior1stMetalSd	4.740e-13	2.288e+05	0	1
## Exterior1stPlywood	-7.452e-13	1.998e+05	0	1
## Exterior1stStone	6.152e-12	3.767e+05	0	1
## Exterior1stStucco	-4.716e-12	2.215e+05	0	1
## Exterior1stVinylSd	2.108e-12	2.081e+05	0	1
## `Exterior1stWd Sdng`	4.409e-12	1.931e+05	0	1
## Exterior1stWdShing	1.537e-12	2.092e+05	0	1
## Exterior2ndAsphShn	4.137e-12	3.485e+05	0	1
## `Exterior2ndBrk Cmn`	6.902e-13	3.151e+05	0	1
## Exterior2ndBrkFace	-1.247e-12	2.060e+05	0	1
## Exterior2ndCBlock	NA	NA	NA	NA
## Exterior2ndCmentBd	3.728e-11	3.001e+05	0	1
## Exterior2ndHdBoard	1.716e-12	1.945e+05	0	1
## Exterior2ndImStucc	2.061e-11	2.252e+05	0	1
## Exterior2ndMetalSd	1.114e-12	2.229e+05	0	1
## Exterior2ndOther	4.558e-12	4.270e+05	0	1
## Exterior2ndPlywood	1.553e-12	1.889e+05	0	1
## Exterior2ndStone	-1.339e-12	2.668e+05	0	1
## Exterior2ndStucco	-5.230e-12	2.143e+05	0	1
## Exterior2ndVinylSd	-6.318e-13	2.010e+05	0	1
## `Exterior2ndWd Sdng`	-2.578e-12	1.870e+05	0	1
## `Exterior2ndWd Shng`	-1.936e-12	1.955e+05	0	1
## MasVnrTypeBrkFace	-2.249e-12	1.076e+05	0	1
## MasVnrTypeNone	-2.203e-12	1.086e+05	0	1
## MasVnrTypeStone	-2.595e-12	1.138e+05	0	1
## MasVnrArea	-3.952e-15	9.123e+01	0	1
## ExterQualFa	8.387e-12	1.741e+05	0	1
## ExterQualGd	7.456e-12	7.594e+04	0	1
## ExterQualTA	9.024e-12	8.380e+04	0	1
## ExterCondFa	5.801e-12	2.824e+05	0	1
## ExterCondGd	1.060e-12	2.699e+05	0	1
## ExterCondPo	9.093e-12	4.948e+05	0	1
## ExterCondTA	2.250e-12	2.693e+05	0	1
## FoundationCBlock	-3.620e-13	4.991e+04	0	1
## FoundationPConc	-2.265e-12	5.381e+04	0	1
## FoundationSlab	8.230e-13	1.233e+05	0	1
## FoundationStone	2.471e-12	1.769e+05	0	1
## FoundationWood	-2.084e-12	2.325e+05	0	1
## BsmtQualFa	-2.740e-12	9.951e+04	0	1
## BsmtQualGd	-3.467e-12	5.389e+04	0	1
## BsmtQualTA	-3.393e-12	6.598e+04	0	1
## BsmtCondGd	-1.943e-12	8.297e+04	0	1
## BsmtCondPo	-1.524e-11	4.703e+05	0	1
## BsmtCondTA	-1.665e-12	6.669e+04	0	1
## BsmtExposureGd	-2.608e-12	4.779e+04	0	1
## BsmtExposureMn	3.545e-14	4.756e+04	0	1
## BsmtExposureNo	-1.427e-13	3.429e+04	0	1
## BsmtFinType1BLQ	5.532e-13	4.386e+04	0	1
## BsmtFinType1GLQ	4.038e-13	3.971e+04	0	1
## BsmtFinType1LwQ	9.449e-13	5.885e+04	0	1
## BsmtFinType1Rec	1.548e-12	4.710e+04	0	1
## BsmtFinType1Unf	4.131e-13	4.550e+04	0	1
## BsmtFinSF1	6.287e-17	7.473e+01	0	1

## BsmtFinType2BLQ	3.962e-13	1.187e+05	0	1
## BsmtFinType2GLQ	-1.447e-12	1.474e+05	0	1
## BsmtFinType2LwQ	-4.191e-12	1.162e+05	0	1
## BsmtFinType2Rec	-4.805e-13	1.118e+05	0	1
## BsmtFinType2Unf	1.102e-13	1.183e+05	0	1
## BsmtFinSF2	2.161e-15	1.343e+02	0	1
## BsmtUnfSF	-1.396e-16	6.293e+01	0	1
## TotalBsmtSF	NA	NA	NA	NA
## HeatingGasA	2.104e-12	3.867e+05	0	1
## HeatingGasW	4.472e-12	4.006e+05	0	1
## HeatingGrav	5.751e-13	4.259e+05	0	1
## HeatingOthW	3.451e-12	4.850e+05	0	1
## HeatingWall	8.756e-12	4.500e+05	0	1
## HeatingQCFA	-1.317e-12	7.416e+04	0	1
## HeatingQCGd	-6.874e-13	3.253e+04	0	1
## HeatingQCPo	-1.435e-12	4.180e+05	0	1
## HeatingQCTA	1.930e-13	3.258e+04	0	1
## CentralAirY	-1.391e-12	6.081e+04	0	1
## ElectricalFuseF	1.177e-13	9.041e+04	0	1
## ElectricalFuseP	-1.714e-12	2.899e+05	0	1
## ElectricalMix	1.564e-12	7.000e+05	0	1
## ElectricalSBrkr	-2.232e-13	4.626e+04	0	1
## X1stFlrSF	-2.889e-16	8.657e+01	0	1
## X2ndFlrSF	-1.529e-15	9.389e+01	0	1
## LowQualFinSF	-4.523e-14	2.954e+02	0	1
## GrLivArea	NA	NA	NA	NA
## BsmtFullBath	-3.463e-13	3.110e+04	0	1
## BsmtHalfBath	-2.140e-12	4.758e+04	0	1
## FullBath	-1.709e-13	3.469e+04	0	1
## HalfBath	9.954e-13	3.297e+04	0	1
## BedroomAbvGr	3.263e-13	2.152e+04	0	1
## KitchenAbvGr	1.719e-12	8.914e+04	0	1
## KitchenQualFa	-2.590e-12	9.784e+04	0	1
## KitchenQualGd	-1.837e-12	5.585e+04	0	1
## KitchenQualTA	-1.554e-12	6.257e+04	0	1
## TotRmsAbvGrd	-3.200e-13	1.504e+04	0	1
## FunctionalMaj2	6.646e-12	2.265e+05	0	1
## FunctionalMin1	-1.694e-12	1.354e+05	0	1
## FunctionalMin2	-2.800e-12	1.357e+05	0	1
## FunctionalMod	-1.147e-11	1.661e+05	0	1
## FunctionalSev	2.264e-14	4.649e+05	0	1
## FunctionalTyp	-2.455e-12	1.176e+05	0	1
## Fireplaces	3.104e-13	2.401e+04	0	1
## FireplaceQuFa	9.691e-12	1.083e+05	0	1
## FireplaceQuGd	9.266e-12	8.392e+04	0	1
## FireplaceQuPo	9.801e-12	1.233e+05	0	1
## FireplaceQuTA	9.822e-12	8.695e+04	0	1
## GarageTypeAttchd	-2.049e-12	1.735e+05	0	1
## GarageTypeBasment	-1.629e-12	2.004e+05	0	1
## GarageTypeBuiltIn	-3.053e-12	1.806e+05	0	1
## GarageTypeCarPort	-3.931e-12	2.305e+05	0	1
## GarageTypeDetchd	-2.283e-12	1.729e+05	0	1
## GarageYrBlt	5.361e-14	8.923e+02	0	1
## GarageFinishRFn	2.004e-13	3.098e+04	0	1

## GarageFinishUnf	3.763e-14	3.773e+04	0	1
## GarageCars	1.250e-12	3.453e+04	0	1
## GarageArea	-6.820e-15	1.224e+02	0	1
## GarageQualFa	-9.740e-12	4.832e+05	0	1
## GarageQualGd	-1.227e-11	4.941e+05	0	1
## GarageQualPo	-1.076e-11	6.125e+05	0	1
## GarageQualTA	-1.024e-11	4.782e+05	0	1
## GarageCondFa	1.361e-11	5.528e+05	0	1
## GarageCondGd	1.559e-11	5.731e+05	0	1
## GarageCondPo	1.534e-11	5.924e+05	0	1
## GarageCondTA	1.328e-11	5.482e+05	0	1
## PavedDriveP	2.144e-12	8.597e+04	0	1
## PavedDriveY	2.028e-13	5.379e+04	0	1
## WoodDeckSF	-1.217e-15	9.257e+01	0	1
## OpenPorchSF	-5.785e-15	1.806e+02	0	1
## EnclosedPorch	-2.526e-14	1.961e+02	0	1
## X3SsnPorch	-2.427e-16	3.520e+02	0	1
## ScreenPorch	-1.085e-14	1.973e+02	0	1
## PoolArea	9.296e-15	4.636e+02	0	1
## PoolQCFa	-2.021e-10	5.004e+05	0	1
## PoolQCGd	-2.018e-10	4.034e+05	0	1
## FenceGdWo	3.809e-12	7.735e+04	0	1
## FenceMnPrv	3.733e-12	5.704e+04	0	1
## FenceMnWw	4.546e-12	1.292e+05	0	1
## MiscFeatureOthr	2.505e-11	1.006e+06	0	1
## MiscFeatureShed	1.930e-11	1.038e+06	0	1
## MiscFeatureTenC	1.812e-11	1.070e+06	0	1
## MiscVal	1.252e-15	6.304e+01	0	1
## MoSold	8.678e-14	3.858e+03	0	1
## YrSold	-1.270e-14	8.101e+03	0	1
## SaleTypeCon	-1.459e-12	2.768e+05	0	1
## SaleTypeConLD	1.039e-12	1.526e+05	0	1
## SaleTypeConLI	-2.007e-12	1.813e+05	0	1
## SaleTypeConLw	-7.088e-13	1.908e+05	0	1
## SaleTypeCWD	-1.570e-12	2.027e+05	0	1
## SaleTypeNew	3.616e-12	2.427e+05	0	1
## SaleTypeOth	3.002e-13	2.255e+05	0	1
## SaleTypeWD	-9.568e-13	6.570e+04	0	1
## SaleConditionAdjLand	-1.266e-12	2.276e+05	0	1
## SaleConditionAlloca	-7.232e-13	1.364e+05	0	1
## SaleConditionFamily	5.142e-13	9.558e+04	0	1
## SaleConditionNormal	2.484e-13	4.570e+04	0	1
## SaleConditionPartial	-4.573e-12	2.333e+05	0	1
## SalePrice	5.242e-17	5.647e-01	0	1
## economico	-5.313e+01	2.113e+05	0	1
## medio	-5.313e+01	1.853e+05	0	1
##				
## (Dispersion parameter for binomial family taken to be 1)				
##				
## Null deviance: 9.9264e+01 on 1459 degrees of freedom				
## Residual deviance: 8.4703e-09 on 1214 degrees of freedom				
## AIC: 492				
##				
## Number of Fisher Scoring iterations: 25				

El modelo de regresión logística con validación cruzada mostró que ninguna de las variables es significativa, ya que los valores de  $z$  son 0 y los valores de  $\Pr(>|z|)$  son 1, lo que indica que las variables no están contribuyendo de manera relevante. Esto podría ser causado por la multicolinealidad entre las variables, debido a que muchas de ellas están altamente correlacionadas, lo que afecta la estimación de los coeficientes. Otra posible causa es el exceso de variables en relación con el número de observaciones, lo que podría llevar a un sobreajuste lo cual es más probable con los modelos realizadas con anterioridad.

Los valores de  $p$  de 1 son un gran indicativo de la falta de significancia en las variables sobre el modelo. Esto es debido a la gran multicolinealidad que se presenta en el conjunto de datos, además de que ninguna variable resulta significativa para la predicción de las casas “caras”.

```
Call:
nnet::multinom(formula = .outcome ~ ., data = dat, decay = param$decay,
trace = FALSE)
##
Coefficients:
(Intercept) MSSubClass MSZoningFV MSZoningRH MSZoningRL MSZoningRM
economico -0.01714893 0.001101410 0.1530568 0.2957217 -0.05689274 -0.2604506
medio 0.01312096 -0.006694639 0.3162988 -0.4647028 0.82131934 1.1182811
LotFrontage LotArea StreetPave AlleyPave LotShapeIR2
economico -0.01299268 0.0001491241 -0.5441204 0.20742026 -0.2246062
medio -0.01687481 0.0001036350 1.9050850 -0.02189445 -0.5503255
LotShapeIR3 LotShapeReg LandContourHLS LandContourLow LandContourLvl
economico 1.1490900 -0.03284831 -0.28870227 0.5214846 0.3077974
medio 0.9912686 -0.39390725 -0.06627513 0.6278728 0.1867241
UtilitiesNoSeWa LotConfigCulDSac LotConfigFR2 LotConfigFR3
economico -0.3790245 -0.4303433 -0.29089932 -0.4764919
medio 0.7074540 -0.2424822 -0.09335567 0.1178051
LotConfigInside LandSlopeMod LandSlopeSev NeighborhoodBlueste
economico -0.2662634 -0.1026328 0.4810144 0.1771096
medio -0.3429775 0.1027424 -0.2696511 -0.3309488
NeighborhoodBrDale NeighborhoodBrkSide NeighborhoodClearCr
economico 0.09232272 0.4122681 0.8579764
medio -0.05203416 0.2004710 0.3427614
NeighborhoodCollgCr NeighborhoodCrawfor NeighborhoodEdwards
economico -0.6141003 0.8707533 0.07641929
medio 0.3972050 0.1707178 -0.09984035
NeighborhoodGilbert NeighborhoodIDOTRR NeighborhoodMeadowV
economico -0.20657514 -0.2520061 -0.34360850
medio -0.04037338 -0.4225894 0.07932858
NeighborhoodMitchel NeighborhoodNames NeighborhoodNoRidge
economico -0.01416389 0.0207002 -0.3561949
medio -0.10715137 -0.1621490 0.3524228
NeighborhoodNPkVill NeighborhoodNridgHt NeighborhoodNWames
economico -0.03353481 -0.090126027 -0.1220062
medio 0.56598072 0.006903909 0.1874474
NeighborhoodOldTown NeighborhoodSawyer NeighborhoodSawyerW
economico 0.07742748 0.1042675 -0.3875433
medio -0.27604055 0.7234797 -0.3815222
NeighborhoodSomerst NeighborhoodStoneBr NeighborhoodSWISU
economico 0.1984696 -0.88008644 0.30924458
medio -0.2794237 0.03543834 -0.07452418
NeighborhoodTimber NeighborhoodVeenker Condition1Feedr Condition1Norm
economico 0.4773896 0.54821107 0.3191159 0.05091740
medio 0.4860941 0.05034178 -0.1661514 0.03322942
```

##	Condition1PosA	Condition1PosN	Condition1RR Ae	Condition1RR An
## economico	0.4552429	0.2413831	0.4151138	-0.07765070
## medio	0.1544174	0.3099631	-0.4416228	-0.05919175
##	Condition1RR Ne	Condition1RR Nn	Condition2Feedr	Condition2Norm
## economico	-0.52754577	-0.3865589	0.601042	0.4077817
## medio	0.01462837	-0.4298720	-1.350585	0.8336800
##	Condition2PosA	Condition2PosN	Condition2RR Ae	Condition2RR An
## economico	-0.4121201	-0.53711508	-0.1980976	-0.20494656
## medio	0.1712187	0.07148083	0.4430674	0.08656668
##	Condition2RR Nn	BldgType2fmCon	BldgTypeDuplex	BldgTypeTwnhs
## economico	0.10872284	-0.2213977	-0.01106503	-0.3203615
## medio	-0.07571559	0.2348846	-0.27582705	0.6400671
##	BldgTypeTwnhsE	HouseStyle1.5Unf	HouseStyle1Story	HouseStyle2.5Fin
## economico	-0.12936422	0.3139577	-0.03307198	0.2366385
## medio	-0.06738761	-0.5213995	-0.38632283	0.4281893
##	HouseStyle2.5Unf	HouseStyle2Story	HouseStyleSFoyer	HouseStyleSLvl
## economico	-0.3161256	-0.008236034	0.14599529	-0.3603264
## medio	-0.3267774	0.356919350	-0.07447617	-0.2552559
##	OverallQual	OverallCond	YearBuilt	YearRemodAdd
## economico	0.4098179	0.3226525	0.01518136	0.005503871
## medio	0.1220051	0.7728217	0.03064422	-0.016057561
##	RoofStyleGambrel	RoofStyleHip	RoofStyleMansard	RoofStyleShed
## economico	0.053505473	-0.4552475	-0.001746087	-0.2011856
## medio	0.002144258	-1.0616212	0.600209922	0.4568513
##	RoofMatlCompShg	RoofMatlMembran	RoofMatlMetal	RoofMatlRoll
## economico	0.03653475	0.32026835	0.2974809	0.2993835
## medio	0.43899540	-0.01349971	0.1097386	0.1285226
##	RoofMatlTar&Grv`	RoofMatlWdShake	RoofMatlWdShngl	Exterior1stAsphShn
## economico	-0.2127485	-0.19032503	-0.4767200	-0.3179992
## medio	0.3525885	-0.07901624	-0.4340175	0.1326490
##	Exterior1stBrkComm	Exterior1stBrkFace	Exterior1stCBlock	
## economico	-0.16359160	0.48116447	0.06121009	
## medio	0.07876888	-0.01821254	-0.09771173	
##	Exterior1stCemntBd	Exterior1stHdBoard	Exterior1stImStucc	
## economico	-1.5019220	-0.1172292	0.1150858	
## medio	-0.7030497	-0.1473618	-0.1137626	
##	Exterior1stMetalSd	Exterior1stPlywood	Exterior1stStone	
## economico	0.4450422	0.7053514	0.1203959	
## medio	-0.1514494	-0.1794610	-0.3794658	
##	Exterior1stStucco	Exterior1stVinylSd	Exterior1stWd Sdng`	
## economico	-0.5637144	0.7217669	0.2131426	
## medio	0.7357022	-0.2902308	-0.1138478	
##	Exterior1stWdShing	Exterior2ndAsphShn	Exterior2ndBrk Cmn`	
## economico	0.52076672	0.3276143	0.06730893	
## medio	0.01953439	-0.2802776	0.31734865	
##	Exterior2ndBrkFace	Exterior2ndCBlock	Exterior2ndCmentBd	
## economico	-0.2195023	0.06121009	0.84910659	
## medio	0.1078082	-0.09771173	0.02124405	
##	Exterior2ndHdBoard	Exterior2ndImStucc	Exterior2ndMetalSd	
## economico	-0.7065934	-0.07080637	-0.2893852	
## medio	-0.1985426	-0.09238393	-0.1014440	
##	Exterior2ndOther	Exterior2ndPlywood	Exterior2ndStone	
## economico	0.0537975	-0.1877785	-0.3195776	
## medio	-0.1672481	-0.2087765	0.3462856	

##	Exterior2ndStucco	Exterior2ndVinylSd	`Exterior2ndWd Sdng`		
## economico	0.7306478	-0.11743038	0.004325423		
## medio	-0.1457104	-0.01608508	0.038003628		
##	`Exterior2ndWd Shng` MasVnrTypeBrkFace MasVnrTypeNone MasVnrTypeStone				
## economico	-0.6456399	-0.01680262	0.33396639	-0.06364656	
## medio	-0.1597615	-0.28403460	0.09018723	0.16693987	
##	MasVnrArea	ExterQualFa	ExterQualGd	ExterQualTA	ExterCondFa
## economico	0.001583670	-0.07678328	0.4148993	-0.3057784	0.2202689
## medio	0.001607949	-0.87318144	-0.9032618	-1.1099690	-0.1694694
##	ExterCondGd	ExterCondPo	ExterCondTA	FoundationCBlock	FoundationPConc
## economico	0.36855995	0.04833628	0.1493948	0.1714171	0.4462299
## medio	-0.03047594	0.14765172	-0.1995359	0.2197555	0.7311633
##	FoundationSlab	FoundationStone	FoundationWood	BsmtQualFa	BsmtQualGd
## economico	-0.6480286	1.438981	0.6807202	-0.4766127	0.1333541
## medio	-0.1745766	0.651968	-0.6031166	0.1479070	0.6127214
##	BsmtQualTA	BsmtCondGd	BsmtCondPo	BsmtCondTA	BsmtExposureGd
## economico	0.1831356	0.4493871	0.3855699	-0.3305763	-0.4371681
## medio	-0.2544266	-0.4158386	-0.7869508	0.4019760	-0.4823639
##	BsmtExposureMn	BsmtExposureNo	BsmtFinType1BLQ	BsmtFinType1GLQ	
## economico	0.3316429	0.2872012	0.03156766	0.1725523	
## medio	-0.2854998	-0.3415710	0.12686212	0.4102017	
##	BsmtFinType1LwQ	BsmtFinType1Rec	BsmtFinType1Unf	BsmtFinSF1	
## economico	0.08289960	-0.1537751	-0.1133463	-0.0003044563	
## medio	-0.06443489	-0.2297761	0.1163508	-0.0004281523	
##	BsmtFinType2BLQ	BsmtFinType2GLQ	BsmtFinType2LwQ	BsmtFinType2Rec	
## economico	0.2830420	0.01488595	0.4146735	0.1552275	
## medio	-0.1152676	-0.04784530	0.2965416	0.5653399	
##	BsmtFinType2Unf	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	HeatingGasA
## economico	0.2371898	-0.0001721706	-0.0003553337	-0.0008319681	-0.7506293
## medio	0.5097313	0.0006826186	-0.0004627562	-0.0002082921	-0.3838489
##	HeatingGasW	HeatingGrav	HeatingOthW	HeatingWall	HeatingQCFa
## economico	0.5109077	-0.2522827	0.06104162	0.11413934	0.06258231
## medio	0.8908967	-0.2538473	-0.06823086	-0.09284914	-0.05108432
##	HeatingQCGd	HeatingQCPo	HeatingQCTA	CentralAirY	ElectricalFuseF
## economico	0.1055135	-0.1413208	-0.12858786	0.1073664	-0.04027725
## medio	-0.1480589	0.1183587	-0.08465793	0.4735902	0.28771567
##	ElectricalFuseP	ElectricalMix	ElectricalSBrkr	X1stFlrSF	
## economico	0.09306355	0.2829388	0.4308974	9.467992e-05	
## medio	-0.08511168	-0.3774419	0.6376577	-2.985019e-04	
##	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	BsmtHalfBath
## economico	-0.0009751435	0.003073956	0.002193534	0.5262366	0.04053264
## medio	-0.0018323491	0.003778733	0.001647851	-0.2288404	-0.05947129
##	FullBath	HalfBath	BedroomAbvGr	KitchenAbvGr	KitchenQualFa
## economico	0.1930876	0.03125897	0.8890714	0.1752478	-0.130697
## medio	0.4375040	0.02837515	-0.8042966	0.2776410	-0.288850
##	KitchenQualGd	KitchenQualTA	TotRmsAbvGrd	FunctionalMaj2	
## economico	0.23097437	0.2996015	-0.6577827	1.8515709	
## medio	0.08221661	-0.3058388	0.3079607	-0.9223682	
##	FunctionalMin1	FunctionalMin2	FunctionalMod	FunctionalSev	
## economico	-0.2850374	0.01360182	-1.3558075	0.3758713	
## medio	0.3242594	0.58516888	-0.2171951	-0.7033537	
##	FunctionalTyp	Fireplaces	FireplaceQuFa	FireplaceQuGd	FireplaceQuPo
## economico	-0.2049661	0.4809739	-0.4609171	-1.0415242	-0.7615189
## medio	0.6885652	0.5366603	-0.3631750	-0.4783431	-0.2812913

```

FireplaceQuTA GarageTypeAttchd GarageTypeBasment GarageTypeBuiltIn
economico -0.8728485 0.07246153 0.1371366 0.04449576
medio -0.7370135 -0.39216198 0.7122471 0.14670151
GarageTypeCarPort GarageTypeDetchd GarageYrBlt GarageFinishRfN
economico -0.1610016 0.006406593 0.0002712129 0.02656806
medio -0.7544620 -0.184441077 -0.0019906569 -0.17405334
GarageFinishUnf GarageCars GarageArea GarageQualFa GarageQualGd
economico 0.33036404 0.18366247 -0.0003501396 -0.36424658 -0.2193659
medio 0.02684333 -0.02114018 0.0001952360 0.06002847 0.2364312
GarageQualPo GarageQualTA GarageCondFa GarageCondGd GarageCondPo
economico 1.0945677 -0.67749935 -0.3563443 -0.4375111 0.7355742
medio -0.8563868 -0.03859975 0.5380417 0.1596827 -0.7560980
GarageCondTA PavedDriveP PavedDriveY WoodDeckSF OpenPorchSF
economico -0.2895975 -0.7865759 -0.3764457 0.0003986864 -0.001866176
medio 0.3487040 -0.5764269 -0.4030238 -0.0013835478 -0.002585929
EnclosedPorch X3SsnPorch ScreenPorch PoolArea PoolQCFA
economico 0.003546126 0.012549937 -0.001965906 0.003059456 -0.02054309
medio 0.007759641 0.007561441 0.001412170 0.003931773 0.37359978
PoolQCGd FenceGdWo FenceMnPrv FenceMnWw MiscFeature0thr
economico -0.8259283 -0.3665405 -0.34011755 -0.05119467 0.02097904
medio -0.5891223 -0.2126394 0.05193031 -0.20175737 0.07356371
MiscFeatureShed MiscFeatureTenC MiscVal MoSold
economico -0.1090484 -0.04283081 0.0005769711 0.0008385918
medio -0.7836459 0.84486441 -0.0005527146 -0.0244102735
YrSold SaleTypeCon SaleTypeConLD SaleTypeConLI SaleTypeConLw
economico -0.01980608 0.4177099 0.5036697 0.2127623 -0.02612279
medio -0.01437454 -0.3320231 0.1212872 0.9382414 0.24388227
SaleTypeCWD SaleTypeNew SaleType0th SaleTypeWD SaleConditionAdjLand
economico 0.4006678 0.2053054 0.3017478 -0.09414143 -0.5831784
medio 0.3024123 0.1679612 -0.1213645 0.31955287 0.6171371
SaleConditionAlloca SaleConditionFamily SaleConditionNormal
economico 0.5008348 0.02074259 -0.03052446
medio -1.3604822 0.32027298 0.34547539
SaleConditionPartial SalePrice economico medio caro
economico -0.1129704 -2.554907e-05 12.480314 -4.934031 -7.563431
medio 0.3138578 -2.006937e-05 -1.498526 12.915822 -11.404175
##
Std. Errors:
(Intercept) MSSubClass MSZoningFV MSZoningRH MSZoningRL
economico 8.006962e-06 0.1557881 8.744219e-05 2.949224e-05 0.0005235057
medio 7.604434e-06 0.0984562 1.521733e-04 2.856644e-06 0.0004211864
MSZoningRM LotFrontage LotArea StreetPave AlleyPave
economico 0.0004922520 0.03414598 0.003347460 4.542891e-05 6.294235e-05
medio 0.0003514056 0.02703459 0.003343605 7.592089e-06 1.829386e-05
LotShapeIR2 LotShapeIR3 LotShapeReg LandContourHLS LandContourLow
economico 1.056805e-04 1.707236e-05 0.0002734384 0.0001101008 4.635251e-05
medio 9.914008e-05 1.661205e-05 0.0003658016 0.0001405420 2.793003e-05
LandContourLvl UtilitiesNoSeWa LotConfigCulDSac LotConfigFR2
economico 0.0002503898 0.0002355811 0.0003112939 9.306908e-05
medio 0.0001641265 0.0002624652 0.0003122132 1.173668e-04
LotConfigFR3 LotConfigInside LandSlopeMod LandSlopeSev
economico 1.239420e-05 0.0002019750 0.0001255374 2.89539e-05
medio 1.148346e-05 0.0002224911 0.0001575924 3.88484e-05
NeighborhoodBlueste NeighborhoodBrDale NeighborhoodBrkSide

```

## economico	2.455551e-06	1.246459e-04	1.892147e-04		
## medio	1.634291e-06	7.567216e-05	8.284681e-05		
##	NeighborhoodClearCr	NeighborhoodCollgCr	NeighborhoodCrawfor		
## economico	8.718677e-05	0.0003883228	7.221292e-05		
## medio	7.269436e-05	0.0002967880	1.404745e-04		
##	NeighborhoodEdwards	NeighborhoodGilbert	NeighborhoodIDOTRR		
## economico	1.020884e-04	0.0001357913	1.919710e-04		
## medio	6.453488e-05	0.0001131858	7.639078e-05		
##	NeighborhoodMeadowV	NeighborhoodMitchel	NeighborhoodNames		
## economico	0.0003197793	5.568615e-05	0.0002894844		
## medio	0.0002294299	3.531849e-05	0.0001526972		
##	NeighborhoodNoRidge	NeighborhoodNPkVill	NeighborhoodNridgHt		
## economico	8.691373e-05	4.645447e-05	0.0002374752		
## medio	6.047711e-05	2.965833e-05	0.0002489233		
##	NeighborhoodNWAmes	NeighborhoodOldTown	NeighborhoodSawyer		
## economico	0.0001929931	0.0002923957	1.181406e-04		
## medio	0.0001272635	0.0001917203	6.481616e-05		
##	NeighborhoodSawyerW	NeighborhoodSomerst	NeighborhoodStoneBr		
## economico	5.080920e-05	0.0001033116	0.00017405		
## medio	4.387882e-05	0.0001726743	0.00018882		
##	NeighborhoodSWISU	NeighborhoodTimber	NeighborhoodVeenker		
## economico	2.150230e-05	0.0002282526	1.180398e-05		
## medio	1.921472e-05	0.0002365110	1.397384e-05		
##	Condition1Feedr	Condition1Norm	Condition1PosA	Condition1PosN	
## economico	7.873359e-05	0.0001244117	4.426290e-05	2.758248e-05	
## medio	5.622046e-05	0.0001015582	7.150297e-05	4.187672e-05	
##	Condition1RR Ae	Condition1RR An	Condition1RR Ne	Condition1RR Nn	
## economico	8.794045e-06	9.193757e-05	1.713039e-05	3.932509e-05	
## medio	1.515519e-05	5.546320e-05	1.591023e-05	7.726112e-06	
##	Condition2Feedr	Condition2Norm	Condition2PosA	Condition2PosN	
## economico	9.033212e-06	6.918377e-05	8.870379e-09	2.435800e-05	
## medio	2.530654e-06	6.773125e-05	4.760552e-05	2.200284e-05	
##	Condition2RR Ae	Condition2RR An	Condition2RR Nn	BldgType2fmCon	
## economico	2.192364e-07	1.339291e-06	1.009610e-05	2.013319e-04	
## medio	3.441648e-07	8.055687e-07	6.019827e-06	3.256161e-05	
##	BldgTypeDuplex	BldgTypeTwnhs	BldgTypeTwnhsE	HouseStyle1.5Unf	
## economico	1.284857e-04	0.0004748924	0.0006239287	2.178026e-05	
## medio	5.679441e-05	0.0003829690	0.0004158675	1.676275e-05	
##	HouseStyle1Story	HouseStyle2.5Fin	HouseStyle2.5Unf	HouseStyle2Story	
## economico	0.0004815599	4.321862e-05	1.426519e-04	0.0002153103	
## medio	0.0003152952	4.450851e-05	9.610759e-05	0.0001335781	
##	HouseStyleSFoyer	HouseStyleSLvl	OverallQual	OverallCond	YearBuilt
## economico	0.0002532111	0.0002550265	0.0007876906	0.0009062944	0.01682424
## medio	0.0002008359	0.0002250583	0.0007470030	0.0006247071	0.01280595
##	YearRemodAdd	RoofStyleGable	RoofStyleGambrel	RoofStyleHip	
## economico	0.013062159	0.0001202384	5.627251e-05	0.0001271590	
## medio	0.008334655	0.0002312783	6.563805e-05	0.0001594939	
##	RoofStyleMansard	RoofStyleShed	RoofMatlCompShg	RoofMatlMembran	
## economico	3.920651e-05	1.501972e-06	5.532289e-05	2.400228e-07	
## medio	5.602619e-05	1.622848e-06	8.081182e-05	2.845022e-07	
##	RoofMatlMetal	RoofMatlRoll	RoofMatlTar&Grv`	RoofMatlWdShake	
## economico	1.259127e-07	7.915787e-06	1.377532e-05	4.081561e-05	
## medio	1.511586e-07	2.430316e-06	1.142554e-05	5.998133e-05	
##	RoofMatlWdShngl	Exterior1stAsphShn	Exterior1stBrkComm		

## economico	4.787567e-06	4.557883e-07	3.993340e-06
## medio	2.371811e-05	1.727826e-07	1.871246e-06
##	Exterior1stBrkFace	Exterior1stCBlock	Exterior1stCemntBd
## economico	6.409669e-05	2.551975e-05	0.0003734905
## medio	8.981073e-05	2.820260e-05	0.0002954096
##	Exterior1stHdBoard	Exterior1stImStucc	Exterior1stMetalSd
## economico	0.0002849773	6.037610e-06	0.0003132943
## medio	0.0003455778	6.222043e-06	0.0002011090
##	Exterior1stPlywood	Exterior1stStone	Exterior1stStucco
## economico	7.472799e-05	4.665611e-05	6.002219e-05
## medio	6.455129e-05	5.022823e-05	7.041421e-05
##	Exterior1stVinylSd	Exterior1stWd Sdng	Exterior1stWdShing
## economico	0.0002587044	0.0002775036	7.058473e-05
## medio	0.0003130797	0.0001228940	7.230134e-05
##	Exterior2ndAsphShn	Exterior2ndBrk Cmn	Exterior2ndBrkFace
## economico	1.387971e-06	2.479224e-05	3.718113e-05
## medio	1.346984e-06	2.624154e-05	2.808158e-05
##	Exterior2ndCBlock	Exterior2ndCmentBd	Exterior2ndHdBoard
## economico	2.551975e-05	0.0003730714	0.0002769573
## medio	2.820260e-05	0.0002850796	0.0003147095
##	Exterior2ndImStucc	Exterior2ndMetalSd	Exterior2ndOther
## economico	1.637478e-05	0.0003236526	2.865251e-09
## medio	1.604781e-05	0.0002029960	6.542195e-06
##	Exterior2ndPlywood	Exterior2ndStone	Exterior2ndStucco
## economico	0.0001980831	4.858887e-05	5.343224e-05
## medio	0.0000877670	6.306255e-05	6.032283e-05
##	Exterior2ndVinylSd	Exterior2ndWd Sdng	Exterior2ndWd Shng
## economico	0.0002541827	2.331461e-04	0.0001438151
## medio	0.0003179308	8.282782e-05	0.0001137529
##	MasVnrTypeBrkFace	MasVnrTypeNone	MasVnrTypeStone
## economico	0.0003416164	0.0003874761	8.237495e-05
## medio	0.0002361880	0.0003194825	1.433766e-04
##	ExterQualFa	ExterQualGd	ExterQualTA
## economico	9.284458e-05	0.0002583483	0.0003143904
## medio	3.317203e-05	0.0003969662	0.0002707649
##	ExterCondFa	ExterCondGd	ExterCondTA
## economico	4.066483e-05	1.319110e-04	0.0002392530
## medio	4.559186e-07	7.243108e-05	0.0002452191
##	FoundationSlab	FoundationStone	FoundationWood
## economico	5.840562e-05	2.706162e-05	3.149216e-06
## medio	3.728269e-05	4.025096e-06	9.895527e-07
##	BsmtQualFa	BsmtQualGd	BsmtQualTA
## economico	0.0004134461	0.0004058647	2.711733e-05
## medio	0.0004588052	0.0003120336	1.318607e-04
##	BsmtExposureGd	BsmtExposureMn	BsmtExposureNo
## economico	0.0002380998	0.0001190622	0.0004469458
## medio	0.0001378178	0.0001839419	0.0002793317
##	BsmtFinType1GLQ	BsmtFinType1LwQ	BsmtFinType1Rec
## economico	0.0003384430	0.0001584538	0.0002036833
## medio	0.0003383033	0.0001117593	0.0001416001
##	BsmtFinType1Unf	BsmtFinType2BLQ	BsmtFinType2GLQ
## economico	0.03417969	1.140216e-04	5.357128e-05
## medio	0.04368389	7.548475e-05	7.575708e-05
##	BsmtFinType2Rec	BsmtFinType2Unf	BsmtFinSF2
##	BsmtUnfSF	TotalBsmtSF	

## economico	0.0002638790	0.0002267775	0.05515344	0.02958684	0.05229199
## medio	0.0003629019	0.0002364323	0.07152798	0.03903486	0.07320409
##	HeatingGasA	HeatingGasW	HeatingGrav	HeatingOthW	HeatingWall
## economico	4.977862e-05	4.181255e-05	1.297872e-05	6.809691e-06	2.362325e-05
## medio	3.045633e-05	1.709898e-05	1.839082e-06	7.956691e-06	1.024473e-05
##	HeatingQCFa	HeatingQCGd	HeatingQCPo	HeatingQCTA	CentralAirY
## economico	9.998353e-05	0.0002683178	1.132878e-05	0.0003166748	0.0002945485
## medio	3.521856e-05	0.0001672985	8.816188e-06	0.0003830492	0.0000846418
##	ElectricalFuseF	ElectricalFuseP	ElectricalMix	ElectricalSBrkr	
## economico	1.055291e-04	9.675324e-06	4.302592e-08	0.0003616570	
## medio	5.824351e-05	9.796053e-06	1.933887e-11	0.0001823056	
##	X1stFlrSF	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath
## economico	0.05732055	0.04601704	0.09629693	0.04403392	0.0002780259
## medio	0.07715615	0.04983829	0.08793452	0.04828416	0.0002176794
##	BsmtHalfBath	FullBath	HalfBath	BedroomAbvGr	KitchenAbvGr
## economico	0.0001917648	0.0002489269	0.0002537577	0.0008718895	2.142726e-04
## medio	0.0001916004	0.0001308022	0.0002864086	0.0007487350	9.736856e-05
##	KitchenQualFa	KitchenQualGd	KitchenQualTA	TotRmsAbvGrd	FunctionalMaj2
## economico	1.011879e-04	0.0003661255	0.0004653296	0.0011797964	2.837907e-07
## medio	5.142075e-05	0.0003053397	0.0003526669	0.0008085687	4.273614e-08
##	FunctionalMin1	FunctionalMin2	FunctionalMod	FunctionalSev	
## economico	5.742257e-05	5.098698e-05	6.623612e-05	1.488455e-07	
## medio	5.146807e-05	2.299805e-05	1.076459e-04	2.491323e-07	
##	FunctionalTyp	Fireplaces	FireplaceQuFa	FireplaceQuGd	FireplaceQuPo
## economico	0.0001234834	0.0005149597	1.950680e-05	0.0002912886	3.682474e-05
## medio	0.0001404665	0.0002073631	1.175888e-05	0.0002146868	1.526448e-05
##	FireplaceQuTA	GarageTypeAttchd	GarageTypeBasment	GarageTypeBuiltIn	
## economico	0.0002793807	0.0003430456	0.0001780008	1.08285e-04	
## medio	0.0001758973	0.0002762439	0.0002294329	9.96254e-05	
##	GarageTypeCarPort	GarageTypeDetchd	GarageYrBlt	GarageFinishRfn	
## economico	9.24599e-05	0.000325671	0.01139246	0.0002645142	
## medio	1.58306e-05	0.000317826	0.01137765	0.0002272131	
##	GarageFinishUnf	GarageCars	GarageArea	GarageQualFa	GarageQualGd
## economico	0.0001957925	0.0002702174	0.07561051	1.004408e-04	5.317039e-05
## medio	0.0002902356	0.0003751510	0.11276245	6.228461e-05	5.049581e-05
##	GarageQualPo	GarageQualTA	GarageCondFa	GarageCondGd	GarageCondPo
## economico	7.286251e-07	1.435991e-04	1.071077e-04	5.507786e-05	6.378271e-05
## medio	9.161089e-08	5.131837e-05	4.905453e-05	1.344296e-05	5.893577e-06
##	GarageCondTA	PavedDriveP	PavedDriveY	WoodDeckSF	OpenPorchSF
## economico	1.797251e-04	4.588999e-05	1.447329e-04	0.1218680	0.1917451
## medio	4.789179e-05	3.132719e-05	6.906853e-05	0.1696755	0.2796749
##	EnclosedPorch	X3SsnPorch	ScreenPorch	PoolArea	PoolQCFa
## economico	0.1459642	0.002136383	0.2328127	0.03136260	5.349700e-05
## medio	0.1181985	0.002333017	0.2788786	0.03109531	5.470326e-05
##	PoolQCGd	FenceGdWo	FenceMnPrv	FenceMnWw	MiscFeature0thr
## economico	5.431176e-05	5.774394e-05	1.116181e-04	2.051841e-05	3.792663e-05
## medio	5.604732e-05	2.522631e-05	3.853601e-05	8.890498e-06	4.841111e-06
##	MiscFeatureShed	MiscFeatureTenC	MiscVal	MoSold	YrSold
## economico	4.054199e-05	5.310364e-05	0.09422977	0.0017109937	0.01603303
## medio	5.562294e-05	5.439328e-05	0.13373654	0.0009669727	0.01532265
##	SaleTypeCon	SaleTypeConLD	SaleTypeConLI	SaleTypeConLw	SaleTypeCWD
## economico	8.516569e-07	5.422627e-05	4.483628e-06	1.280649e-05	4.034112e-05
## medio	8.020523e-07	4.351956e-06	7.011543e-06	1.269163e-05	1.370041e-05
##	SaleTypeNew	SaleTypeOth	SaleTypeWD	SaleConditionAdjLand	

```

economico 8.129496e-05 3.272053e-06 0.0003539961 2.217397e-05
medio 1.832100e-04 6.004988e-07 0.0002896359 1.051574e-05
SaleConditionAlloca SaleConditionFamily SaleConditionNormal
economico 2.561715e-05 4.786098e-05 0.0002803497
medio 1.884204e-05 1.498812e-05 0.0002716672
SaleConditionPartial SalePrice economico medio
economico 8.667338e-05 0.0003557239 3.817706e-05 0.0000414717
medio 1.831999e-04 0.0004087076 1.180959e-04 0.0002148406
caro
economico 4.667592e-05
medio 1.167636e-04
##
Residual Deviance: 0.1498268
AIC: 984.1498

Confusion Matrix and Statistics
##
Reference
Prediction caro economico medio
caro 8 0 0
economico 2 1010 0
medio 0 0 439
##
Overall Statistics
##
Accuracy : 0.9986
95% CI : (0.9951, 0.9998)
No Information Rate : 0.6923
P-Value [Acc > NIR] : < 2.2e-16
##
Kappa : 0.9968
##
Mcnemar's Test P-Value : NA
##
Statistics by Class:
##
Class: caro Class: economico Class: medio
Sensitivity 0.800000 1.0000 1.0000
Specificity 1.000000 0.9955 1.0000
Pos Pred Value 1.000000 0.9980 1.0000
Neg Pred Value 0.998622 1.0000 1.0000
Prevalence 0.006854 0.6923 0.3009
Detection Rate 0.005483 0.6923 0.3009
Detection Prevalence 0.005483 0.6936 0.3009
Balanced Accuracy 0.900000 0.9978 1.0000

```

Primero que nada, se observa que el modelo pudo predecir como se puede observar un porcentaje de 99.68%. Las predicciones para las clases economico y medio son casi perfectas, mientras que la clase caro muestra una leve disminución en la sensibilidad (80%), pero sigue siendo un buen resultado. La alta precisión y Kappa indican que el modelo está sobreajustado.

11. Compare la eficiencia del modelo anterior con los de clasificación de las entregas anteriores ¿Cuál se demoró más en procesar? ¿Cuál se equivocó más? ¿Cuál se equivocó menos? ¿por qué?

```
[1] "Training time: 20.5764999389648"
```

De la entrega 2 del proyecto 2 se observa en terminos de tiempo de ejecución que este es el algoritmo más tardado a comparación de los modelos cruzados y no cruzados en las cuales toman un rango de tiempo de 2 a 10 segundos. En cuanto a los modelos que más se equivocaron se observa que el modelo knn tiene un porcentaje de precisión de 74.66%. Aunque se ve que hay otros modelos que estan cerca del rango de 90% a 100% como Bayes se observa que este es el mejor modelo.

# Avances2.7

Andre Jo 22199, Nelson Escalante 22046

2025-05-03

## Introducción

En el presente trabajo, se tiene como objetivo construir y evaluar modelos predictivos utilizando el algoritmo de Máquinas de Vectores de Soporte (SVM) para clasificar propiedades inmobiliarias según su precio en tres categorías: barata, media y cara. Para ello, se emplearán los mismos conjuntos de datos de entrenamiento y prueba utilizados en trabajos previos, asegurando la consistencia en las evaluaciones.

En primer lugar, se realizará un análisis exploratorio de los datos para identificar las transformaciones necesarias y garantizar que las características sean adecuadas para el entrenamiento del modelo SVM. Se utilizará como variable de respuesta una categorización del precio de las casas, lo que permitirá desarrollar un modelo de clasificación.

A continuación, se llevará a cabo una exploración general de los datos, utilizando herramientas como las cajas de bigote para visualizar la distribución de las variables y detectar posibles valores atípicos.

```
Id SalePrice economico medio caro
1 1461 169277.1 1 0 0
2 1462 187758.4 0 1 0
3 1463 183583.7 1 0 0
4 1464 179317.5 1 0 0
5 1465 150730.1 1 0 0
6 1466 177151.0 1 0 0

Id MSSubClass MSZoning LotFrontage LotArea Street Alley LotShape LandContour
1 1 60 RL 65 8450 Pave <NA> Reg Lvl
2 2 20 RL 80 9600 Pave <NA> Reg Lvl
3 3 60 RL 68 11250 Pave <NA> IR1 Lvl
4 4 70 RL 60 9550 Pave <NA> IR1 Lvl
5 5 60 RL 84 14260 Pave <NA> IR1 Lvl
6 6 50 RL 85 14115 Pave <NA> IR1 Lvl
Utilities LotConfig LandSlope Neighborhood Condition1 Condition2 BldgType
1 AllPub Inside Gtl CollgCr Norm Norm 1Fam
2 AllPub FR2 Gtl Veenker Feedr Norm 1Fam
3 AllPub Inside Gtl CollgCr Norm Norm 1Fam
4 AllPub Corner Gtl Crawfor Norm Norm 1Fam
5 AllPub FR2 Gtl NoRidge Norm Norm 1Fam
6 AllPub Inside Gtl Mitchel Norm Norm 1Fam
HouseStyle OverallQual OverallCond YearBuilt YearRemodAdd RoofStyle RoofMatl
1 2Story 7 5 2003 2003 Gable CompShg
2 1Story 6 8 1976 1976 Gable CompShg
3 2Story 7 5 2001 2002 Gable CompShg
4 2Story 7 5 1915 1970 Gable CompShg
5 2Story 8 5 2000 2000 Gable CompShg
6 1.5Fin 5 5 1993 1995 Gable CompShg
Exterior1st Exterior2nd MasVnrType MasVnrArea ExterQual ExterCond Foundation
```

## 1	VinylSd	VinylSd	BrkFace	196	Gd	TA	PConc
## 2	MetalSd	MetalSd	None	0	TA	TA	CBlock
## 3	VinylSd	VinylSd	BrkFace	162	Gd	TA	PConc
## 4	Wd Sdng	Wd Shng	None	0	TA	TA	BrkTil
## 5	VinylSd	VinylSd	BrkFace	350	Gd	TA	PConc
## 6	VinylSd	VinylSd	None	0	TA	TA	Wood
##	BsmtQual	BsmtCond	BsmtExposure	BsmtFinType1	BsmtFinSF1	BsmtFinType2	
## 1	Gd	TA	No	GLQ	706	Unf	
## 2	Gd	TA	Gd	ALQ	978	Unf	
## 3	Gd	TA	Mn	GLQ	486	Unf	
## 4	TA	Gd	No	ALQ	216	Unf	
## 5	Gd	TA	Av	GLQ	655	Unf	
## 6	Gd	TA	No	GLQ	732	Unf	
##	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	Heating	HeatingQC	CentralAir	Electrical
## 1	0	150	856	GasA	Ex	Y	SBrkr
## 2	0	284	1262	GasA	Ex	Y	SBrkr
## 3	0	434	920	GasA	Ex	Y	SBrkr
## 4	0	540	756	GasA	Gd	Y	SBrkr
## 5	0	490	1145	GasA	Ex	Y	SBrkr
## 6	0	64	796	GasA	Ex	Y	SBrkr
##	X1stFlrSF	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	BsmtHalfBath	FullBath
## 1	856	854	0	1710	1	0	2
## 2	1262	0	0	1262	0	1	2
## 3	920	866	0	1786	1	0	2
## 4	961	756	0	1717	1	0	1
## 5	1145	1053	0	2198	1	0	2
## 6	796	566	0	1362	1	0	1
##	HalfBath	BedroomAbvGr	KitchenAbvGr	KitchenQual	TotRmsAbvGrd	Functional	
## 1	1	3	1	Gd	8	Typ	
## 2	0	3	1	TA	6	Typ	
## 3	1	3	1	Gd	6	Typ	
## 4	0	3	1	Gd	7	Typ	
## 5	1	4	1	Gd	9	Typ	
## 6	1	1	1	TA	5	Typ	
##	Fireplaces	FireplaceQu	GarageType	GarageYrBlt	GarageFinish	GarageCars	
## 1	0	<NA>	Attchd	2003	RFn	2	
## 2	1	TA	Attchd	1976	RFn	2	
## 3	1	TA	Attchd	2001	RFn	2	
## 4	1	Gd	Detchd	1998	Unf	3	
## 5	1	TA	Attchd	2000	RFn	3	
## 6	0	<NA>	Attchd	1993	Unf	2	
##	GarageArea	GarageQual	GarageCond	PavedDrive	WoodDeckSF	OpenPorchSF	
## 1	548	TA	TA	Y	0	61	
## 2	460	TA	TA	Y	298	0	
## 3	608	TA	TA	Y	0	42	
## 4	642	TA	TA	Y	0	35	
## 5	836	TA	TA	Y	192	84	
## 6	480	TA	TA	Y	40	30	
##	EnclosedPorch	X3SsnPorch	ScreenPorch	PoolArea	PoolQC	Fence	MiscFeature
## 1	0	0	0	0	<NA>	<NA>	<NA>
## 2	0	0	0	0	<NA>	<NA>	<NA>
## 3	0	0	0	0	<NA>	<NA>	<NA>
## 4	272	0	0	0	<NA>	<NA>	<NA>
## 5	0	0	0	0	<NA>	<NA>	<NA>

```

6 0 320 0 0 <NA> MnPrv Shed
MiscVal MoSold YrSold SaleType SaleCondition SalePrice economico medio caro
1 0 2 2008 WD Normal 208500 1 0 0
2 0 5 2007 WD Normal 181500 1 0 0
3 0 9 2008 WD Normal 223500 1 0 0
4 0 2 2006 WD Abnorml 140000 1 0 0
5 0 12 2008 WD Normal 250000 1 0 0
6 700 10 2009 WD Normal 143000 1 0 0

Id MSSubClass MSZoning LotFrontage
Min. :1461 Min. : 20.00 Length:1459 Min. : 21.00
1st Qu.:1826 1st Qu.: 20.00 Class :character 1st Qu.: 58.00
Median :2190 Median : 50.00 Mode :character Median : 67.00
Mean :2190 Mean : 57.38 Mean : 68.58
3rd Qu.:2554 3rd Qu.: 70.00 3rd Qu.: 80.00
Max. :2919 Max. :190.00 Max. :200.00
NA's :227

LotArea Street Alley LotShape
Min. : 1470 Length:1459 Length:1459 Length:1459
1st Qu.: 7391 Class :character Class :character Class :character
Median : 9399 Mode :character Mode :character Mode :character
Mean : 9819
3rd Qu.:11518
Max. :56600

##
LandContour Utilities LotConfig LandSlope
Length:1459 Length:1459 Length:1459 Length:1459
Class :character Class :character Class :character Class :character
Mode :character Mode :character Mode :character Mode :character
##
##
##
##
Neighborhood Condition1 Condition2 BldgType
Length:1459 Length:1459 Length:1459 Length:1459
Class :character Class :character Class :character Class :character
Mode :character Mode :character Mode :character Mode :character
##
##
##
##
HouseStyle OverallQual OverallCond YearBuilt
Length:1459 Min. : 1.000 Min. :1.000 Min. :1879
Class :character 1st Qu.: 5.000 1st Qu.:5.000 1st Qu.:1953
Mode :character Median : 6.000 Median :5.000 Median :1973
Mean : 6.079 Mean :5.554 Mean :1971
3rd Qu.: 7.000 3rd Qu.:6.000 3rd Qu.:2001
Max. :10.000 Max. :9.000 Max. :2010
##
##
YearRemodAdd RoofStyle RoofMatl Exterior1st
Min. :1950 Length:1459 Length:1459 Length:1459
1st Qu.:1963 Class :character Class :character Class :character
Median :1992 Mode :character Mode :character Mode :character
Mean :1984

```

```

3rd Qu.:2004
Max. :2010
##
Exterior2nd MasVnrType MasVnrArea ExterQual
Length:1459 Length:1459 Min. : 0.0 Length:1459
Class :character Class :character 1st Qu.: 0.0 Class :character
Mode :character Mode :character Median : 0.0 Mode :character
##
Mean : 100.7
3rd Qu.: 164.0
Max. :1290.0
NA's :15
##
ExterCond Foundation BsmtQual BsmtCond
Length:1459 Length:1459 Length:1459 Length:1459
Class :character Class :character Class :character Class :character
Mode :character Mode :character Mode :character Mode :character
##
##
##
##
BsmtExposure BsmtFinType1 BsmtFinSF1 BsmtFinType2
Length:1459 Length:1459 Min. : 0.0 Length:1459
Class :character Class :character 1st Qu.: 0.0 Class :character
Mode :character Mode :character Median : 350.5 Mode :character
##
Mean : 439.2
3rd Qu.: 753.5
Max. :4010.0
NA's :1
##
BsmtFinSF2 BsmtUnfSF TotalBsmtSF Heating
Min. : 0.00 Min. : 0.0 Min. : 0 Length:1459
1st Qu.: 0.00 1st Qu.: 219.2 1st Qu.: 784 Class :character
Median : 0.00 Median : 460.0 Median : 988 Mode :character
Mean : 52.62 Mean : 554.3 Mean :1046
3rd Qu.: 0.00 3rd Qu.: 797.8 3rd Qu.:1305
Max. :1526.00 Max. :2140.0 Max. :5095
NA's :1 NA's :1 NA's :1
##
HeatingQC CentralAir Electrical X1stFlrSF
Length:1459 Length:1459 Length:1459 Min. : 407.0
Class :character Class :character Class :character 1st Qu.: 873.5
Mode :character Mode :character Mode :character Median :1079.0
##
Mean :1156.5
3rd Qu.:1382.5
Max. :5095.0
##
##
X2ndFlrSF LowQualFinSF GrLivArea BsmtFullBath
Min. : 0 Min. : 0.000 Min. : 407 Min. :0.0000
1st Qu.: 0 1st Qu.: 0.000 1st Qu.:1118 1st Qu.:0.0000
Median : 0 Median : 0.000 Median :1432 Median :0.0000
Mean : 326 Mean : 3.544 Mean :1486 Mean :0.4345
3rd Qu.: 676 3rd Qu.: 0.000 3rd Qu.:1721 3rd Qu.:1.0000
Max. :1862 Max. :1064.000 Max. :5095 Max. :3.0000
##
NA's :2
##
BsmtHalfBath FullBath HalfBath BedroomAbvGr
Min. :0.0000 Min. :0.000 Min. :0.0000 Min. :0.000
1st Qu.:0.0000 1st Qu.:1.000 1st Qu.:0.0000 1st Qu.:2.000

```

```

Median :0.0000 Median :2.000 Median :0.0000 Median :3.000
Mean :0.0652 Mean :1.571 Mean :0.3777 Mean :2.854
3rd Qu.:0.0000 3rd Qu.:2.000 3rd Qu.:1.0000 3rd Qu.:3.000
Max. :2.0000 Max. :4.000 Max. :2.0000 Max. :6.000
NA's :2
KitchenAbvGr KitchenQual TotRmsAbvGrd Functional
Min. :0.000 Length:1459 Min. : 3.000 Length:1459
1st Qu.:1.000 Class :character 1st Qu.: 5.000 Class :character
Median :1.000 Mode :character Median : 6.000 Mode :character
Mean :1.042 Mean : 6.385
3rd Qu.:1.000 3rd Qu.: 7.000
Max. :2.000 Max. :15.000
##
Fireplaces FireplaceQu GarageType GarageYrBlt
Min. :0.0000 Length:1459 Length:1459 Min. :1895
1st Qu.:0.0000 Class :character Class :character 1st Qu.:1959
Median :0.0000 Mode :character Mode :character Median :1979
Mean :0.5812 Mean :1978
3rd Qu.:1.0000 3rd Qu.:2002
Max. :4.0000 Max. :2207
NA's :78
GarageFinish GarageCars GarageArea GarageQual
Length:1459 Min. :0.000 Min. : 0.0 Length:1459
Class :character 1st Qu.:1.000 1st Qu.: 318.0 Class :character
Mode :character Median :2.000 Median : 480.0 Mode :character
Mean :1.766 Mean : 472.8
3rd Qu.:2.000 3rd Qu.: 576.0
Max. :5.000 Max. :1488.0
NA's :1 NA's :1
GarageCond PavedDrive WoodDeckSF OpenPorchSF
Length:1459 Length:1459 Min. : 0.00 Min. : 0.00
Class :character Class :character 1st Qu.: 0.00 1st Qu.: 0.00
Mode :character Mode :character Median : 0.00 Median : 28.00
Mean : 93.17 Mean : 48.31
3rd Qu.:168.00 3rd Qu.: 72.00
Max. :1424.00 Max. :742.00
##
EnclosedPorch X3SsnPorch ScreenPorch PoolArea
Min. : 0.00 Min. : 0.000 Min. : 0.00 Min. : 0.000
1st Qu.: 0.00 1st Qu.: 0.000 1st Qu.: 0.00 1st Qu.: 0.000
Median : 0.00 Median : 0.000 Median : 0.00 Median : 0.000
Mean : 24.24 Mean : 1.794 Mean :17.06 Mean : 1.744
3rd Qu.: 0.00 3rd Qu.: 0.000 3rd Qu.: 0.00 3rd Qu.: 0.000
Max. :1012.00 Max. :360.000 Max. :576.00 Max. :800.000
##
PoolQC Fence MiscFeature MiscVal
Length:1459 Length:1459 Length:1459 Min. : 0.00
Class :character Class :character Class :character 1st Qu.: 0.00
Mode :character Mode :character Mode :character Median : 0.00
Mean : 58.17
3rd Qu.: 0.00
Max. :17000.00
##
MoSold YrSold SaleType SaleCondition

```


```

Min. : 1.000 Min. :2006 Length:1459 Length:1459
1st Qu.: 4.000 1st Qu.:2007 Class :character Class :character
Median : 6.000 Median :2008 Mode :character Mode :character
Mean : 6.104 Mean :2008
3rd Qu.: 8.000 3rd Qu.:2009
Max. :12.000 Max. :2010
##


Id SalePrice economico medio
Min. :1461 Min. :135751 Min. :0.0000 Min. :0.0000
1st Qu.:1826 1st Qu.:168703 1st Qu.:0.0000 1st Qu.:0.0000
Median :2190 Median :179209 Median :1.0000 Median :0.0000
Mean :2190 Mean :179184 Mean :0.6923 Mean :0.3009
3rd Qu.:2554 3rd Qu.:186789 3rd Qu.:1.0000 3rd Qu.:1.0000
Max. :2919 Max. :281644 Max. :1.0000 Max. :1.0000
##
caro category
Min. :0.000000 Length:1459
1st Qu.:0.000000 Class :character
Median :0.000000 Mode :character
Mean :0.006854
3rd Qu.:0.000000
Max. :1.000000

```


Se observa que utilizamos para la variable objetivo tres categorías, economico, caro y medio donde primero calculamos el valor de la casa máxima y el mínimo valor de la casa donde luego lo restamos el valor máximo con el mínimo y luego dividirlo entre tres para así diferenciar que casa debería de pertenecer en esas tres variables.



Se observa que las casas que tienen una condición de venta “Normal” son las más caras. En comparación, otras casas con diferentes condiciones tienden a ser económicas o de bajo costo. Aunque también se observa que la condición “Family” tiende a presentar un precio medio.



Se observa que las casas con escritura “WD” presentan un mayor rango de precios, concentrándose en viviendas caras y con áreas superiores a los 30,000 m<sup>2</sup>. Sin embargo, también se identifican varios puntos atípicos en este grupo. Por otro lado, las propiedades con escritura tipo “COD” (escritura emitida por un funcionario judicial) tienden a ubicarse en un rango de entre 0 y 20,000 m<sup>2</sup>, con precios mayormente medios y algunos económicos. Finalmente, las viviendas con tipo de venta “ConLI” (contrato con interés bajo) se asocian exclusivamente a casas económicas, sin presencia en los rangos de precio medio o alto.



Se observa en este diagrama de caja y bigotes que la mayoría de las casas clasificadas como “caras” forman parte del tipo de venta “WD”, que corresponde a la transferencia mediante escritura. Por otro lado, las categorías “caro” y “medio” se encuentran en un rango similar, aunque “caro” presenta un rango más amplio. También se puede notar que dentro del criterio “WD” existen casos tanto económicos como de precio medio. Por otro lado, las casas vendidas bajo condiciones de menor interés (como “ConLI”) presentan un mayor volumen de viviendas económicas, lo cual resulta coherente con el tipo de financiación ofrecido.

En base a los datos explorados podemos observar o utilizar ciertas variables para generar el modelo SVM. A continuación se realizarán varios modelos tuneados de SVM para realizar comparaciones ante la eficiencia y exactitud de otros modelos.

```
Cargando paquete requerido: lattice

##
Adjuntando el paquete: 'dplyr'

The following objects are masked from 'package:stats':
##
filter, lag

The following objects are masked from 'package:base':
##
intersect, setdiff, setequal, union

##
##
===== MODELO 1: SVM LINEAL =====

##
===== Resultados para SVM Lineal (C=1) =====
```

```


Precisión en train: 96.38 %
Precisión en test: 95.65 %
Diferencia (train-test): 0.73 % puntos
##
Matriz de confusión (datos de prueba):
Reference
Prediction caro economico medio
caro 2 1 1
economico 0 381 9
medio 0 8 35
##
Diagnóstico: El modelo parece estar bien ajustado
##
##
===== MODELO 2: SVM POLINOMIAL =====
##
===== Resultados para SVM Polinomial (grado=2, C=1) =====
Precisión en train: 95.21 %
Precisión en test: 94.51 %
Diferencia (train-test): 0.7 % puntos
##
Matriz de confusión (datos de prueba):
Reference
Prediction caro economico medio
caro 0 1 1
economico 1 383 14
medio 1 6 30
##
Diagnóstico: El modelo parece estar bien ajustado
##
##
===== MODELO 3: SVM RADIAL =====
##
===== Resultados para SVM Radial (gamma=0.1, C=1) =====
Precisión en train: 97.07 %
Precisión en test: 94.97 %
Diferencia (train-test): 2.1 % puntos
##
Matriz de confusión (datos de prueba):
Reference
Prediction caro economico medio
caro 0 0 0
economico 0 382 12
medio 2 8 33
##
Diagnóstico: El modelo parece estar bien ajustado
##
##
===== MODELO 4: SVM RADIAL CON MAYOR REGULARIZACIÓN =====
##
===== Resultados para SVM Radial Regularizado (gamma=0.01, C=0.5) =====


```

```
Precisión en train: 94.92 %
Precisión en test: 95.42 %
Diferencia (train-test): -0.51 % puntos
##
Matriz de confusión (datos de prueba):
Reference
Prediction caro economico medio
caro 0 0 0
economico 0 383 11
medio 2 7 34
##
Diagnóstico: El modelo parece estar bien ajustado
```

En todos los modelos, las equivocaciones parecen ser entre las casas economicas y las de precio medio. Todos estas equivocaciones son leves, ya que los precios que comprenden estas categorias son bastante cercanos, por lo cual equivocaciones en estos campos. Para las casas caras, los modelos parecen tener equivocaciones entre las casas caras y medias. El unico modelo que fue capaz de identificar correctamente las casas caras fue el SMV linear con  $c = 1$ .

	Modelo	Precisión_Train	Precisión_Test	Diferencia
## 1	SVM Lineal	0.9638319	0.9565217	0.007310128
## 2	SVM Polinomial	0.9521017	0.9450801	0.007021570
## 3	SVM Radial	0.9706745	0.9496568	0.021017736
## 4	SVM Radial Regularizado	0.9491691	0.9542334	-0.005064299





## El mejor modelo según precisión en validación es: SVM Lineal

Todos los modelos parecen tener una precisión demasiado alta, lo que podría ser indicador de sobreajuste, pero el modelo con la mayor diferencia de precisión (y la precisión más alta) parece ser el SVM Radial. Para manejar posibles sobreajustes se podría:


- Reducir la complejidad del modelo (con menor gamma o grado polinomial)
- Aumentar la regularización
- Reducir el número de variables predictoras
- Usar validación cruzada

Al observar la eficiencia de diferentes modelos podemos notar que hay algunos más eficientes que el modelo SVM pero, el modelo SVM se puede realizar un tuneo con la finalidad de observar si es más eficiente o mejor que otros modelos. A continuación se realizará el tuneo de SVM lineal y realizar la comparación ante modelos como KNN, naive Bayes con el criterio del menor RMSE.

## [1] 70803.9


Al normalizar los datos y reemplazar valores NA's observamos que el RMSE del modelo SVM lineal está en los rangos adecuados de otros modelos pero se observa en un momento que este no es un modelo con el menor RMSE.

### Comparación: Valores Reales vs. Predicciones



Como se muestra en la gráfica, observamos que los valores predicho se acercan más a los valores reales y confirme se observa este es el mejor para realizar comparación ante valores reales y predichos que otros modelos.

### Comparación: Valores Reales vs. Predicciones




Se observa en la gráfica del modelo KNN que hay algunos puntos que si pudo predecir y además no hay evidencia de sobreajuste. Pero, se observa que el modelo SVM lineal es el mejor al realizar predicciones.

```
RMSE(predModelo3, datos$SalePrice)
```

```
[1] 62053.9
```

Observamos que KNN tiene el menor RMSE de los modelos a analizar. Este modelo puede ser el menor RMSE de los modelos pero no haya mejor gráfica que SVM lineal.

El modelo a utilizar es Naive Bayes donde a continuación se presentara la gráfica y su RMSE.




Se observa en la gráfica que no es un modelo tan optimo ya que presenta algunos datos con sobreajuste pero existen otros datos que no están sobreajustados.

```
RMSE(predBayes, datos$SalePrice)
```

```
[1] 70237.08
```

Por otro lado vemos que el RMSE es menor que SVM lineal. Aunque no es uno de los mejores modelos, en el siguiente modelo a comparar observamos el mayor RMSE y sobreajuste de datos.




El modelo presentado es un árbol de decisión en la cual tenemos 4 niveles de comparación. Además en se observa que RMSE es el mayor de todos los modelos presentados.

## [1] 77161.11

se observa que el rmse del modelo de prueba es de 77161.11 lo cual sus valores son muy altos lo cual puede indicar un overfitting de los datos como se muestra en la siguiente gráfica.

## Predicciones vs valores originales




Se observa en la gráfica y efectivamente se puede respaldar el overfitting en los datos, como se observa con los puntos rojos, se observa líneas de puntos mientras que en los puntos azules se van esparciendo no como la línea de puntos rojos.

```
fitLMPW<-lm(SalePrice~LotArea, data = train_data)
```

```
ggplot(data = train_data, mapping = aes(x = SalePrice, y = LotArea)) +
 geom_point(color = "firebrick", size = 2) +
 geom_smooth(method = "lm", se = TRUE, color = "black") +
 labs(title = "Precio Casas ~ Area del lote", x = "Precio", y = "Area") +
 theme_bw() + theme(plot.title = element_text(hjust = 0.5))
```

```
`geom_smooth()` using formula = 'y ~ x'
```



Usando esta ecuación podemos predecir la Venta de casa para el conjunto de prueba.

```
predL<-predict(fitLMPW, newdata = datos)
```

Al sacar la predicción observamos que este modelo tiene un RMSE muy alto lo cual podemos argumentar y analizar con las siguientes gráficas.

```
RMSE(predL, price$SalePrice)
```

```
[1] 11620.85
```

```
head(predL)
```

```
1 2 3 4 5 6
183242.0 188796.5 187878.8 179789.7 169346.5 179835.9
```

```
length(predL)
```

```
[1] 1459
```


Para saber que tan bueno es el modelo para predecir dados los datos de entrenamiento se deben analizar los residuos. Estos no pueden seguir ningún patrón, es decir que deben ser aleatorios alrededor de 0. Deben estar distribuidos normalmente.


```
head(fitLMPW$residuals)
```


```
1 2 3 4 5 6
31919.085 2504.117 41039.164 -38890.884 61218.248 -45477.256
```


En los siguientes gráficos se pueden analizar los residuales.

```
plot(fitLMPW)
```











En el gráfico *Residuals vs Fitted* se puede ver que no parece haber un patrón y que los puntos están aleatoriamente distribuidos alrededor de 0.

```
hist(fitLMPW$residuals)
```


**Histogram of fitLMPW\$residuals**



```
boxplot(fitLMPW$residuals)
```



```
qqnorm(fitLMPW$residuals)
qqline(fitLMPW$residuals, col="red")
```



Se observa con el histograma que los datos están distribuidos de manera aproximadamente normal, aunque no de forma perfecta. Además, se nota que las colas del QQ plot no están alineadas con la línea de tendencia, lo cual podría indicar un sobreajuste en los modelos, lo que se puede observar en ciertos modelos, como el árbol de regresión. Por otro lado, en el diagrama de cajas de bigote se pueden identificar dos datos atípicos, los cuales podrían representar ventas de casas en ocasiones raras. Por lo tanto en breve se presentarán las conclusiones a realizar en todos los modelos realizado, comparaciones, eficiencia, entre otros aspectos.

En conclusión, tras evaluar los diferentes modelos de regresión, se observa que el modelo de KNN presenta un bajo valor de RMSE, lo que indica una buena precisión en sus predicciones. Sin embargo, al analizar la dispersión de los puntos predichos frente a los valores reales, se puede notar que el modelo de SVM lineal tiene los puntos más cercanos a los valores reales en comparación con el KNN, lo que sugiere una mejor capacidad de generalización. En contraste, otros modelos presentaron signos de sobreajuste o un RMSE elevado, lo que indica que no lograron generalizar bien los datos.

```
Id SalePrice economico medio caro
1 1461 169277.1 1 0 0
2 1462 187758.4 0 1 0
3 1463 183583.7 1 0 0
4 1464 179317.5 1 0 0
5 1465 150730.1 1 0 0
6 1466 177151.0 1 0 0
```

```
Id MSSubClass MSZoning LotFrontage LotArea Street Alley LotShape LandContour
1 1 60 RL 65 8450 Pave <NA> Reg Lvl
2 2 20 RL 80 9600 Pave <NA> Reg Lvl
3 3 60 RL 68 11250 Pave <NA> IR1 Lvl
4 4 70 RL 60 9550 Pave <NA> IR1 Lvl
5 5 60 RL 84 14260 Pave <NA> IR1 Lvl
```

## 6	6	50	RL	85	14115	Pave	<NA>	IR1	Lvl
##	Utilities	LotConfig	LandSlope	Neighborhood	Condition1	Condition2	BldgType		
## 1	AllPub	Inside	Gtl	CollgCr	Norm	Norm	1Fam		
## 2	AllPub	FR2	Gtl	Veenker	Feedr	Norm	1Fam		
## 3	AllPub	Inside	Gtl	CollgCr	Norm	Norm	1Fam		
## 4	AllPub	Corner	Gtl	Crawfor	Norm	Norm	1Fam		
## 5	AllPub	FR2	Gtl	NoRidge	Norm	Norm	1Fam		
## 6	AllPub	Inside	Gtl	Mitchel	Norm	Norm	1Fam		
##	HouseStyle	OverallQual	OverallCond	YearBuilt	YearRemodAdd	RoofStyle	RoofMatl		
## 1	2Story	7	5	2003	2003	Gable	CompShg		
## 2	1Story	6	8	1976	1976	Gable	CompShg		
## 3	2Story	7	5	2001	2002	Gable	CompShg		
## 4	2Story	7	5	1915	1970	Gable	CompShg		
## 5	2Story	8	5	2000	2000	Gable	CompShg		
## 6	1.5Fin	5	5	1993	1995	Gable	CompShg		
##	Exterior1st	Exterior2nd	MasVnrType	MasVnrArea	ExterQual	ExterCond	Foundation		
## 1	VinylSd	VinylSd	BrkFace	196	Gd	TA	PConc		
## 2	MetalSd	MetalSd	None	0	TA	TA	CBlock		
## 3	VinylSd	VinylSd	BrkFace	162	Gd	TA	PConc		
## 4	Wd Sdng	Wd Shng	None	0	TA	TA	BrkTil		
## 5	VinylSd	VinylSd	BrkFace	350	Gd	TA	PConc		
## 6	VinylSd	VinylSd	None	0	TA	TA	Wood		
##	BsmtQual	BsmtCond	BsmtExposure	BsmtFinType1	BsmtFinSF1	BsmtFinType2			
## 1	Gd	TA	No	GLQ	706	Unf			
## 2	Gd	TA	Gd	ALQ	978	Unf			
## 3	Gd	TA	Mn	GLQ	486	Unf			
## 4	TA	Gd	No	ALQ	216	Unf			
## 5	Gd	TA	Av	GLQ	655	Unf			
## 6	Gd	TA	No	GLQ	732	Unf			
##	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	Heating	HeatingQC	CentralAir	Electrical		
## 1	0	150	856	GasA	Ex	Y	SBrkr		
## 2	0	284	1262	GasA	Ex	Y	SBrkr		
## 3	0	434	920	GasA	Ex	Y	SBrkr		
## 4	0	540	756	GasA	Gd	Y	SBrkr		
## 5	0	490	1145	GasA	Ex	Y	SBrkr		
## 6	0	64	796	GasA	Ex	Y	SBrkr		
##	X1stFlrSF	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	BsmtHalfBath	FullBath		
## 1	856	854	0	1710	1	0	2		
## 2	1262	0	0	1262	0	1	2		
## 3	920	866	0	1786	1	0	2		
## 4	961	756	0	1717	1	0	1		
## 5	1145	1053	0	2198	1	0	2		
## 6	796	566	0	1362	1	0	1		
##	HalfBath	BedroomAbvGr	KitchenAbvGr	KitchenQual	TotRmsAbvGrd	Functional			
## 1	1	3	1	Gd	8	Typ			
## 2	0	3	1	TA	6	Typ			
## 3	1	3	1	Gd	6	Typ			
## 4	0	3	1	Gd	7	Typ			
## 5	1	4	1	Gd	9	Typ			
## 6	1	1	1	TA	5	Typ			
##	Fireplaces	FireplaceQu	GarageType	GarageYrBlt	GarageFinish	GarageCars			
## 1	0	<NA>	Attchd	2003	RFn	2			
## 2	1	TA	Attchd	1976	RFn	2			
## 3	1	TA	Attchd	2001	RFn	2			

```

4 1 Gd Detchd 1998 Unf 3
5 1 TA Attchd 2000 RFn 3
6 0 <NA> Attchd 1993 Unf 2
GarageArea GarageQual GarageCond PavedDrive WoodDeckSF OpenPorchSF
1 548 TA TA Y 0 61
2 460 TA TA Y 298 0
3 608 TA TA Y 0 42
4 642 TA TA Y 0 35
5 836 TA TA Y 192 84
6 480 TA TA Y 40 30
EnclosedPorch X3SsnPorch ScreenPorch PoolArea PoolQC Fence MiscFeature
1 0 0 0 0 <NA> <NA> <NA>
2 0 0 0 0 <NA> <NA> <NA>
3 0 0 0 0 <NA> <NA> <NA>
4 272 0 0 0 <NA> <NA> <NA>
5 0 0 0 0 <NA> <NA> <NA>
6 0 320 0 0 <NA> MnPrv Shed
MiscVal MoSold YrSold SaleType SaleCondition SalePrice economico medio caro
1 0 2 2008 WD Normal 208500 1 0 0
2 0 5 2007 WD Normal 181500 1 0 0
3 0 9 2008 WD Normal 223500 1 0 0
4 0 2 2006 WD Abnorml 140000 1 0 0
5 0 12 2008 WD Normal 250000 1 0 0
6 700 10 2009 WD Normal 143000 1 0 0
category
1 economico
2 economico
3 economico
4 economico
5 economico
6 economico

```

Se realiza la eliminación de datos NA´s dentro del dataset con la finalidad de tener más precisión y exactitud en los modelos.

```

Id MSSubClass MSZoning LotFrontage LotArea Street Alley LotShape
1 1461 20 RH 80 11622 Pave Grvl Reg
2 1462 20 RL 81 14267 Pave Grvl IR1
3 1463 60 RL 74 13830 Pave Grvl IR1
4 1464 60 RL 78 9978 Pave Grvl IR1
5 1465 120 RL 43 5005 Pave Grvl IR1
6 1466 60 RL 75 10000 Pave Grvl IR1
LandContour Utilities LotConfig LandSlope Neighborhood Condition1 Condition2
1 Lvl AllPub Inside Gtl Names Feedr Norm
2 Lvl AllPub Corner Gtl Names Norm Norm
3 Lvl AllPub Inside Gtl Gilbert Norm Norm
4 Lvl AllPub Inside Gtl Gilbert Norm Norm
5 HLS AllPub Inside Gtl StoneBr Norm Norm
6 Lvl AllPub Corner Gtl Gilbert Norm Norm
BldgType HouseStyle OverallQual OverallCond YearBuilt YearRemodAdd RoofStyle
1 1Fam 1Story 5 6 1961 1961 Gable
2 1Fam 1Story 6 6 1958 1958 Hip
3 1Fam 2Story 5 5 1997 1998 Gable
4 1Fam 2Story 6 6 1998 1998 Gable
5 TwnhsE 1Story 8 5 1992 1992 Gable

```

## 6	1Fam	2Story	6	5	1993	1994	Gable
##	RoofMatl	Exterior1st	Exterior2nd	MasVnrType	MasVnrArea	ExterQual	ExterCond
## 1	CompShg	VinylSd	VinylSd	None	0	TA	TA
## 2	CompShg	Wd Sdng	Wd Sdng	BrkFace	108	TA	TA
## 3	CompShg	VinylSd	VinylSd	None	0	TA	TA
## 4	CompShg	VinylSd	VinylSd	BrkFace	20	TA	TA
## 5	CompShg	HdBoard	HdBoard	None	0	Gd	TA
## 6	CompShg	HdBoard	HdBoard	None	0	TA	TA
##	Foundation	BsmtQual	BsmtCond	BsmtExposure	BsmtFinType1	BsmtFinSF1	
## 1	CBlock	TA	TA	No	Rec	468	
## 2	CBlock	TA	TA	No	ALQ	923	
## 3	PConc	Gd	TA	No	GLQ	791	
## 4	PConc	TA	TA	No	GLQ	602	
## 5	PConc	Gd	TA	No	ALQ	263	
## 6	PConc	Gd	TA	No	Unf	0	
##	BsmtFinType2	BsmtFinSF2	BsmtUnfSF	TotalBsmtSF	Heating	HeatingQC	CentralAir
## 1	LwQ	144	270	882	GasA	TA	Y
## 2	Unf	0	406	1329	GasA	TA	Y
## 3	Unf	0	137	928	GasA	Gd	Y
## 4	Unf	0	324	926	GasA	Ex	Y
## 5	Unf	0	1017	1280	GasA	Ex	Y
## 6	Unf	0	763	763	GasA	Gd	Y
##	Electrical	X1stFlrSF	X2ndFlrSF	LowQualFinSF	GrLivArea	BsmtFullBath	
## 1	SBrkr	896	0	0	896	0	
## 2	SBrkr	1329	0	0	1329	0	
## 3	SBrkr	928	701	0	1629	0	
## 4	SBrkr	926	678	0	1604	0	
## 5	SBrkr	1280	0	0	1280	0	
## 6	SBrkr	763	892	0	1655	0	
##	BsmtHalfBath	FullBath	HalfBath	BedroomAbvGr	KitchenAbvGr	KitchenQual	
## 1	0	1	0	2	1	TA	
## 2	0	1	1	3	1	Gd	
## 3	0	2	1	3	1	TA	
## 4	0	2	1	3	1	Gd	
## 5	0	2	0	2	1	Gd	
## 6	0	2	1	3	1	TA	
##	TotRmsAbvGrd	Functional	Fireplaces	FireplaceQu	GarageType	GarageYrBlt	
## 1	5	Typ	0	Gd	Attchd	1961	
## 2	6	Typ	0	Gd	Attchd	1958	
## 3	6	Typ	1	TA	Attchd	1997	
## 4	7	Typ	1	Gd	Attchd	1998	
## 5	5	Typ	0	Gd	Attchd	1992	
## 6	7	Typ	1	TA	Attchd	1993	
##	GarageFinish	GarageCars	GarageArea	GarageQual	GarageCond	PavedDrive	
## 1	Unf	1	730	TA	TA	Y	
## 2	Unf	1	312	TA	TA	Y	
## 3	Fin	2	482	TA	TA	Y	
## 4	Fin	2	470	TA	TA	Y	
## 5	RFn	2	506	TA	TA	Y	
## 6	Fin	2	440	TA	TA	Y	
##	WoodDeckSF	OpenPorchSF	EnclosedPorch	X3SsnPorch	ScreenPorch	PoolArea	PoolQC
## 1	140	0	0	0	120	0	Ex
## 2	393	36	0	0	0	0	Ex
## 3	212	34	0	0	0	0	Ex

```

4 360 36 0 0 0 0 Ex
5 0 82 0 0 144 0 Ex
6 157 84 0 0 0 0 Ex
Fence MiscFeature MiscVal MoSold YrSold SaleType SaleCondition SalePrice
1 MnPrv Shed 0 6 2010 WD Normal 169277.1
2 MnPrv Gar2 12500 6 2010 WD Normal 187758.4
3 MnPrv Shed 0 3 2010 WD Normal 183583.7
4 MnPrv Shed 0 6 2010 WD Normal 179317.5
5 MnPrv Shed 0 1 2010 WD Normal 150730.1
6 MnPrv Shed 0 4 2010 WD Normal 177151.0
economico medio caro category
1 1 0 0 economico
2 0 1 0 medio
3 1 0 0 economico
4 1 0 0 economico
5 1 0 0 economico
6 1 0 0 economico

Confusion Matrix and Statistics
##
Reference
Prediction economico medio caro
economico 1010 436 3
medio 0 3 7
caro 0 0 0
##
Overall Statistics
##
Accuracy : 0.6943
95% CI : (0.67, 0.7179)
No Information Rate : 0.6923
P-Value [Acc > NIR] : 0.445
##
Kappa : 0.0153
##
Mcnemar's Test P-Value : <2e-16
##
Statistics by Class:
##
Class: economico Class: medio Class: caro
Sensitivity 1.00000 0.006834 0.000000
Specificity 0.02227 0.993137 1.000000
Pos Pred Value 0.69703 0.300000 NaN
Neg Pred Value 1.00000 0.699103 0.993146
Prevalence 0.69225 0.300891 0.006854
Detection Rate 0.69225 0.002056 0.000000
Detection Prevalence 0.99315 0.006854 0.000000
Balanced Accuracy 0.51114 0.499985 0.500000

```

Se observa a continuación que el modelo obtuvo una exactitud de 69.36%, esta cifra no puede ser tan cierto ya que el modelo prácticamente predice todas las observaciones como pertenecientes a la clase económico. Además, observamos que la métrica Kappa está cercana a cero lo cual respalda con la teoría. Por otro lado existe un rendimiento nulo en la predicción de las clases “medio” y “caro”. Puede ser que haya una fuerte desbalance de clases debido a que hay varias variables predictoras.

```

Confusion Matrix and Statistics
##
Reference
Prediction 1 2 3
1 0 0 0
2 10 1010 439
3 0 0 0
##
Overall Statistics
##
Accuracy : 0.6923
95% CI : (0.6679, 0.7159)
No Information Rate : 0.6923
P-Value [Acc > NIR] : 0.5128
##
Kappa : 0
##
McNemar's Test P-Value : NA
##
Statistics by Class:
##
Class: 1 Class: 2 Class: 3
Sensitivity 0.000000 1.0000 0.0000
Specificity 1.000000 0.0000 1.0000
Pos Pred Value NaN 0.6923 NaN
Neg Pred Value 0.993146 NaN 0.6991
Prevalence 0.006854 0.6923 0.3009
Detection Rate 0.000000 0.6923 0.0000
Detection Prevalence 0.000000 1.0000 0.0000
Balanced Accuracy 0.500000 0.5000 0.5000

```

Se observa a continuación que el modelo y el modelo anterior tuvieron una exactitud cercana a 69% ya que se debe al desbalance en la variable objetivo. La mayoría de las predicciones son asignadas a la clase “económico”, lo cual refleja un modelo sesgado hacia la clase que tiene la mayoría de los datos. La métrica Kappa cercana a cero respalda que el modelo no logra una clasificación útil más allá de lo que se obtendría por azar. Como había mencionado con anterioridad, esto se debe al desbalance en los datos donde representa que la mayoría de los datos son económicos.

La baja exactitud de los modelos muestra que estos no cuentan con sobreajuste, si no que están mal ajustados y tienen desbalance en la información.

Para mejorar el muestreo se realizarán tuneos para el primer modelo (caret).

Una vez utilizado la variable respuesta category, seleccionaremos la variable SalePrice para comparar si tiene una mejor exactitud el modelo con otros modelos que utilizamos para la variable respuesta SalePrice.

```

An R interface to Weka class
'weka.classifiers.functions.MultilayerPerceptron', which has
information
##
A classifier that uses backpropagation to learn a multi-layer
perceptron to classify instances. The network can be built by hand or
or set up using a simple heuristic. The network parameters can also
be monitored and modified during training time. The nodes in this
network are all sigmoid (except for when the class is numeric, in
which case the output nodes become unthresholded linear units).

```

```

##
Argument list:
(formula, data, subset, na.action, control = Weka_control(),
options = NULL)
##
Returns objects inheriting from classes:
Weka_classifier

-L <learning rate>
Learning rate for the backpropagation algorithm. (Value should
be between 0 - 1, Default = 0.3).
Number of arguments: 1.
-M <momentum>
Momentum rate for the backpropagation algorithm. (Value should
be between 0 - 1, Default = 0.2).
Number of arguments: 1.
-N <number of epochs>
Number of epochs to train through. (Default = 500).
Number of arguments: 1.
-V <percentage size of validation set>
Percentage size of validation set to use to terminate training
(if this is non zero it can preempt num of epochs. (Value
should be between 0 - 100, Default = 0).
Number of arguments: 1.
-S <seed>
The value used to seed the random number generator (Value
should be >= 0 and and a long, Default = 0).
Number of arguments: 1.
-E <threshold for number of consecutive errors>
The number of consecutive increases of error allowed for
validation testing before training terminates. (Value should
be > 0, Default = 20).
Number of arguments: 1.
-G
GUI will be opened. (Use this to bring up a GUI).
-A
Autocreation of the network connections will NOT be done.
(This will be ignored if -G is NOT set)
-B
A NominalToBinary filter will NOT automatically be used. (Set
this to not use a NominalToBinary filter).
-H <comma separated numbers for nodes on each layer>
The hidden layers to be created for the network. (Value should
be a list of comma separated Natural numbers or the letters 'a'
= (attrs + classes) / 2, 'i' = attrs, 'o' = classes, 't' =
attrs .+ classes) for wildcard values, Default = a).
Number of arguments: 1.
-C
Normalizing a numeric class will NOT be done. (Set this to not
normalize the class if it's numeric).
-I
Normalizing the attributes will NOT be done. (Set this to not
normalize the attributes).
-R
Resetting the network will NOT be allowed. (Set this to not
allow the network to reset).
-D
Learning rate decay will occur. (Set this to cause the
learning rate to decay).
-output-debug-info
If set, classifier is run in debug mode and may output

```

```

additional info to the console
-do-not-check-capabilities
If set, classifier capabilities are not checked before
classifier is built (use with caution).
-num-decimal-places
The number of decimal places for the output of numbers in the
model (default 2).
Number of arguments: 1.
-batch-size
The desired batch size for batch prediction (default 100).
Number of arguments: 1.
[1] 75804.77

```


Por otro lado se observa que el RMSE es muy alto a comparación de otros modelos vistos, normalmente otros modelos como los modelos de random Forest, KNN, Bayes entre otros tiene un RMSE típicamente alrededor de 75000 a 33,000. Este modelo llega a predecir entre un rango de 87165.8 a 145701.9

```

weights: 199
initial value 28924961435658.417969
final value 28924828471891.332031
converged
[1] 1.376887

```

se observa que la medición de la variable respuesta SalePrice con el modelo Red neuronal es muy bueno como se puede observar con el RMSE al ser 179942.2 donde es el menor de todos los modelos vistos.



Al observar la curva de aprendizaje, notamos que existe una tendencia donde puede ser que el modelo de red neuronal sea sobreajustado. Inferimos que a medida que aumentamos el error de entrenamiento como el de

validación disminuyen, Sin embargo, al superar aproximadamente el 50-75% de los datos de entrenamiento, comienza a surgir una divergencia notable. El error de entrenamiento continúa su trayectoria descendente, lo que sugiere que el modelo se vuelve cada vez más hábil para ajustarse a los ejemplos de entrenamiento.

```
weights: 67
initial value 29929002479.049370
final value 14957021.489339
converged
[1] 172911.2
```

Se observa que al poner `linout` a `True`, y otros valores menor al modelo anterior, obtenemos que tiene un RMSE aun mejor 16518.62 lo cual es mejor que otros modelos vistos anteriormente. Por lo tanto observamos que para la variable `SalePrice`, entre valores menores sea podriamos inferir que el RMSE sea mejor que los otros modelos neuronales vistos.

Con los modelos anteriores se observa que este modelo al tener más repeticiones se puede demorar más que los otros modelos red neuronales. Por lo tanto el modelo tuneado que tenemos es el más eficiente con respecto a tiempo y menor RMSE. Ahora con la variable categorica, `category` (caro, economico, medio) observamos que no tiene mejor exactitud que otros modelos. Entonces inferimos que no es mejor para variables categoricas.

## Análisis de Algoritmos

### **Comparación de resultados del mejor modelo de clasificación con entregas anteriores**

El mejor modelo que utilizamos fue el de árboles de decisión con profundidad máxima de 5. Este modelo fue bastante efectivo en alcanzar una buena distribución entre las clases y una buena clasificación de los datos, pudiendo interpretar correctamente los rangos de los precios de nuestra variable objetivo.

### **Comparación del mejor modelo para predecir el precio de venta con entregas anteriores**

El mejor modelo para predecir el precio de venta de casas fue un árbol de regresión entrenado con validación cruzada (modelo 8), con una profundidad óptima de 10, que alcanzó un RMSE de aproximadamente 43,921.16 y un  $R^2$  de 0.7085. Esto representa una mejora sustancial frente al modelo de regresión lineal de la entrega anterior, cuyo RMSE fue de 77,161.11, y a otros modelos de árbol sin validación cruzada que oscilaron entre 57,259.84 y 69,556.06. Esta diferencia muestra que el modelo con validación cruzada no solo generaliza mejor, sino que reduce el sobreajuste observado en modelos anteriores, lo cual se corrobora con menores errores en los conjuntos de prueba.

### **Conclusiones generales sobre los mejores modelos para clasificar y predecir precios**

Modelo	Tipo	Profundidad	RMSE (Test)	$R^2$	Observaciones
Regresión lineal (Entrega 1)	Regresión	—	77,161.11	—	Alto error, poco ajuste
Árbol sin cruzar (modelo 1)	Regresión	2	68,109.83	—	Overfitting visible
Árbol sin cruzar (modelo 3)	Regresión	3	69,556.06	—	Mejora leve
Árbol con CV (modelo 5)	Regresión	6 (aprox.)	63,229.97	—	Mejor ajuste con CV
Árbol con CV optimizado (modelo 8)	Regresión	<b>10</b>	<b>43,921.16</b>	<b>0.7085</b>	<b>Mejor modelo para regresión</b>
Árbol de clasificación	Clasificación	5	—	—	Buena predicción por rango

Para clasificación, el mejor modelo resulta ser el árbol de decisión con profundidad 5, y para regresión es el modelo de árbol con validación cruzada y profundidad 10.